

Création de données



Cours M1 TAL - Inalco
Johanna Cordova

Structurer un corpus : le langage XML

Le langage de balisage XML

Le **langage XML** (*eXtensible Markup Language*) permet de structurer les informations d'une page grâce à des balises, pour ainsi ajouter des métadonnées au contenu.

XML définit une **syntaxe** qui permet de définir plusieurs langages : HTML, XSLT, SVG, TeX etc.

Objectif : obtenir des données structurées, interopérables.

Syntaxe XML

Le langage XML utilise des **balises** (*tag*) **ouvrantes** et **fermantes** :

`<balise></balise>`, ou éventuellement des balises autofermantes : `<balise />`.

Les balises peuvent posséder des **attributs** eux-mêmes dotés d'une valeur :

```
<text lang="fr">Mon texte en français.</text>
```

```
<h1>Exemple HTML</h1>
```

```
<p>Le texte du paragraphe est  
délimité par des balises p. <br />  
La balise br (pour break) permet  
d'afficher un retour à la ligne.</p>
```

Exemple HTML

Le texte du paragraphe est délimité par des balises p.
La balise br (pour break) permet d'afficher un retour à la ligne.

Syntaxe XML

Pour être **bien formé** , un document XML doit avoir :

- une **déclaration** XML accompagnée de l'encodage du document (optionnel) :

```
<?xml version="1.0" encoding="UTF-8"?>
```

- un élément **racine** , c'est-à-dire des balises qui englobent toutes les autres. Par exemple :

```
<document>  
    <!-- Contenu du document -->  
</document>
```

Syntaxe XML

Certains caractères ont une signification spéciale en XML et doivent être échappés avec des entités :

- & → &
- < → <
- > → >
- " → "
- ' → '

Schéma XML

La structure d'un document est définie par un **schéma**. Ce schéma détermine :

- le nom des balises à utiliser dans le document
- la hiérarchie de ces balises

Si un document respecte le schéma, on dit qu'il est **valide**.

Le schéma est défini dans un document qui sert de “grammaire” du langage XML qu'on veut utiliser. Il existe plusieurs types de schémas ; le plus répandu se nomme **DTD** (Description de Type de Document).

DTD et validation

```
<!ELEMENT text (word|verb)*>
<!ELEMENT word (#PCDATA)>
<!ELEMENT verb (#PCDATA)>
<!ATTLIST verb
    . . . . . tense CDATA #IMPLIED
    . . . . . mood CDATA #IMPLIED
    . . . . . category CDATA #REQUIRED>
```

L'élément racine `<text>` peut contenir **zéro ou plusieurs** (*) éléments `<word>` ou `<verb>`, dans n'importe quel ordre.

L'élément `<verb>` ne contient que du **texte brut** (`#PCDATA`, pour *Parsed Character Data*).

L'élément `<verb>` a **trois attributs** de type Chaîne de caractères (CDATA) : tense, mood, category. L'attribut category est obligatoire.

Cette DTD peut être définie directement dans le fichier XML ou être enregistrée dans un fichier .dtd puis liée au fichier XML grâce à une balise `<!DOCTYPE text SYSTEM "grammaire.dtd">`

DTD et validation

Il existe des outils pour vérifier qu'un XML est **bien formé** et **valide**.

Exemple : **xmllint**, ou en ligne <https://www.xmlvalidation.com/>

Installation

Ubuntu : `sudo apt install libxml2-utils`

MacOS : `brew install libxml2`

La commande `xmllint mon_fichier.xml` va vérifier si le document est bien formé.

La commande `xmllint -dtdvalid mon_fichier.xml` va vérifier si le document est valide par rapport à une DTD définie dans le document ou dans un fichier à part.

Le schéma XML-TEI

Le schéma TEI

Le **schéma TEI** (*Text Encoding Initiative*) est une proposition de balisage XML destiné à structurer des textes (littéraires, historiques) pour l'édition numérique. Il est très utilisé en Humanités Numériques, où les métadonnées internes aux textes sont essentielles.

Le schéma TEI n'est **pas une norme** : il s'agit plutôt de proposer des stratégies d'annotation de façon à uniformiser les documents de même type (dictionnaires, corpus oraux, fac-similé de manuscrits, partitions, etc.).



Intérêts du format XML-TEI

- Inclure de nombreuses métadonnées liées aux **informations non textuelles** d'un document à l'intérieur d'un corpus textuel
- **Homogénéiser** les annotations entre documents comparables, de façon à pouvoir y appliquer des traitements conjoints
- Faciliter la **diffusion numérique** des corpus grâce à la transformation automatique XML -> HTML

XSLT : réorganiser et transformer le XML

XSLT (*eXtensible Stylesheet Language Transformations*) permet de transformer un document XML vers un autre format (HTML, PDF, etc.). Il s'appuie sur XPath, un langage de requête permettant de manipuler la structure du document XML.

Pour appliquer une feuille de transformation sur un document XML, on peut utiliser la commande **xsltproc** :

```
xsltproc -o sortie.html feuille.xslt fichier.xml
```

Exercise

XML, TEI, XSL : exercices

- 1) Proposer une annotation TEI pour l'article sur la page d'accueil du Wiktionnaire grâce à la documentation TEI (liens sur Moodle).
- 2) Télécharger le document XSLT présent sur Moodle. Il va vous permettre de transformer votre fichier XML-TEI au format HTML. Modifier éventuellement le code de la feuille XSLT pour afficher au mieux votre document.