

Construction de données, pt.2

Gestion Informatique du Multilinguisme

Ilaine Wang

4 novembre 2025

Sur quoi va porter ce cours ?

- ▶ stockage et manipulation de l'information
- ▶ langue et écriture
- ▶ représentation et interprétation
- ▶ caractères, jeux de caractères, encodages
- ▶ problème d'encodage

Problèmes d'encodage...

L'histoire de cet édifice commence en 1919, quand Albert Klein, marchand de meubles, achète son frère Bernard un terrain d'une superficie de 583 m² situé à Nogent-sur-Marne au 153 de la Grande Rue.

Il faudra peu de temps à ce passionné du 7^{me} art pour monter son projet : construire et exploiter une salle de spectacles cinématographiques.

Grâce aux fonds apportés par la famille Marcelot avec laquelle il s'associe au lendemain de l'acquisition du terrain, la construction du "Nogentais-Palace" commence, dirigée par l'ingénieur-architecte Milon.

Témoin de son époque et de l'originalité de son maître d'œuvre, la façade de l'ouvrage, achevée en 1921 force l'admiration : larges baies vitrées, motifs d'ornementation, balcon travaillé en fonte. Elle sera inscrite, 70 ans plus tard, sur l'inventaire supplémentaire des Monuments Historiques.

Figure 1: Exemple 1

Problèmes d'encodage...

```
SincÃres salutations,  
L'Ãquipe Free
```

```
NOUS CONTACTER
```

```
-----
```

```
EN LIGNE https://assistance.free.fr/
```

```
PAR VISIO avec notre service d'assistance par webcam  
https://assistance.free.fr/facetofree/ disponible sur ordinateurs,  
tablettes et tÃlÃphones
```

```
PAR TÃLÃPHONE au tel:3244  
(appel inclus depuis votre ligne Free, tarif local depuis un poste  
fixe)
```

Figure 2: Exemple 2

Problèmes d'encodage...

Votre message est prêt à être envoyé avec les fichiers ou liens joints suivants :

Plan de Trésorerie.xls

Remarque : pour se protéger des virus informatiques, les programmes de messagerie électronique peuvent interdire la réception de certains types de fichiers en pièce jointe. Vérifiez les paramètres de sécurité de votre messagerie électronique pour savoir comment sont gérées les pièces jointes.

Figure 3: Exemple 3

Problèmes d'encodage...

[illegible]

Figure 4: Exemple 4

L'information en informatique

- ▶ les textes ?
- ▶ les images ?
- ▶ les sons ?
- ▶ les films ?
- ▶ les sites ?
- ▶ les chiffres ?
- ▶ les mots/lettres, ou plutôt *chaînes de caractères/caractères* ?




Figure 5: Binaire

Comment savoir quelle **interprétation** est la bonne ?

Systèmes de numération

Système binaire

Définition : système de numération de base 2.

- ▶ deux symboles quelconques : 0 ou 1, haut ou bas, *on* ou *off*, présence ou absence, être ou ne pas être...

Système décimal

Définition : système de numération de base 10.

- ▶ dix symboles : $\{ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9 \}$

10^4	10^3	10^2	10^1	10^0
10 000	1 000	100	10	1

Exemple : $8\ 326 = ?$

$$8 \times 10^3 + 3 \times 10^2 + 2 \times 10^1 + 6 \times 10^0$$

Systèmes de numération

Système binaire

Définition : système de numération de base 2.

- ▶ deux symboles : $\{ 0, 1 \}$

2^8	2^7	2^6	2^5	2^4	2^3	2^2	2^1	2^0
256	128	64	32	16	8	4	2	1

- ▶ décimal au binaire : $(10)_{10} = ?$ $(19)_{10} = ?$ $(100)_{10} = ?$
- ▶ binaire au décimal : $(101)_2 = ?$ $(10101)_2 = ?$
- ▶ calcul binaire : $(11 + 1)_2 = ?$

Système hexadécimal

Définition : système de numération de base 16.

- ▶ seize symboles, dont 10 : $\{ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9 \}$
- ▶ puis 6 : $\{ A, B, C, D, E, F \}$

Systèmes de numération

décimal vs. hexadécimal vs. binaire

Base 10	Base 16	Base 2
0	0	0
1	1	1
2	2	10
3	3	11
4	4	100
5	5	101
6	6	110
7	7	111
8	8	1000
9	9	1001
10	A	1010
11	B	1011
12	C	1100
13	D	1101
14	E	1110
15	F	1111
16	10	10000

La question de l'interprétation

Interprétation numérique

- ▶ **compter**
- ▶ en base 2, 10...
- ▶ ...mais aussi en base 5 (quinaire), 12 (duodécimal), 20 (vicésimal) etc.

Interprétation **informatique**

- ▶ codage d'une information
- ▶ codage d'un texte
- ▶ codage d'un *caractère*

La mesure de l'information

Le bit, *binary digit*

- ▶ **théorie de l'information** : quantité minimale d'information transmise par un message ;
- ▶ **informatique** : unité de mesure de base de l'information.

Le *byte*, ou “multiplet”

- ▶ la plus petite unité *logiquement* adressable par un programme sur un ordinateur
- ▶ un byte particulier, l'**octet**, le byte de 8 bits (en anglais *eight-bit byte*)
 - ▶ aujourd'hui normalisé (kB ~ ko) mais ça n'a pas toujours été le cas !
 - ▶ d'ailleurs, processeur 16 bits, 32 bits, 64 bits...

Coder l'information

- ▶ numéro d'appartement : couloir, étage, numéro
- ▶ cote de livres à la bibliothèque : fonds, section et sous-section, date, auteur...
- ▶ numéro de téléphone
- ▶ numéro de sécurité sociale
 - ▶ 12 chiffres à l'origine : année de naissance, mois de naissance, département de naissance, commune, numéro
 - ▶ 13e chiffre pour le sexe : 1 ou 2
 - ▶ clé de contrôle
- ▶ les *identifiants*...
- ▶ un alphabet ?

ASCII, American Standard Code for Information Interchange

	0	1	2	3	4	5	6	7
0	NUL	DLE	space	0	@	P	`	p
1	SOH	DC1 XON	!	1	A	Q	a	q
2	STX	DC2	"	2	B	R	b	r
3	ETX	DC3 XOFF	#	3	C	S	c	s
4	EOT	DC4	\$	4	D	T	d	t
5	ENQ	NAK	%	5	E	U	e	u
6	ACK	SYN	&	6	F	V	f	v
7	BEL	ETB	'	7	G	W	g	w
8	BS	CAN	(	8	H	X	h	x
9	HT	EM	)	9	I	Y	i	y
A	LF	SUB	*	:	J	Z	j	z
B	VT	ESC	+	;	K	[	k	{
C	FF	FS	,	<	L	\	l	
D	CR	GS	-	=	M	]	m	}
E	SO	RS	.	>	N	^	n	~
F	SI	US	/	?	O	_	o	del

Figure 6: Table ASCII

Table 7-bits

= 128 caractères (0 à 127) dont:

- ▶ caractères imprimables
 - ▶ lettres latines minuscules et majuscules
 - ▶ signes de ponctuation
 - ▶ chiffres
 - ▶ symboles mathématiques
- ▶ caractères non-imprimables = les caractères de contrôle (machines Teletype)

Le 8e bit de l'octet, ou bit de poids fort (le plus à gauche), est 0.

Table de caractères

Caractère

Un caractère peut **représenter** une lettre minuscule, une lettre majuscule, un chiffre, un signe de ponctuation ; mais aussi une espace, une tabulation, un retour à la ligne et quelques autres opérations spéciales (sonnerie, effacement, etc.).

Point de code

Chaque caractère ici a un point de code, c'est-à-dire une **valeur numérique** qui compose l'espace de codage. En ASCII, nous avons 128 caractères pour 128 points de code. Les points de code sont représentés de manière canonique en **hexadécimal**.

Pour trouver le point de code correspondant à un caractère depuis la table ASCII en Figure 6, il faut lire d'abord les colonnes (valeurs de 0 à 7, soit de 0000 à 0111 en chaînes de 4-bits) puis les lignes (valeurs de 0 à F, soit de 0000 à 1111). Par exemple, le caractère K a pour point de code 4B.