

TD2

Les tables 8 bits

1. Éditer le fichier `choeur.txt` avec votre éditeur de texte.

- a) L'affichage est-il correct ? Décrire ce que vous observez. Si vous n'observez pas de problèmes particuliers, sautez la question (d) et utilisez l'encodage trouvé en (b) pour les questions (e) et (f).
- b) Quel est l'encodage d'après votre *éditeur de texte* ? Qu'en pensez-vous ? Est-ce que votre éditeur indique autre chose que l'encodage (soit dans la barre de statut¹, soit lorsque vous voulez sauvegarder avec Ctrl+Shift+S) ?
- c) Cette fois, ouvrir le fichier avec votre *éditeur hexadécimal*. Observer les passages à la ligne. Que pouvez-vous en dire par rapport à ce que vous avez vu en cours ?
- d) Chercher et noter les caractères mal rendus ainsi que leur point de code. Comparer avec la(les) table(s) qui vous semblent justes. Quel est donc l'**encodage d'origine** de ce fichier ? Justifier.
- e) *Question bonus*: Convertir le fichier **depuis** son encodage d'origine à l'aide de la commande `iconv` **vers** l'encodage ISO-8859-15. Pour cela, se placer d'abord dans le dossier où se trouve vos fichiers. Attention, avec `bash-ubuntu`, pour accéder à vos fichiers vous devez d'abord aller dans `/mnt/c` grâce à la commande `cd` si votre disque est C:/ sous Windows, sinon remplacer par la bonne lettre.
Que se passe-t-il ? Expliquer pourquoi ce problème se pose.
- f) *Question bonus*: Recommencer la conversion mais cette fois en ajoutant `//TRANSLIT` à l'encodage d'arrivée². Que se passe-t-il ? Déduire la fonction de cette option.

2. Ouvrir successivement dans un *éditeur de texte* les fichiers suivants :

- `ChHein_v2.txt`
- `ChHein_v3.txt`
- `ChHein_v4.txt`

a) Décrire précisément les rendus, fichier par fichier.

1 Il s'agit de la barre qui se situe en bas de la fenêtre de votre éditeur.

2 Donc pour cet exercice, il s'agit de mettre `ISO-8859-15//TRANSLIT`.

- b) A partir de vos **observations** précédentes, procéder par élimination et retrouver la convention d'encodage utilisée pour écrire chacun des fichiers, c'est-à-dire celle utilisée au moment de sauvegarder les fichiers. Expliquer votre démarche.
- c) *Question bonus*: après vous être déplacé dans l'arborescence des fichiers pour vous placer dans le dossier qui contient les fichiers des exercices, faire la commande suivante : `file ChH*[2-4]*`
- Interpréter les réponses de la commande. Que pouvez-vous dire sur les fins de ligne ?
3. On ouvre les fichiers `ChHein_v1.txt` et `ChHein_v4.txt` avec un éditeur de texte.
- a) Sont-ils identiques ?
- b) Observer les octets des deux fichiers grâce à un éditeur adéquat. Quelles différences pouvez-vous constater ?
- c) Sur combien d'octets sont encodés les caractères que vous avez repérés ?
- d) Pour mieux comprendre ces différences, aller sur la page <https://www.ltg.ed.ac.uk/~richard/utf-8.html> et entrer dans le champ texte le point de code des caractères repérés pour le fichier `ChHein_v4.txt`, puis cliquer sur « Go ». Que comprenez-vous ?
4. On doit effectuer un traitement sur le texte enregistré dans le document `coeur.odt`. L'outil que nous devons utiliser nécessite que ce texte soit enregistré en texte brut dans une convention 8 bits. Quel encodage choisir pour conserver tous les caractères, y compris le caractère « œ » et les points de suspension ?
- Procéder par élimination puis, lorsque vous pensez avoir trouvé la réponse, tester votre réponse en copiant-collant le texte dans votre éditeur de texte, puis sauvegarder en sélectionnant un autre encodage que UTF-8. Est-ce correct ?
5. Peut-on enregistrer le fichier `clima.txt` dans l'un des encodages 8 bits suivants : ISO-8859-1, ISO-8859-9, ISO-8859-10³, Mac-Central Europe⁴, Windows-1250, Windows-1252 ?
- a) Pour répondre à cette question, commencer par lister les caractères hors ASCII spécifiques à ce fichier.

3 À vous de trouver la table.

4 Table ci-dessous.

Pour vous aider, vous pouvez utiliser votre éditeur hexadécimal et choisir comme encodage ASCII ou US-ASCII. Cela devrait mettre en évidence les caractères qui ne font pas partie de cette table ; vous pourrez ensuite vous référer au texte original pour savoir de quels caractères il s'agit.

- b) Faire ensuite un tableau comparatif exhaustif en trouvant, si possible, chacun des caractères répertoriés en (a) dans chacun des encodages. Noter le point de code des caractères dans le tableau.

Tableau 1 : table Mac-Central Europe

	_0	_1	_2	_3	_4	_5	_6	_7	_8	_9	_A	_B	_C	_D	_E	_F
8_128	Ä	Å	ä	É	Ą	Ö	Ü	á	ą	Č	ä	č	Ć	ć	é	Ž
	00C4	0100	0101	00C9	0104	00D6	00DC	00E1	0105	010C	00E4	010D	0106	0107	00E9	0179
9_144	ž	Đ	đ	đ'	Ě	ě	Ě	ó	è	ô	ö	õ	ú	Ě	ě	ü
	017A	010E	00ED	010F	0112	0113	0116	00F3	0117	00F4	00F6	00F5	00FA	011A	011B	00FC
A_160	†	°	£	£	§	•	¶	ß	@	©	™	€	™	≠	ğ	İ
	2020	00B0	0118	00A3	00A7	2022	00B6	00DF	00AE	00A9	2122	0119	00A8	2260	0123	012E
B_176	ı	İ	≤	≥	ı	Ɔ	ð	Σ	ł	Ł	ł	Ł	ł	ł	ł	ł
	012F	012A	2264	2265	012B	0136	2202	2211	0142	013B	013C	013D	013E	0139	013A	0145
C_192	ŋ	Ň	ŋ	√	ň	Ň	Δ	«	»	...	NBSP	ň	Ů	Ů	Ů	Ů
	0146	0143	00AC	221A	0144	0147	2206	00AB	00BB	2026	00A0	0148	0150	00D5	0151	014C
D_208	–	–	“	”	‘	’	÷	◊	ō	Ř	ř	Ř	◊	◊	ř	Ř
	2013	2014	201C	201D	2018	2019	00F7	25CA	014D	0154	0155	0158	2039	203A	0159	0156
E_224	ŕ	š	,	„	š	š	š	Á	ř	ř	í	ž	ž	Ů	ó	ô
	0157	0160	201A	201E	0161	015A	015B	00C1	0164	0165	00CD	017D	017E	016A	00D3	00D4
F_240	ū	Ů	Ú	ú	Ů	Ů	Ů	Ů	Ý	ý	ķ	Ž	ł	ž	Ç	˘
	016B	016E	00DA	016F	0170	0171	0172	0173	00DD	00FD	0137	017B	0141	017C	0122	02C7

6. L'encodage du fichier `Ostd_v2.txt` est-il ISO-8859-1 ou ISO-8859-15 ?