

Prétraitements

- Segmentation en phrases
- Tokenisation
- Lemmatisation
- Etiquetage morpho-syntaxique
- Reconnaissance des entités nommées

Segmentation en phrases

entrée	texte brut (= suite de caractères)
sortie	texte découpé en unités (paragraphe/phrases)

Pierre achète des fleurs. Il va avec sa femme au marché chez un fleuriste.



[Pierre achète des fleurs.] [Il va avec sa femme au marché chez un fleuriste.]

- séparateurs :
- problèmes

Tokenisation : segmentation en tokens

[Pierre achète des fleurs]. [Il va avec sa femme au marché chez un fleuriste.]



[Pierre] [achète] [des] [fleurs][.]

[Il] [va] [avec] [sa] [femme] [au] [marché] [chez] [un] [fleuriste][.]

Mot vs token

- Linguistique : Qu'est-ce qu'un mot ?
- TAL : Qu'est-ce qu'un token ?

Séparateurs

- Séparateurs en français ?
- Les problèmes avec les séparateurs?

Tokenisation : format

Aujourd'hui il boit du vin tandis qu'hier il buvait de l'eau.

```
# Aujourd'hui il boit du vin tandis qu'hier il buvait de l'eau.
```

```
Aujourd'hui
```

```
il
```

```
boit
```

```
de
```

```
le
```

```
vin
```

```
tandis que
```

```
hier
```

```
il
```

```
buvait
```

```
de
```

```
la
```

```
eau
```

Lemmatisation

Aujourd'hui il mange des pommes délicieuses à la cantine.

token	lemme
Aujourd'hui	aujourd'hui
il	il
mange	manger
des	une
pommes	pomme
délicieuses	délicieux
à	à
la	le
cantine	cantine

Quels sont les difficultés qu'on peut rencontrer durant la lemmatisation automatique ?

Etiquetage morpho-syntactique

- Etiquetage morpho-syntactique

<i>Token (mot)</i>	<i>Etiquette morpho-syntactique</i>	<i>Lemme</i>
<i>en effet</i>	<i>ADV</i>	<i>en effet</i>
<i>on</i>	<i>PRO-PER-3-SIN-ING</i>	<i>on</i>
<i>peut</i>	<i>VER-IND-PRE-3-SIN</i>	<i>pouvoir</i>
<i>commencer</i>	<i>VER-INF</i>	<i>commencer</i>

Quels sont les difficultés qu'on peut rencontrer durant l'étiquetage morpho-syntaxique ?

Etiqueteurs/Taggeurs en ligne

- <http://visl.sdu.dk/visl/fr/parsing/automatic/complex.php>
- <http://apps.lattice.cnrs.fr/sem/>
- <https://cental.uclouvain.be/treetagger/>

Anglais

- http://cst.dk/online/pos_tagger/uk/index.html
- <http://ucrel-api.lancaster.ac.uk/claws/free.html>

Reconnaissances des Entités Nommées

Muc (Message Understanding Conference)

- Le but de ces conférences
 - Evaluer les systèmes d'extraction d'informations.
- La définition est donnée par (Chinchor, 1997) pour la conférence Muc-7 :
 - On the level of entity extraction, **Named Entities (NE)** were defined as **proper names and quantities** of interest. **Person, organization, and location names** were marked as well as **dates, times, percentages, and monetary amounts**.

ESTER 2

Convention 1.2	Pour les différentes catégories et sous-catégories identifiées, les valeurs xxx et yyy prennent les valeurs suivantes :	
- personne ▪ humain réel ou fictif ▪ animal réel ou fictif	- pers ▪ pers.hum ▪ pers.anim	
- fonction ▪ politique ▪ militaire ▪ administrative ▪ religieuse ▪ aristocratique	- fonc ▪ fonc.pol ▪ fonc.mil ▪ fonc.admi ▪ fonc.rel ▪ fonc.ari	
- organisation ▪ politique ▪ éducative ▪ commerciale ▪ non commerciale ▪ média & divertissement ▪ géo-socio-administrative	- org ▪ org.pol ▪ org.edu ▪ org.com ▪ org.non-profit ▪ org.div ▪ org.gsp	
- lieu ▪ géographique naturel ▪ région administrative ▪ axe de circulation ▪ adresse ○ adresse postale ○ téléphone et fax ○ adresse électronique ▪ construction humaine	- loc ▪ loc.geo ▪ loc.admi ▪ loc.line ▪ loc.addr ○ loc.addr.post ○ loc.addr.tel ○ loc.addr.elec ▪ loc.fac	
- production humaine ▪ moyen de transport ▪ récompense ▪ œuvre artistique ▪ production documentaire	- prod ▪ prod.vehicule ▪ prod.award ▪ prod.art ▪ prod.doc	
- date et heure ▪ date ○ date absolue ○ date relative ▪ heure	- time ▪ time.date ○ time.date.abs ○ time.date.rel ▪ time.hour	
- montant ▪ âge ▪ durée ▪ température ▪ longueur ▪ surface et aire ▪ volume ▪ poids ▪ vitesse ▪ autre ▪ valeur monétaire	- amount ▪ amount.phy.age ▪ amount.phy.dur ▪ amount.phy.temp ▪ amount.phy.len ▪ amount.phy.area ▪ amount.phy.vol ▪ amount.phy.wei ▪ amount.phy.spd ▪ amount.phy.other ▪ amount.cur	

Le guide Quaero





FIG. 1.3: Exemples d'entités.



Quels sont les difficultés qu'on peut rencontrer durant la reconnaissance des entités nommées ?

Demo en ligne

<http://apps.lattice.cnrs.fr/sem/>

<https://explosion.ai/demos/displacy-ent>

<https://cloud.gate.ac.uk/shopfront/displayItem/french-named-entity-recognizer>