

Evaluation

Evaluation

- Evaluation d'un système :
 - nécessite un corpus de référence (humaine)
 - évalue à quelle point le résultat du traitement automatique est proche de la référence


Mesures d'évaluation

Mesures binaires

- ▶ Sur N données, calcul d'un **taux d'erreur** binaire
- ▶ Exactitude (en anglais **accuracy**)
- ▶ Exemple : “Je suis parti en vacances avec Marie” (7 mots)
 - Combien de données ont été **correctement traitées** ?
 - ⇒ Etiquetage morpho-syntaxique
 - PRO VER VER PREP NC PREP NP : $7/7 = 100\%$
 - PRO VER **NC** PREP NC PREP NP : $6/7 = 86\%$

Il existe quatre cas de distribution entre le résultat de *référence* et le résultat de l'*hypothèse*.

1. *vrais positifs* (accord type 1) : nombre d'exemples similaires entre la référence et l'évaluation
2. *faux positifs* (désaccord type 1) : nombre de cas présents dans l'hypothèse et absents de la référence
3. *faux négatifs* (désaccord type 2) : nombre de cas présents dans la référence et absents de l'hypothèse
4. *vrais négatifs* (accord de type 2) : nombre de cas absents de la référence et de l'hypothèse



Rappel Le « rappel » (*recall*), « sensibilité » (*sensitivity*) ou « taux de vrais positifs », est une mesure quantitative (formule 1). Elle mesure le nombre d'éléments correctement étiquetés par le système (vrais positifs) rapporté au nombre d'éléments étiquetés dans la référence (vrais positifs et faux négatifs).

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux négatifs}} \quad (1)$$

Précision La « précision » (*precision*), ou « valeur prédictive positive », est une mesure qualitative (formule 2). Elle mesure le nombre d'éléments correctement étiquetés par le système (vrais positifs) rapporté au nombre total d'éléments étiquetés par le système (vrais et faux positifs).

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}} \quad (2)$$

F-mesure Moyenne harmonique pondérée du rappel et de la précision

$$\text{F-mesure} = \frac{(1 + \beta^2) \times \text{Précision} \times \text{Rappel}}{\beta^2 \times \text{Précision} + \text{Rappel}}$$

La valeur attribuée à β permet :

- soit d'équilibrer les poids du rappel et de la précision ($\beta=1$) ;
- soit de favoriser le rappel par rapport à la précision ($\beta=2$), ou la précision par rapport au rappel ($\beta=0.5$).

Exemple

- l'ensemble des éléments attendus : A,B,C,D,E (5 éléments)
 - l'ensemble des éléments retrouvés : B,C,D,F (4 éléments).
- ⇒ l'ensemble des éléments attendus retrouvés est B,C,D (3 éléments communs).

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}}$$

$$P=3/4=75\%$$

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux négatifs}}$$

$$R=3/5=60\%$$

- la F-mesure est la moyenne harmonique de la précision P et du rappel R

$$F=2(P \times R)/(P+R)$$

Méthodologie

Partitions

- Les données sont divisées en plusieurs sous-corpus (2 ou 3)
- La proportion de la division **dépend de la taille et de la spécificité de l'ensemble de données**
- Le **jeu de test est laissé de côté**, de façon à ce qu'il ne soit jamais vu par le modèle. Il **sert à évaluer la performance du système**.

Division de corpus : 2 sous échantillons

- Elaboration de règles symboliques :
 - développement de règles : 60%-70%
 - Test ou évaluation : 30-40%
- Méthodes statistiques :
 - entraînement du modèle : 60%-70%
 - Test ou évaluation : 30-40%

Division de corpus : 3 sous échantillons

- Division de corpus : entraînement / test :
 - diviser l'échantillon en plusieurs sous échantillons :
 - entraînement – développement - test


Evaluation : division de corpus (3 sous échantillons)

- Méthodes symboliques

- Développement de règles : 40%-60%
- Test de règles : 20%-40%
- Evaluation : 20%-40%

- Méthodes statistiques

- Entraînement : 40%-50%-60%
- Validation : 20%-30%-40%
- Test ou évaluation : 20%-40%




Validation croisée

La validation croisée est une méthode d'estimation de fiabilité d'un modèle fondé sur une **technique d'échantillonnage**.

- **diviser l'échantillon en k échantillons**, sélectionner un des k échantillons comme ensemble de validation et les (k-1) autres échantillons constitueront l'ensemble d'apprentissage.
- Ex. 10 sous-corpus, on apprend sur 9 et on teste 10^{ème}, puis on répète l'opération en sélectionnant un autre échantillon de validation parmi les échantillons qui n'ont pas encore été utilisés pour le test.

L'opération se répète ainsi k fois pour qu'en fin de compte chaque sous-échantillon ait été utilisé exactement une fois comme ensemble de validation.



Méthodes mixte

Diviser le corpus en 3 parties

- 80% validation croisée,
- 10% développement ,
- 10% test