

4L7TL02P – Analyse symbolique de données

Introduction

Delphine Battistelli, Anna Colli

dbattist@parisnanterre.fr

acolli@parisnanterre.fr

Organisation du cours

- Espace Cours en ligne U. Paris Nanterre > M1 TAL > Analyse symbolique des données (Groupe 1 / Groupe 2)
- À installer sur les machines : Unitex (<https://unitexgramlab.org/fr>)
LabelStudio (<https://labelstud.io/>)
- Evaluation : DM – 40% + DST – 60%
- Bibliographie indicative
 - Desclés, J.-P. (1969), “Linguistique et Mathématiques”, l’Homme, 9-3, pp. 93-99
 - Gosselin, L. (2015), “De l’opposition *modus/dictum* à la distinction entre modalités extrinsèques et modalités intrinsèques”, *Bulletin de la Société de Linguistique* de Paris, CX-1, pp. 1-50
 - Opitz, J., Wein, S., Schneider, N., (2025). “Natural Language Processing RELIES on Linguistics”. *Computational Linguistics* 2025; 51 (3): 1009–1032
 - Sutton, R. (2019). “The bitter lesson”. *Incomplete Ideas (blog)*, 13(1), 38
 - Tanguy L., Fabre C. (2014), “Évolutions de la linguistique outillée : méfaits et bienfaits du TAL”. *L’information grammaticale*, 2014, 142, pp.15-23
 - Victorri, B., (1997). “Le modèle en linguistique”, *Encyclopaedia Universalis*, 1997

Organisation du cours

GROUPE 1 – salle 418

25/09 : Introduction

02/10 : DB

09/10 : DB

16/10 : DB

23/10 : DB

– 30/10 : **vacances** –

06/11 : **DB - DST modélisation automates**

13/11 : AC

20/11 : AC

27/11: AC

04/12: AC

11/12: AC

18/12 : AC (séance pour avancer sur le DM)

Rendu du DM ↔ 08/01

GROUPE 2 – salle 308

25/09 : Introduction

02/10 : AC

09/10 : AC

16/10 : AC (9h30 - 12h30)

23/10 : **absente**

– 30/10 : **vacances** –

06/11 : AC (9h30 - 12h30)

13/11 : DB

20/11 : DB

27/11: DB

04/12: DB

11/12: DB

18/12 : **DB - DST modélisation automates**

Rendu du DM ↔ 18/12

Avant de commencer ...

Votre parcours ?

Qu'attendez-vous de votre formation en master TAL ?

fiche avec nom, prénom, université, formation (si $\neq$ Master TAL)

Objectif du cours – *Modéliser en linguistique : pourquoi, comment, quelles implications pour le TAL*

- Modéliser pour rendre compte de phénomènes observables
- Mesurer l'adéquation d'une théorie aux faits de langue qu'elle prétend expliquer
- Objectif : compromis entre simplicité du système *et* adéquation aux données observées
- Mise à contribution des mathématiques grâce aux outils informatiques dans la construction des modèles (ex. automates finis, automates à pile)

Questionnement sous-jacent : le TAL a-t-il encore besoin de linguistes ?

Deux exemples (deux parties distinctes du cours)


Exemple 1 : la notion de 'date' → modélisation linguistique par des automates

Exemple 2 : la notion d' 'incertitude' → modélisation linguistique *via* un logiciel d'annotation

Introduction : Modéliser en linguistique

Qu'est-ce que "modéliser" ?


- La démarche scientifique consiste à observer, décrire, classer, généraliser, modéliser
 - L'*observation* est la toute première phase de la démarche scientifique,
 - tandis que la *modélisation* en constitue la phase ultime
- Ceci est vrai en linguistique comme dans d'autres sciences




C'est Chomsky, dans les années '50, qui a donné à la linguistique le statut de science

Qu'est-ce que "modéliser" ?

Démarche scientifique



Modéliser en linguistique



Modéliser en linguistique

- Modéliser pour rendre compte de phénomènes observables
- Mesurer l'adéquation d'une théorie aux faits de langue qu'elle prétend expliquer
- Objectif : compromis entre simplicité du système et adéquation aux données observées
- Mise à contribution des mathématiques grâce aux outils informatiques dans la construction des modèles

"Modéliser" en TAL ?

A LIRE :

HABERT, Benoît. « Portrait de linguiste(s) à l'instrument ». *Texto!* [en ligne], décembre 2005, vol. X, n°4
http://www.revue-texto.net/Corpus/Publications/Habert/Habert_Portrait.html

VICTORRI, Bernard. « Le modèle en linguistique », *Encyclopaedia Universalis*, 1997
Version préliminaire disponible sur
<http://halshs.archives-ouvertes.fr/halshs-00009518>


Les observables en TAL :

- TAL avant 2000' :
 - **Observables** : recours très limité à des corpus et appel à l'intuition
 - **Méthodes** : méthodes à base de règles
- TAL depuis 2000' : “statistical revolution” (Church, 2011)
 - **Observables** : un **changement d'échelle** dans les **observables**. Des corpus très volumineux, et aussi très diversifiés (articles scientifiques, blogs, romans, tweets, ...)
 - **Méthodes** : les **méthodes par apprentissage** (*i.e.* méthodes statistiques). Dans ces méthodes, « le rôle principal attribué au linguiste (...) se limite à l'annotation des données, que ce soit à des fins d'entraînement ou d'évaluation » (Fabre, 2010)


→ *Observe-t-on vraiment les données ? Quelle est la place du linguiste ? Quelle est la place des outils de TAL dans cette observation ?*

→ *Le TAL a-t-il encore besoin des linguistes ?*

Evolution des observables et des méthodes en TAL



Evolution des observables et des méthodes en TAL



Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). "Attention is all you need." *Advances in neural information processing systems*, 30.

Le TAL a-t-il encore besoin des linguistes ?

Une première réponse, avant le *Deep Learning* :

- Oui !
- Performances limitées aux phénomènes fréquents (Hajicova, 2011), pourtant phénomènes "rares" nombreux cf. loi de Zipf (Kay, 2011)

Hajičová, E. (2011). Computational linguistics without linguistics ? view from prague. Linguistic Issues in Language Technology, 6.
Kay, M. (2011). Zipf's law and l'arbitraire du signe. Linguistic Issues in Language Technology, 6.

Le TAL a-t-il encore besoin des linguistes ?

Une première réponse, avant le *Deep Learning* :

- Kay (2011) et Hajicová (2011) rappellent que les connaissances linguistiques pointues sont les seules façons de faire progresser les systèmes au-delà de la zone des phénomènes suffisamment répétés, *i.e.* les fameux 80 premiers %, alors que **la loi de Zipf** nous a depuis longtemps appris qu'**un grand nombre de phénomènes très rares constituent la partie manquante de la couverture de tout système de TAL**.
- Dans tous les cas, Church (2011) prédit **un retour cyclique du balancier vers des travaux de TAL** plus théoriques et moins empiriques lors de la prochaine décennie, avec dans ce cadre une remontée en puissance de la linguistique sur la scène du TAL

Church, K. (2011). A pendulum swung too far. Linguistic Issues in Language Technology, 6.

Hajičová, E. (2011). Computational linguistics without linguistics ? view from prague. Linguistic Issues in Language Technology, 6.

Kay, M. (2011). Zipf's law and l'arbitraire du signe. Linguistic Issues in Language Technology, 6.

Le TAL a-t-il encore besoin des linguistes ?

Est-ce que cette réponse est encore d'actualité, même après le *Deep Learning* ?

- On a l'impression que les LLMs sont désormais capables d'exécuter n'importe quelle tâche de manière satisfaisante et qu'ils sont donc de plus en plus capables de traiter ces fameux phénomènes "rares" dont on parlait en 2010.
(Pourquoi? + de données, + de paramètres)
- (Sutton, 2019) "The Bitter Lesson" : *"The biggest lesson that can be read from 70 years of AI research is that **general methods that leverage computation are ultimately the most effective**, and by a large margin. [...] Researchers seek to leverage their human knowledge of the domain, but **the only thing that matters in the long run is the leveraging of computation**. [...] And the human-knowledge approach tends to complicate methods in ways that make them less suited to taking advantage of general methods leveraging computation."*

→ (Sutton, 2019) affirme que pour progresser il faut se focaliser sur la **puissance de calcul** et les **méthodes générales** plutôt que d'essayer de donner aux machines du savoir spécifique qui vient de nous.

Le TAL a-t-il encore besoin des linguistes ?

Est-ce que cette réponse est encore d'actualité, après le *Deep Learning* ?

Question : faut-il “juste” augmenter la puissance de calcul et les données ?

Pas vraiment ...

- coût financier et impact environnemental
- manque de connaissance sur des sujets spécifiques / complexes / en temps réel (et donc : hallucinations)
- **mauvaises performances sur des tâches concernant la sémantique**
- manque d'explicabilité et interprétabilité

Aujourd'hui, les méthodes symboliques sont de plus en plus utilisées dans la recherche académique comme industrielle :

- knowledge representations, knowledge graphs, ontologies
- “expert” ressources : **ce à quoi nous allons nous intéresser dans ce cours**

Le TAL a-t-il encore besoin des linguistes ?

Est-ce que cette réponse est encore d'actualité, même après le *Deep Learning* ?

Même si on a à disposition le dernier modèle en termes de puissance, il est important de savoir :

Ce que l'on cherche exactement

Comment ?

En **modélisant le problème/phénomène linguistique** que l'on veut aborder

Comment modéliser ?

En faisant appel aux **modèles** offerts par la **linguistique**

Le TAL a-t-il encore besoin des linguistes ?

Est-ce que cette réponse est encore d'actualité, même après le *Deep Learning* ?


(Opitz et al., 2025)

“**Sensitivity to linguistic factors** is particularly important because of the wide variability of human language and the **subjectivity inherent in certain labeling problems**, like sentiment and toxic language (Sasidharan Nair, Dinkar, and Abercrombie 2024; Abercrombie, Hovy, and Prabhakaran 2023).

[...] In the annotation process, **advanced linguistic knowledge of annotators has been of value**, and people skilled at language analysis can ensure **meaningful evaluation of NLP systems**. [...] For **consistent sentiment annotation**, Taboada (2016) highlights the importance of understanding linguistic discourse phenomena.”

[...] To design approaches for **meta-evaluation** (assessing and comparing metrics), **expertise in linguistics** can prove highly useful, since **the challenging linguistic phenomena for models and metrics need to be understood in order to be identified**. In a WMT metric shared task, Freitag et al. (2021b) find that most metrics struggle to **handle complex semantic phenomena** and do not appropriately punish the reversal of sentiment or negation; this is established with test sets that assess specified linguistic features (here: sentiment or negation reversal).”

Les principes adoptés dans ce cours :



Le TAL a besoin de **modèles linguistiques** rigoureux à implémenter pour optimiser les applications

→ On adopte une démarche de modélisation linguistique et l'on met à contribution des mathématiques grâce aux outils informatiques dans la construction d'un modèle

Organisation du cours

Deux parties correspondant à deux exemples d'analyse et de modélisation :

Exemple 1 : la notion de 'date' -> le concept linguistique d'adverbial temporel -> modélisation linguistique par des automates

Exemple 2 : la notion d' 'incertitude' -> le concept linguistique de modalité épistémique -> modélisation linguistique *via* un logiciel d'annotation

Quelques exemples d'applications en TAL où les notions intuitives de 'date' et d' 'incertitude' sont mobilisées :

- Détection automatique des connaissances certaines / incertaines dans des articles journalistiques ou sur les réseaux sociaux (*fake news*)
- Détection de discours propagandistes *via* la détection et la quantification de marqueurs modaux
- Calcul de l'ordonnancement temporel d'évènements à partir des adverbes temporels
- Repérage d'évènements saillants dans des corpus d'entretiens relatifs à une situation traumatique

Exemple 1 : la notion (intuitive) de date

- **En linguistique** : renvoie à la notion d' "adverbe temporel"
- **En extraction d'information** : est qualifiée d' "entité nommée"
- **En TAL** : dans les classifications (annotations) proposées, on opposera le plus souvent "date", "durée" et "fréquence" et on s'intéressera également à l'opposition "relatif" vs "absolu"



→ Comment modéliser cette notion *linguistiquement*, c'est à dire en intégrant du mieux possible le savoir expert du linguiste

→ approche symbolique à l'aide d'un logiciel de définition d'automates finis (Unitex)

Exemple 2 : la notion (intuitive) d'incertitude

- **En linguistique** : traitée comme un type de “modalité”. Beaucoup de cadres théoriques différents pour traiter la modalité.
- **En TAL** : le plus souvent ramenée à un cadre applicatif, lui même lié à un genre de textes. Ex. : repérer dans des textes scientifiques du domaine de la biologie des connaissances “incertaines” vs. “certaines”



→ voir comment une modélisation *fine* de la notion permet d'en retrouver les modes d'expression dans un texte

→ approche symbolique *via* un logiciel d'annotation manuelle (LabelStudio) et une ressource experte déjà construite

Exemple 1 : Les dates



Exemple 2 : L'incertitude

