

LYSET08 – Analyse linguistique des modèles de langues

Diaporama 3 – Convertir le texte en nombres.
Vecteurs, TF-IDF, Similarités, Statistiques

[Andrea Briglia](#)

andrea.briglia@sorbonne-nouvelle.fr


Crédits : Marine Wauquier, Lila Kim

- L'objectif de **la tokenisation** est de diviser un texte en une séquence de "mots", généralement appelés "tokens".
- Ces tokens comprennent des chaînes successives de caractères alphanumériques, des nombres, ainsi que des éléments comme les traits d'union et les apostrophes.

- **L'étiquetage morphosyntaxique** (POS Tagging) consiste à attribuer automatiquement une catégorie grammaticale à chaque mot d'une phrase.
- Chaque mot reçoit une étiquette correspondant à sa nature morphosyntaxique.
 - Quelques exemples de balises courantes : NN (nom), VV (verbe), AA (adjectif), Aux (auxiliaire), PU (ponctuation).
 - Cette annotation est essentielle en traitement automatique du langage naturel (NLP) pour des tâches comme l'analyse syntaxique, la reconnaissance d'entités nommées ou la désambiguïsation sémantique.

Basic NLP Tools - Parser

- **Un analyseur syntaxique** (Syntactic Parser) a pour objectif d'effectuer une analyse automatique des relations de dépendance syntaxique entre les mots d'une phrase.
- En analyse en dépendances (dependency parsing), chaque mot est relié à un autre mot par une relation grammaticale, formant ainsi une structure en arbre. L'idée est de comprendre comment les mots s'articulent les uns avec les autres pour former le sens global de la phrase.



Le modèle d'espace vectoriel (*Vector Space Model - VSM*)

- Proposé par G. Salton et al. dans le domaine de la recherche d'information à la fin des années 1960.
- Une représentation textuelle le plus simple et le plus couramment utilisé en text mining.
- L'idée centrale est de représenter les documents et les requêtes sous forme de vecteurs dans un espace où chaque dimension correspond à un terme du vocabulaire.
- Chaque document est donc un point dans cet espace et la pertinence d'un document par rapport à une requête est calculée à l'aide de mesures de similarité comme le produit scalaire ou la similarité cosinus.

Introduction to VSM (ii)

Définitions de base

- **Texte** : Une séquence de caractères pouvant être des phrases, des paragraphes ou un document entier. Ici, l'accent est mis sur les documents.
- **Terme** : L'unité linguistique minimale et indivisible dans le modèle d'espace vectoriel (VSM). Il peut s'agir de caractères, mots, phrases, etc. En VSM, un texte est vu comme un ensemble de termes, noté $(t_1, t_2, \dots, t_n)$, où t_n représente le n ème terme.
- **Poids du terme** : Pour un texte contenant n termes, chaque terme t se voit attribuer un poids w , selon certains principes, afin d'**indiquer son importance et sa pertinence dans le texte**. Un texte est ainsi représenté par un ensemble de termes associés à leurs poids $(w_1, w_2, \dots, w_n)$.

Représentation des documents

- Un document d est représenté comme un vecteur :

$$d = (w_1, w_2, \dots, w_n) \quad (1)$$

- où chaque w_i est le poids du terme t_i , dans le document d .
- Ce poids est souvent calculé à l'aide de **TF-IDF** (*Term Frequency - Inverse Document Frequency*) ou d'autres pondérations.

Introduction to VSM (iV)

- Le modèle d'espace vectoriel nécessite une collection de termes uniques ($t_1, t_2, \dots, t_n$). Lorsqu'on utilise des mots comme termes, cette collection peut être considérée comme un vocabulaire.
- Les termes sont traités comme un sac de mots (*bag of words*), ce qui signifie que **l'ordre des mots n'est pas pris en compte**. C'est pourquoi le modèle d'espace vectoriel est aussi appelé modèle Bag-of-Words (BoW).

Un sac de mots est une représentation d'un texte qui décrit la présence et la fréquence des mots dans un document, sans tenir compte de leur ordre.

Introduction to VSM (V)

Un sac de mots est une représentation d'un texte qui décrit la présence et la fréquence des mots dans un document, sans tenir compte de leur ordre.

- Document 1 : A rose is red, a violet is blue.
- Document 2 : My love is like a red, red rose.

Introduction to VSM (V)

Un sac de mots est une représentation d'un texte qui décrit la présence et la fréquence des mots dans un document, sans tenir compte de leur ordre.

- Document 1 : A rose is red, a violet is blue.
- Document 2 : My love is like a red, red rose.

Document	"red"	"rose"	"violet"
Doc 1	1	1	1
Doc 2	2	1	0

Introduction to VSM (V)

Un sac de mots est une représentation d'un texte qui décrit la présence et la fréquence des mots dans un document, sans tenir compte de leur ordre.

- Document 1 : A rose is red, a violet is blue.
- Document 2 : My love is like a red, red rose.

Document	"red"	"rose"	"violet"
Doc 1	1	1	1
Doc 2	2	1	0

- Doc 1 $\rightarrow (1,1,1)$
- Doc 2 $\rightarrow (2,1,0)$

Introduction to VSM (Vi)




Figure 1: Sous forme de vecteurs de données dans un espace de caractéristiques tridimensionnel. D'après [IBM](#).

Introduction to VSM (Vi)




Figure 2: Sous forme de vecteurs de données dans un espace de caractéristiques tridimensionnel. D'après [IBM](#).

Introduction to VSM (Vi)





Figure 3: Sous forme de vecteurs de caractéristiques dans un espace de données. D'après IBM.

Un vecteur de caractéristiques représente la valeur (occurrence) d'une caractéristique donnée (mot) dans un point de données spécifique (document)

Introduction to VSM (Vii)

Un sac de mots repose sur deux hypothèses principales :

- Chaque terme t_i est unique, ce qui signifie qu'il n'y a pas de duplication dans la représentation vectorielle du texte.
- L'ordre des termes n'est pas pris en compte, ce qui signifie que la structure syntaxique du texte est ignorée.



Le calcul du poids des termes est une étape clé dans la représentation des textes en VSM.

1. **Poids booléen**(*Boolean Weight - BOOL*) : Ce modèle indique uniquement si un terme apparaît dans un document ou non. If t_i in d : $w_i = 1$; else 0.
2. **Fréquence du terme** (*Term Frequency - TF*) : Le TF mesure la fréquence d'un terme dans un document. Il repose sur l'idée que **plus un mot apparaît souvent, plus il est important** dans ce document.

$$TF = \frac{\text{Nombre d'occurrences du terme}}{\text{Nombre total de termes dans le document}} \quad (2)$$

3. **Fréquence Inverse du Document** (*Inverse Document Frequency - IDF*) :

L'IDF mesure l'importance d'un terme dans l'ensemble du corpus.

- Il est basé sur l'idée que **les mots présents dans de nombreux documents sont moins informatifs**.

$$IDF = \log\left(\frac{\text{Nombre total de documents}}{\text{Nombre de documents contenant le terme}}\right) \quad (3)$$

- Un mot qui apparaît dans tous les documents aura un IDF faible (= peu d'information).
- Un mot rare dans le corpus aura un IDF élevé (= plus discriminatif).

4. **TF-IDF** (*Term Frequency - Inverse Document Frequency*) : Le TF-IDF combine TF et IDF pour attribuer un score aux termes en permettant de quantifier l'importance d'un terme pour un document particulier compte tenu de ses occurrences dans tous les autres documents.

$$TF - IDF = TF \times IDF \quad (4)$$

- De fait, un terme est d'autant plus pertinent s'il est surreprésenté dans un document, tout en étant rare dans l'ensemble du corpus.
- Avantage : TF-IDF améliore la pertinence des représentations textuelles en mettant en avant les mots significatifs et en réduisant l'impact des mots très fréquents.

Modèle n-gram

- Contrairement au modèle VSM, les ***n*-grammes** s'appuient sur des séquences contiguës de n éléments (mots ou caractères), ce qui permet de capturer une partie de l'ordre des mots dans le texte.
- Malgré leur simplicité, les n-grammes sont très efficaces pour détecter des groupes de mots fréquemment associés. Même avec une petite valeur de n , le calcul de tous les n-grammes peut faire émerger des motifs intéressants du texte, sans traitement supplémentaire.
- En revanche, il faut garder à l'esprit que stocker un modèle n-gramme peut être coûteux en mémoire : il nécessite de l'espace pour environ $T \times n$ tokens, où T est le nombre total de tokens et n la taille des n-grammes.

Co-occurrences et collocations

Les termes « collocation » et « cooccurrence » sont souvent confondus. . .


- **Une cooccurrence** désigne une **combinaison de mots qui apparaissent fréquemment ensemble dans un même corpus**.
 - Lorsqu'un mot est présent, cela suggère souvent la présence d'un autre mot associé, car **ils sont régulièrement utilisés dans un contexte similaire**.
 - Par exemple, on retrouve fréquemment les associations suivantes dans les textes : « professeurs, étudiants », « médecin, infirmière », ou encore « pain, boulangerie », car ces mots partagent un environnement lexical commun.
- **Les collocations**, quant à elles, sont un type particulier de cooccurrence.
 - Ce sont des **associations de mots qui apparaissent naturellement ensemble**, formant des expressions courantes.
 - En français, on peut citer comme exemples : « un désir ardent », « un léger frisson », ou « un regret amer ».

Mais comment savoir si deux termes sont associés plus fréquemment que ce qu'on attendrait simplement par hasard ou en moyenne ?

- ➡ On peut utiliser différentes mesures statistiques : le test du χ^2 (khi-deux), le test de Student, le likelihood ratio (rapport de vraisemblance), et la pointwise mutual information (PMI), ou score d'information mutuelle.

Test de *Student* (i)

- Le test de *Student* est l'un des tests statistiques les plus utilisés pour vérifier l'hypothèse d'indépendance entre deux groupes.
- Il fonctionne en comparant les moyennes des deux groupes, afin de déterminer si la différence observée peut s'expliquer par le hasard, ou si elle est statistiquement significative.
- Toutefois, ce test repose sur une hypothèse forte : il suppose que les données dans chaque groupe suivent une distribution normale.



Test de *Student* (ii)

1. En partant de l'idée que deux termes sont indépendants (H_0)
2. On calcule la fréquence moyenne attendue de leur cooccurrence si H_0 est vraie.
3. On observe la fréquence réelle dans le corpus.
4. On applique un test t de *Student* pour voir si la différence entre fréquence observée et fréquence attendue est significative -> le test t nous donne une p-value.
5. Si la probabilité est significativement petite ($< 0,05$), H_0 est rejetée (on peut supposer qu'ils sont associés).

Test de *Student* (iii)

$$t\text{-Student}(\text{"machine - learning"}) = \frac{\frac{N(\text{"machine learning"})}{T} - \left(\frac{N(\text{"machine"})}{T} \times \frac{N(\text{"learning"})}{T} \right)}{\sqrt{\frac{N(\text{"machine-learning"})}{T}}} \quad (1)$$

Test de *Student* (iV)

Prenons par exemple la paire "machine" - "learning" et nous souhaitons savoir si ces deux termes apparaissent ensemble par hasard ou non.

- On prends plusieurs sous-parties du corpus (ex : $N = 1000$ phrases).
- Dans chaque sous-partie, on note si les deux mots apparaissent ensemble ($=1$) ou non ($=0$).
- On calcule la moyenne observée de cooccurrences.
- On compare cette moyenne à la moyenne attendue (si H_0 est vraie).
- Le test t indique si la différence est trop grande pour être due au hasard.

Test du khi-deux (Chi-squared)

- Le test du χ^2 permet de vérifier s'il existe une relation significative entre deux variables.

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i} \quad (2)$$

où χ^2 = khi carré

O_i = valeur observée

E_i = valeur attendue

- En Traitement Automatique du Langage (TAL), il est souvent utilisé pour évaluer l'indépendance entre deux termes.
- Contrairement à d'autres tests statistiques, il ne suppose pas que les données suivent une distribution normale.

Test du khi-deux (ii)

- Il attribue un score d'association à une paire de mots, en se basant sur quatre types d'observations :

	Mot 2 présent	Mot 2 absent	Total
Mot 1 présent	a	b	a+b
Mot 1 absent	c	d	c+d
	a+c	b+d	N

Test du khi-deux (iii)

Reprenons nos observations de deux termes "Machine" et "Learning".

	"Learning" présent	"Learning" absent	Total
"Machine" présent	$a = 30$	$b = 70$	$a + b = 100$
"Machine" absent	$c = 50$	$d = 850$	$c + d = 900$
Total	$a + c = 80$	$b + d = 920$	1000

Test du khi-deux (iii)

Reprenons nos observations de deux termes "Machine" et "Learning".

	"Learning" présent	"Learning" absent	Total
"Machine" présent	$a = 30$	$b = 70$	$a + b = 100$
"Machine" absent	$c = 50$	$d = 850$	$c + d = 900$
Total	$a + c = 80$	$b + d = 920$	1000

Le calcul de la valeur attendue se fait à l'aide de l'équation suivante:

$$E_i = \frac{(\text{total ligne}) \times (\text{total colonne})}{N} \quad (3)$$

Test du khi-deux (iii)

Reprenons nos observations de deux termes "Machine" et "Learning".

	"Learning" présent	"Learning" absent	Total
"Machine" présent	$a = 30$	$b = 70$	$a + b = 100$
"Machine" absent	$c = 50$	$d = 850$	$c + d = 900$
Total	$a + c = 80$	$b + d = 920$	1000

Le calcul de la valeur attendue se fait à l'aide de l'équation suivante:

$$E_i = \frac{(\text{total ligne}) \times (\text{total colonne})}{N} \quad (3)$$

Puis on applique le test du Khi-deux.


Rapport de vraisemblance (Likelihood ratio)

- Ce test compare deux hypothèses :
 - H_0 : les deux termes sont indépendants (ils coapparaissent par hasard).
 - H_1 : les deux termes sont dépendants (plus que par hasard).
- Pour cela, il calcule une vraisemblance sous chaque hypothèse, en s'appuyant sur les probabilités conditionnelles :
 - Quelle est la probabilité qu'un mot apparaisse si l'autre est présent ?

Rapport de vraisemblance (ii)


- Le ratio est déterminé en comparant les deux valeurs de vraisemblances obtenus.
- Ce calcul suppose que les apparitions des mots suivent une loi binomiale (présent/absent dans chaque contexte).

b) Likelihood ratio



Similarité entre documents

- Dans le modèle de l'espace vectoriel, chaque document est représenté par un vecteur.
- Deux approches courantes pour évaluer la similarité entre documents :
 - La similarité cosinus (largement utilisée pour les textes)
 - La similarité basée sur la distance (idéale pour données numériques absolues)



La similarité cosinus



- La similarité cosinus mesure le degré de ressemblance entre deux vecteurs en calculant le cosinus de l'angle qui les sépare.
- Plus cet angle est **petit**, plus la similarité est **grande**.
 1. Si les vecteurs sont parfaitement alignés (angle de 0°), la similarité est maximale : 1.
 2. S'ils sont orthogonaux (angle de 90°), cela signifie qu'ils ont rien en commun : la similarité est 0.
 3. Enfin, s'ils pointent dans des directions opposées (angle de 180°), la similarité atteint son minimum : -1.

La similarité basée sur la distance (i)

- La méthode la plus simple pour comparer deux documents consiste à mesurer la distance entre leurs vecteurs dans un espace vectoriel.
 - Plus cette distance est **courte**, plus les documents sont **considérés comme similaires**.
- Parmi les métriques les plus utilisés, on retrouve notamment la distance euclidienne, Manhattan, Chebyshev, Minkowski, Mahalanobis et Jaccard.

La similarité basée sur la distance (ii)

- **Distance euclidienne** : elle se calcule à partir des coordonnées cartésiennes des points, en appliquant le théorème de Pythagore.
 - /!\ Résultats faibles pour les données de grande dimension
- **Distance de Manhattan** (*taxicab* ou *city block*) : elle mesure l'écart entre deux vecteurs numériques en suivant un chemin en grille.
 - Un bon exemple est une pièce se déplaçant sur un échiquier : elle ne va que de case en case horizontalement ou verticalement.
 - /!\ Moins intuitive que la distance euclidienne, surtout lorsqu'on l'applique à des données en haute dimension



La similarité basée sur la distance (iii)

- **Distance de Chebyshev** : elle correspond à la plus grande différence entre deux vecteurs sur une seule dimension.
 - En d'autres termes, on ne prend que l'axe où l'écart est le plus fort.
- **Indice de Jaccard** (Intersection sur Union) : il mesure la similarité entre deux ensembles.
 - On le calcule en divisant la taille de l'intersection par celle de l'union.
 - **/!\ Inconvénient important** : il est très sensible à la taille des données. Dans les grands ensembles, l'union peut beaucoup croître alors que l'intersection reste stable, ce qui fausse l'interprétation du score.

