

LYSET08 – Analyse linguistique des modèles de langues

Diaporama – évaluation génération de texte, f-score

[Andrea Briglia](#)

andrea.briglia@sorbonne-nouvelle.fr

Crédits : M. Wauquier

- Générer du texte n'est pas compliqué.
- *Hello world* est l'output traditionnel des programmes simples
 - Techniquement, ces programmes génèrent du texte, à savoir la séquence "Hello world"
 - Mais ça reste le niveau 0 de la génération de texte

- Générer du texte n'est pas compliqué.
- *Hello world* est l'output traditionnel des programmes simples
 - Techniquement, ces programmes génèrent du texte, à savoir la séquence "Hello world"
 - Mais ça reste le niveau 0 de la génération de texte

- Générer du texte n'est pas compliqué.
- *Hello world* est l'output traditionnel des programmes simples
 - Techniquement, ces programmes génèrent du texte, à savoir la séquence "Hello world"
 - Mais ça reste le niveau 0 de la génération de texte

- Générer du texte n'est pas compliqué.
- *Hello world* est l'output traditionnel des programmes simples
 - Techniquement, ces programmes génèrent du texte, à savoir la séquence "Hello world"
 - Mais ça reste le niveau 0 de la génération de texte

- Générer automatiquement du contenu n'est pas difficile en soit
 - Pour rappel, Mozart proposait déjà un système pour générer aléatoirement de la musique
 - Cette approche est applicable à n'importe quel type de contenu, y compris textuel
 - Il suffit d'associer un mot à un nombre et de sélectionner aléatoirement n nombres
 - Testons

- Générer automatiquement du contenu n'est pas difficile en soit
 - Pour rappel, Mozart proposait déjà un système pour générer aléatoirement de la musique
 - Cette approche est applicable à n'importe quel type de contenu, y compris textuel
 - Il suffit d'associer un mot à un nombre et de sélectionner aléatoirement n nombres
 - Testons

- Générer automatiquement du contenu n'est pas difficile en soit
 - Pour rappel, Mozart proposait déjà un système pour générer aléatoirement de la musique
 - Cette approche est applicable à n'importe quel type de contenu, y compris textuel
 - Il suffit d'associer un mot à un nombre et de sélectionner aléatoirement n nombres
 - Testons

- Générer automatiquement du contenu n'est pas difficile en soit
 - Pour rappel, Mozart proposait déjà un système pour générer aléatoirement de la musique
 - Cette approche est applicable à n'importe quel type de contenu, y compris textuel
 - Il suffit d'associer un mot à un nombre et de sélectionner aléatoirement n nombres
- Testons

- Générer automatiquement du contenu n'est pas difficile en soit
 - Pour rappel, Mozart proposait déjà un système pour générer aléatoirement de la musique
 - Cette approche est applicable à n'importe quel type de contenu, y compris textuel
 - Il suffit d'associer un mot à un nombre et de sélectionner aléatoirement n nombres
 - Testons

- La génération aléatoire est facile, peu coûteuse, mais terriblement problématique
- Le texte généré souffre de grosses lacunes linguistiques
 - Il est nécessaire d'insuffler quelques connaissances linguistiques
- Testons de nouveau

- La génération aléatoire est facile, peu coûteuse, mais terriblement problématique
- Le texte généré souffre de grosses lacunes linguistiques
 - Il est nécessaire d'insuffler quelques connaissances linguistiques
- Testons de nouveau

- La génération aléatoire est facile, peu coûteuse, mais terriblement problématique
- Le texte généré souffre de grosses lacunes linguistiques
 - Il est nécessaire d'insuffler quelques connaissances linguistiques
- Testons de nouveau

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

Le bon et le mauvais texte généré

- Générer du texte n'est dans l'absolu pas difficile
 - On peut facilement avoir un niveau satisfaisant de résultats pour un coût limité
 - Mais la 'créativité' proposée par ces systèmes est relativement limitée
 - Le système est contraint par la taille du lexique, les règles définies, etc.
- Le véritable enjeu des systèmes de NLG est la qualité du texte généré
 - C'est d'autant plus important en fonction des applications visées
 - Pour un chatbot conversationnel, il faut que le texte soit logique et crédible
 - Pour un chatbot informationnel, il faut que l'information fournie soit claire et juste
 - etc

- Comme pour toute application ou tâche, il est primordial d'évaluer un système de NLG
 - Comprendre dans quelle mesure le système marche
 - Comprendre ce qui ne marche pas
 - Comprendre pourquoi ça ne marche pas
 - Comprendre comment améliorer le système
- Comment évaluer la qualité d'un texte généré ?

- Comme pour toute application ou tâche, il est primordial d'évaluer un système de NLG
 - Comprendre dans quelle mesure le système marche
 - Comprendre ce qui ne marche pas
 - Comprendre pourquoi ça ne marche pas
 - Comprendre comment améliorer le système
- Comment évaluer la qualité d'un texte généré ?

- Comme pour toute application ou tâche, il est primordial d'évaluer un système de NLG
 - Comprendre dans quelle mesure le système marche
 - Comprendre ce qui ne marche pas
 - Comprendre pourquoi ça ne marche pas
 - Comprendre comment améliorer le système
- Comment évaluer la qualité d'un texte généré ?

- Comme pour toute application ou tâche, il est primordial d'évaluer un système de NLG
 - Comprendre dans quelle mesure le système marche
 - Comprendre ce qui ne marche pas
 - Comprendre pourquoi ça ne marche pas
 - Comprendre comment améliorer le système
- Comment évaluer la qualité d'un texte généré ?

- Comme pour toute application ou tâche, il est primordial d'évaluer un système de NLG
 - Comprendre dans quelle mesure le système marche
 - Comprendre ce qui ne marche pas
 - Comprendre pourquoi ça ne marche pas
 - Comprendre comment améliorer le système
- Comment évaluer la qualité d'un texte généré ?

- Comme pour toute application ou tâche, il est primordial d'évaluer un système de NLG
 - Comprendre dans quelle mesure le système marche
 - Comprendre ce qui ne marche pas
 - Comprendre pourquoi ça ne marche pas
 - Comprendre comment améliorer le système
- Comment évaluer la qualité d'un texte généré ?

- Pour chaque extrait de l'annexe 3, identifiez les forces et faiblesses des textes générés

- Une efficacité redoutable

- Transformation des amorces pour garantir la grammaticalité et l'idiomaticité de la phrase

- *don't* devient *simply never*
- *I killed my boss* devient *I, too, killed my boss*

- Mise en page

- Gestion sémantique d'une locution figée métaphorique

- En surface du moins, nous n'avons pas suffisamment de contexte pour s'assurer que n'est pas le fruit du hasard

- Avec quelques limites

- L'adaptation des amorces n'est pas complètement aboutie

- Emploi surprenant du pronom personnel à la 1e personne dans *you can kill my boss* et *go kill my boss*

- Une efficacité redoutable
 - Transformation des amorces pour garantir la grammaticalité et l'idiomaticité de la phrase
 - *don't* devient *simply never*
 - *I killed my boss* devient *I, too, killed my boss*
 - Mise en page
 - Gestion sémantique d'une locution figée métaphorique
 - En surface du moins, nous n'avons pas suffisamment de contexte pour s'assurer que n'est pas le fruit du hasard
- Avec quelques limites
 - L'adaptation des amorces n'est pas complètement aboutie
 - Emploi surprenant du pronom personnel à la 1e personne dans *you can kill my boss* et *go kill my boss*

- Une efficacité redoutable
 - Transformation des amorces pour garantir la grammaticalité et l'idiomaticité de la phrase
 - *don't* devient *simply never*
 - *I killed my boss* devient *I, too, killed my boss*
 - Mise en page
 - Gestion sémantique d'une locution figée métaphorique
 - En surface du moins, nous n'avons pas suffisamment de contexte pour s'assurer que n'est pas le fruit du hasard
- Avec quelques limites
 - L'adaptation des amorces n'est pas complètement aboutie
 - Emploi surprenant du pronom personnel à la 1e personne dans *you can kill my boss* et *go kill my boss*

- Une efficacité redoutable
 - Transformation des amorces pour garantir la grammaticalité et l'idiomaticité de la phrase
 - *don't* devient *simply never*
 - *I killed my boss* devient *I, too, killed my boss*
 - Mise en page
 - Gestion sémantique d'une locution figée métaphorique
 - En surface du moins, nous n'avons pas suffisamment de contexte pour s'assurer que n'est pas le fruit du hasard
- Avec quelques limites
 - L'adaptation des amorces n'est pas complètement aboutie
 - Emploi surprenant du pronom personnel à la 1e personne dans *you can kill my boss* et *go kill my boss*

- Une efficacité redoutable
 - Transformation des amorces pour garantir la grammaticalité et l'idiomaticité de la phrase
 - *don't* devient *simply never*
 - *I killed my boss* devient *I, too, killed my boss*
 - Mise en page
 - Gestion sémantique d'une locution figée métaphorique
 - En surface du moins, nous n'avons pas suffisamment de contexte pour s'assurer que n'est pas le fruit du hasard
- Avec quelques limites
 - L'adaptation des amorces n'est pas complètement aboutie
 - Emploi surprenant du pronom personnel à la 1e personne dans *you can kill my boss* et *go kill my boss*

- Une efficacité redoutable
 - Transformation des amorces pour garantir la grammaticalité et l'idiomaticité de la phrase
 - *don't* devient *simply never*
 - *I killed my boss* devient *I, too, killed my boss*
 - Mise en page
 - Gestion sémantique d'une locution figée métaphorique
 - En surface du moins, nous n'avons pas suffisamment de contexte pour s'assurer que n'est pas le fruit du hasard
- Avec quelques limites
 - L'adaptation des amorces n'est pas complètement aboutie
 - Emploi surprenant du pronom personnel à la 1e personne dans *you can kill my boss* et *go kill my boss*

- Un extrait crédible
 - L'extrait présente un style littéraire plutôt proche de celui de J.K. Rowling
 - On retrouve la terminologie de la saga *Harry Potter* (*Death Eaters*, *Hagrid's hut*)
- Mais en surface uniquement
 - L'intégration de nouveaux personnages et/ou éléments non vus est relativement limitée
 - On retrouve beaucoup d'éléments basiques : *spider*, *Ron*, *Harry*, *Voldemort*, *Death Eaters*
 - Un nouveau personnage est proposé (*Mr. Staircase*, *a shabby-robed ghost*), mais ce n'est pas une nouvelle créature, et la création patronymique se limite à de l'antonomase inversée
 - Le texte contient de nombreux problèmes linguistiques, pragmatiques et/ou stylistiques
 - *Ron's Ron shirt was just as bad as Ron himself.*
 - *He saw Harry and immediately began to eat Hermione's family.*
 - *The password was "BEEF WOMEN," Hermione cried.*

Analyse de l'extrait 2

- Un extrait crédible
 - L'extrait présente un style littéraire plutôt proche de celui de J.K. Rowling
 - On retrouve la terminologie de la saga *Harry Potter* (*Death Eaters*, *Hagrid's hut*)
- Mais en surface uniquement
 - L'intégration de nouveaux personnages et/ou éléments non vus est relativement limitée
 - On retrouve beaucoup d'éléments basiques : *spider*, *Ron*, *Harry*, *Voldemort*, *Death Eaters*
 - Un nouveau personnage est proposé (*Mr. Staircase*, *a shabby-robed ghost*), mais ce n'est pas une nouvelle créature, et la création patronymique se limite à de l'antonomase inversée
 - Le texte contient de nombreux problèmes linguistiques, pragmatiques et/ou stylistiques
 - *Ron's Ron shirt was just as bad as Ron himself.*
 - *He saw Harry and immediately began to eat Hermione's family.*
 - *The password was "BEEF WOMEN," Hermione cried.*

Analyse de l'extrait 2

- Un extrait crédible
 - L'extrait présente un style littéraire plutôt proche de celui de J.K. Rowling
 - On retrouve la terminologie de la saga *Harry Potter* (*Death Eaters*, *Hagrid's hut*)
- Mais en surface uniquement
 - L'intégration de nouveaux personnages et/ou éléments non vus est relativement limitée
 - On retrouve beaucoup d'éléments basiques : *spider*, *Ron*, *Harry*, *Voldemort*, *Death Eaters*
 - Un nouveau personnage est proposé (*Mr. Staircase*, *a shabby-robed ghost*), mais ce n'est pas une nouvelle créature, et la création patronymique se limite à de l'antonomase inversée
 - Le texte contient de nombreux problèmes linguistiques, pragmatiques et/ou stylistiques
 - *Ron's Ron shirt was just as bad as Ron himself.*
 - *He saw Harry and immediately began to eat Hermione's family.*
 - *The password was "BEEF WOMEN," Hermione cried.*

Analyse de l'extrait 2

- Un extrait crédible
 - L'extrait présente un style littéraire plutôt proche de celui de J.K. Rowling
 - On retrouve la terminologie de la saga *Harry Potter* (*Death Eaters*, *Hagrid's hut*)
- Mais en surface uniquement
 - L'intégration de nouveaux personnages et/ou éléments non vus est relativement limitée
 - On retrouve beaucoup d'éléments basiques : *spider*, *Ron*, *Harry*, *Voldemort*, *Death Eaters*
 - Un nouveau personnage est proposé (*Mr. Staircase*, *a shabby-robed ghost*), mais ce n'est pas une nouvelle créature, et la création patronymique se limite à de l'antonomase inversée
 - Le texte contient de nombreux problèmes linguistiques, pragmatiques et/ou stylistiques
 - *Ron's Ron shirt was just as bad as Ron himself.*
 - *He saw Harry and immediately began to eat Hermione's family.*
 - *The password was "BEEF WOMEN," Hermione cried.*

Analyse de l'extrait 2

- Un extrait crédible
 - L'extrait présente un style littéraire plutôt proche de celui de J.K. Rowling
 - On retrouve la terminologie de la saga *Harry Potter* (*Death Eaters*, *Hagrid's hut*)
- Mais en surface uniquement
 - L'intégration de nouveaux personnages et/ou éléments non vus est relativement limitée
 - On retrouve beaucoup d'éléments basiques : *spider*, *Ron*, *Harry*, *Voldemort*, *Death Eaters*
 - Un nouveau personnage est proposé (*Mr. Staircase*, *a shabby-robed ghost*), mais ce n'est pas une nouvelle créature, et la création patronymique se limite à de l'antonomase inversée
 - Le texte contient de nombreux problèmes linguistiques, pragmatiques et/ou stylistiques
 - *Ron's Ron shirt was just as bad as Ron himself.*
 - *He saw Harry and immediately began to eat Hermione's family.*
 - *The password was "BEEF WOMEN," Hermione cried.*

Analyse de l'extrait 2

- Un extrait crédible
 - L'extrait présente un style littéraire plutôt proche de celui de J.K. Rowling
 - On retrouve la terminologie de la saga *Harry Potter* (*Death Eaters*, *Hagrid's hut*)
- Mais en surface uniquement
 - L'intégration de nouveaux personnages et/ou éléments non vus est relativement limitée
 - On retrouve beaucoup d'éléments basiques : *spider*, *Ron*, *Harry*, *Voldemort*, *Death Eaters*
 - Un nouveau personnage est proposé (*Mr. Staircase*, *a shabby-robed ghost*), mais ce n'est pas une nouvelle créature, et la création patronymique se limite à de l'antonomase inversée
 - Le texte contient de nombreux problèmes linguistiques, pragmatiques et/ou stylistiques
 - *Ron's Ron shirt was just as bad as Ron himself.*
 - *He saw Harry and immediately began to eat Hermione's family.*
 - *The password was "BEEF WOMEN," Hermione cried.*

- Une performance globalement correcte
 - La syntaxe est bonne
 - Le texte contient des tournures anglophones idiomatiques (*So am I, Standing behind him was a giant elephant*)
 - On observe une cohérence temporelle, avec du passé tout du long
 - Le contenu du texte est 'cohérent'
 - Positionnement et alternance des personnages
 - Mais quelques soucis demeurent, notamment pragmatiques
 - La relation entre *woman* et *elephant* de type *husband* est étrange
- L'outil offre par ailleurs la possibilité de moduler le texte
 - Longueur
 - Mots à intégrer

- Une performance globalement correcte
 - La syntaxe est bonne
 - Le texte contient des tournures anglophones idiomatiques (*So am I, Standing behind him was a giant elephant*)
 - On observe une cohérence temporelle, avec du passé tout du long
 - Le contenu du texte est 'cohérent'
 - Positionnement et alternance des personnages
 - Mais quelques soucis demeurent, notamment pragmatiques
 - La relation entre *woman* et *elephant* de type *husband* est étrange
- L'outil offre par ailleurs la possibilité de moduler le texte
 - Longueur
 - Mots à intégrer

- Une performance globalement correcte
 - La syntaxe est bonne
 - Le texte contient des tournures anglophones idiomatiques (*So am I, Standing behind him was a giant elephant*)
 - On observe une cohérence temporelle, avec du passé tout du long
 - Le contenu du texte est 'cohérent'
 - Positionnement et alternance des personnages
 - Mais quelques soucis demeurent, notamment pragmatiques
 - La relation entre *woman* et *elephant* de type *husband* est étrange
- L'outil offre par ailleurs la possibilité de moduler le texte
 - Longueur
 - Mots à intégrer

- Une performance globalement correcte
 - La syntaxe est bonne
 - Le texte contient des tournures anglophones idiomatiques (*So am I, Standing behind him was a giant elephant*)
 - On observe une cohérence temporelle, avec du passé tout du long
 - Le contenu du texte est 'cohérent'
 - Positionnement et alternance des personnages
 - Mais quelques soucis demeurent, notamment pragmatiques
 - La relation entre *woman* et *elephant* de type *husband* est étrange
- L'outil offre par ailleurs la possibilité de moduler le texte
 - Longueur
 - Mots à intégrer

- Une performance globalement correcte
 - La syntaxe est bonne
 - Le texte contient des tournures anglophones idiomatiques (*So am I, Standing behind him was a giant elephant*)
 - On observe une cohérence temporelle, avec du passé tout du long
 - Le contenu du texte est 'cohérent'
 - Positionnement et alternance des personnages
 - Mais quelques soucis demeurent, notamment pragmatiques
 - La relation entre *woman* et *elephant* de type *husband* est étrange
- L'outil offre par ailleurs la possibilité de moduler le texte
 - Longueur
 - Mots à intégrer

- Une performance bien plus nuancée
 - On observe une certaine cohérence syntaxique (1SG.M) ainsi que thématique (politique)
 - campagne électoral, chômage, mesures, élection présidentielle, tête de liste
 - On est sur un entre-deux sur le plan stylistique, entre texte littéraire et discours politique
 - *c'est l'espoir, la folie, la sérénité d'analyser la situation en quelques cieux et en quelques manières*
 - On note de nombreux problèmes de grammaticalité et/ou d'idiomaticité
 - *Le chômage à la tête!*
 - *l'espoir est généralement définitive*
 - *matinabondage*
 - *se lancer dans un grand cachet*
 - *il me semble certainement qu'une grande cause affiche autant d'insouciance*
 - *seront nécessaires et nécessaires*

- Une performance bien plus nuancée
 - On observe une certaine cohérence syntaxique (1SG.M) ainsi que thématique (politique)
 - campagne électoral, chômage, mesures, élection présidentielle, tête de liste
 - On est sur un entre-deux sur le plan stylistique, entre texte littéraire et discours politique
 - *c'est l'espoir, la folie, la sérénité d'analyser la situation en quelques cieux et en quelques manières*
 - On note de nombreux problèmes de grammaticalité et/ou d'idiomaticité
 - *Le chômage à la tête!*
 - *l'espoir est généralement définitive*
 - *matinabondage*
 - *se lancer dans un grand cachet*
 - *il me semble certainement qu'une grande cause affiche autant d'insouciance*
 - *seront nécessaires et nécessaires*

- Une performance bien plus nuancée
 - On observe une certaine cohérence syntaxique (1SG.M) ainsi que thématique (politique)
 - campagne électoral, chômage, mesures, élection présidentielle, tête de liste
 - On est sur un entre-deux sur le plan stylistique, entre texte littéraire et discours politique
 - *c'est l'espoir, la folie, la sérénité d'analyser la situation en quelques cieux et en quelques manières*
 - On note de nombreux problèmes de grammaticalité et/ou d'idiomaticité
 - *Le chômage à la tête!*
 - *l'espoir est généralement définitive*
 - *matinabondage*
 - *se lancer dans un grand cachet*
 - *il me semble certainement qu'une grande cause affiche autant d'insouciance*
 - *seront nécessaires et nécessaires*

- Une performance bien plus nuancée
 - On observe une certaine cohérence syntaxique (1SG.M) ainsi que thématique (politique)
 - campagne électoral, chômage, mesures, élection présidentielle, tête de liste
 - On est sur un entre-deux sur le plan stylistique, entre texte littéraire et discours politique
 - *c'est l'espoir, la folie, la sérénité d'analyser la situation en quelques cieux et en quelques manières*
 - On note de nombreux problèmes de grammaticalité et/ou d'idiomaticité
 - *Le chômage à la tête!*
 - *l'espoir est généralement définitive*
 - *matinabondage*
 - *se lancer dans un grand cachet*
 - *il me semble certainement qu'une grande cause affiche autant d'insouciance*
 - *seront nécessaires et nécessaires*

- Une performance bien plus nuancée
 - On observe une certaine cohérence syntaxique (1SG.M) ainsi que thématique (politique)
 - campagne électoral, chômage, mesures, élection présidentielle, tête de liste
 - On est sur un entre-deux sur le plan stylistique, entre texte littéraire et discours politique
 - *c'est l'espoir, la folie, la sérénité d'analyser la situation en quelques cieux et en quelques manières*
 - On note de nombreux problèmes de grammaticalité et/ou d'idiomaticité
 - *Le chômage à la tête!*
 - *l'espoir est généralement définitive*
 - *matinabondage*
 - *se lancer dans un grand cachet*
 - *il me semble certainement qu'une grande cause affiche autant d'insouciance*
 - *seront nécessaires et nécessaires*

- Quelles conclusions tirer de ces quelques extraits ?
 - La nature des textes sur lesquels le système est entraîné a un impact très fort
 - Thématiquement
 - Linguistiquement
 - La grammaticalité pose parfois problème
 - La créativité des systèmes (dans son sens le plus artistique) est limitée

- Quelles conclusions tirer de ces quelques extraits ?
 - La nature des textes sur lesquels le système est entraîné a un impact très fort
 - Thématiquement
 - Linguistiquement
 - La grammaticalité pose parfois problème
 - La créativité des systèmes (dans son sens le plus artistique) est limitée

- Quelles conclusions tirer de ces quelques extraits ?
 - La nature des textes sur lesquels le système est entraîné a un impact très fort
 - Thématiquement
 - Linguistiquement
 - La grammaticalité pose parfois problème
 - La créativité des systèmes (dans son sens le plus artistique) est limitée

- Quelles conclusions tirer de ces quelques extraits ?
 - La nature des textes sur lesquels le système est entraîné a un impact très fort
 - Thématiquement
 - Linguistiquement
 - La grammaticalité pose parfois problème
 - La créativité des systèmes (dans son sens le plus artistique) est limitée

- Quelles conclusions tirer de ces quelques extraits ?
 - La nature des textes sur lesquels le système est entraîné a un impact très fort
 - Thématiquement
 - Linguistiquement
 - La grammaticalité pose parfois problème
 - La créativité des systèmes (dans son sens le plus artistique) est limitée

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Parmi les principaux enjeux pour la NLG, on retrouve :
 - Les contraintes syntaxiques
 - Grammaticalité
 - Contraintes sémantiques
 - Richesse lexicale
 - Gestion de la métaphore et de l'analogie
 - Contraintes stylistiques
 - Coréférences et anaphores, cohérence discursive
- Comment évaluer la qualité d'un texte généré ?

- Le NLG est une tâche dite *open-ended*
 - Plusieurs 'réponses' (c'est-à-dire textes) sont possibles/plausibles
- Cela rend son évaluation compliquée
- La typologie des méthodes d'évaluation peut se faire
 - Sur la base de l'objet que l'on évalue
 - Sur la base des types d'approches

- Le NLG est une tâche dite *open-ended*
 - Plusieurs 'réponses' (c'est-à-dire textes) sont possibles/plausibles
- Cela rend son évaluation compliquée
- La typologie des méthodes d'évaluation peut se faire
 - Sur la base de l'objet que l'on évalue
 - Sur la base des types d'approches

- Le NLG est une tâche dite *open-ended*
 - Plusieurs 'réponses' (c'est-à-dire textes) sont possibles/plausibles
- Cela rend son évaluation compliquée
- La typologie des méthodes d'évaluation peut se faire
 - Sur la base de l'objet que l'on évalue
 - Sur la base des types d'approches

- Le NLG est une tâche dite *open-ended*
 - Plusieurs 'réponses' (c'est-à-dire textes) sont possibles/plausibles
- Cela rend son évaluation compliquée
- La typologie des méthodes d'évaluation peut se faire
 - Sur la base de l'objet que l'on évalue
 - Sur la base des types d'approches

- Le NLG est une tâche dite *open-ended*
 - Plusieurs 'réponses' (c'est-à-dire textes) sont possibles/plausibles
- Cela rend son évaluation compliquée
- La typologie des méthodes d'évaluation peut se faire
 - Sur la base de l'objet que l'on évalue
 - Sur la base des types d'approches

- Le NLG est une tâche dite *open-ended*
 - Plusieurs 'réponses' (c'est-à-dire textes) sont possibles/plausibles
- Cela rend son évaluation compliquée
- La typologie des méthodes d'évaluation peut se faire
 - Sur la base de l'objet que l'on évalue
 - Sur la base des types d'approches

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - **Intrinsèque** – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - **Extrinsèque** – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

Ce que l'on évalue

- Quand on parle de NLG, on parle à la fois d'un (sous)système et d'un résultat
- De fait, ces deux facettes mènent à deux types d'évaluation
 - Intrinsèque – évaluation de l'output du système selon des critères prédéfinis au regard de ce qui est attendu du système
 - En l'occurrence, on évalue la qualité du texte généré, dans son ensemble ou selon certains critères (cohérence, grammaticalité...)
 - Ces évaluations reposent généralement, d'une façon ou d'une autre, sur une évaluation humaine
 - Elles sont jugées plus faciles à mettre en place
 - Extrinsèque – évaluation de la performance du système ou de l'apport du module concerné dans une tâche.
 - En l'occurrence, on évalue si le texte généré de telle ou telle façon améliore les résultats du système dans une tâche (par exemple de recherche d'information ou de résumé automatique)
 - C'est l'approche la plus objective dans une approche TAL, mais elle implique l'évaluation d'un système entier
 - Ces évaluations sont donc davantage dépendantes des tâches elles-mêmes

- Indépendamment de ce que l'on évalue, plusieurs types de méthodes s'offrent à nous
 - Mesures '*human-centric*'
 - Mesures automatiques
 - Mesures automatiques par apprentissage (*machine-learned*)

- Indépendamment de ce que l'on évalue, plusieurs types de méthodes s'offrent à nous
 - Mesures '*human-centric*'
 - Mesures automatiques
 - Mesures automatiques par apprentissage (*machine-learned*)

- Indépendamment de ce que l'on évalue, plusieurs types de méthodes s'offrent à nous
 - Mesures '*human-centric*'
 - Mesures automatiques
 - Mesures automatiques par apprentissage (*machine-learned*)

- Indépendamment de ce que l'on évalue, plusieurs types de méthodes s'offrent à nous
 - Mesures '*human-centric*'
 - Mesures automatiques
 - Mesures automatiques par apprentissage (*machine-learned*)

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk (réf fin diaporama, mais aussi Prolific) et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
- L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

Évaluation humaine

- Cette évaluation constitue souvent la base de toute évaluation ultérieure
 - On parle de *gold standard*
- Cette approche est souvent préférée car elle est supposée être plus qualitative
 - On demande à des locuteurs, voire à des experts, de statuer sur certains éléments
 - C'est donc particulièrement coûteux et chronophage
 - La démocratisation des Amazon Mechanical Turk et autres systèmes de crowdsourcing rend cette solution plus accessible, mais non sans son lot de problème
 - Cette approche n'est pas sans défaut
 - Comment définir et objectiver la tâche ?
 - Comment uniformiser les évaluations ?
 - L'accord inter-annotateur permet de mesurer mais pas d'unifier l'annotation humaine
 - L'évaluation humaine couvre deux approches
 - Intrinsèque
 - Extrinsèque

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, overfitting
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- On peut vouloir évaluer la qualité globale d'un texte ou un aspect spécifique
 - *fluency*
 - grammaticalité, style, registre, ton, typicité, répétitivité
 - *adequacy* (notamment en traduction automatique)
 - *factuality* (notamment pour les résumés automatiques)
 - Ces mesures (et leur terminologie) sont assez variables, et les uniformiser n'est pas nécessairement souhaitable
 - Rigidité, *overfitting*, compromis (*trade-off*) entre précision et robustesse
- On peut procéder à une évaluation
 - Absolue - on évalue un texte seul
 - Relative - on compare deux ou plusieurs textes

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

Accords inter-annotateurs

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation (ex classification simple, *Likert scale*)
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

Accords inter-annotateurs

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

- Ces mesures visent à évaluer le degré d'accord des annotateurs
- Ces mesures peuvent varier en fonction du nombre d'annotateurs, de la nature de l'annotation
- L'interprétation de leur score (allant généralement de 0 à 1) n'est pas toujours évidente
- Parmi les plus utilisées, on trouve
 - L'accord brut
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux
 - Kappa de Cohen
 - C'est le pourcentage de cas où les annotateurs sont d'accord entre eux, au regard de l'accord attendu
 - F-score
 - Cette mesure permet d'évaluer l'accord lorsqu'il ne s'agit pas d'une tâche de catégorisation

- L'accord se calcule à l'aide d'une matrice de confusion

$$\begin{aligned}\text{Accord} &= \\ (10+40) / 80 &= \\ 50/80 &= \\ 0,63 \text{ (63\%)}\end{aligned}$$

		JUGE 1		
		oui	non	total
JUGE 2	oui	10	20	30
	non	10	40	50
	total	20	60	80

- Prenons une tâche où deux annotateurs doivent identifier des phrases agrammaticales
- L'accord se calculera selon la formule :

$$F = \frac{2 \times N_{\text{commun}}}{N_{\text{annot1}} + N_{\text{annot2}}}$$

Où N_{commun} est le nombre de phrases sélectionnées par les deux annotateurs, et N_{annot1} et N_{annot2} le nombre de phrases sélectionnées respectivement par l'annotateur 1 et l'annotateur 2 uniquement

- Si l'annotateur 1 a identifié les phrases **P1**, P3, **P5**, et l'annotateur 2 les phrases **P1**, P2, P4, **P5** et P6, on a donc la formule :

$$F = \frac{2 \times 2}{3 + 5} = 0.5$$

- Le F-score peut aussi se décrire en termes de précision (combien d'éléments sélectionnés sont pertinents ?) et de rappel (combien d'éléments pertinents sont sélectionnés ?)

- On peut évaluer la performance du système en termes de
 - Performance de l'utilisateur dans une tâche donnée
 - Dans quelle mesure l'utilisateur tire un bénéfice du système (procède-t-il à une meilleure prise de décision, fait-il moins d'erreurs, etc.)
 - Performance du système à réaliser sa tâche
 - Dans quelle mesure le système complète sa tâche (y a-t-il moins de post-editing à faire en aval, etc.)

- On peut évaluer la performance du système en termes de
 - Performance de l'utilisateur dans une tâche donnée
 - Dans quelle mesure l'utilisateur tire un bénéfice du système (procède-t-il à une meilleure prise de décision, fait-il moins d'erreurs, etc.)
 - Performance du système à réaliser sa tâche
 - Dans quelle mesure le système complète sa tâche (y a-t-il moins de post-editing à faire en aval, etc.)

- On peut évaluer la performance du système en termes de
 - Performance de l'utilisateur dans une tâche donnée
 - Dans quelle mesure l'utilisateur tire un bénéfice du système (procède-t-il à une meilleure prise de décision, fait-il moins d'erreurs, etc.)
 - Performance du système à réaliser sa tâche
 - Dans quelle mesure le système complète sa tâche (y a-t-il moins de post-editing à faire en aval, etc.)

- On peut évaluer la performance du système en termes de
 - Performance de l'utilisateur dans une tâche donnée
 - Dans quelle mesure l'utilisateur tire un bénéfice du système (procède-t-il à une meilleure prise de décision, fait-il moins d'erreurs, etc.)
 - Performance du système à réaliser sa tâche
 - Dans quelle mesure le système complète sa tâche (y a-t-il moins de post-editing à faire en aval, etc.)

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

- Celikyiklaz *et al.* (2021) proposent 5 grands groupes de mesures
 - les mesures de recouvrement des n -grammes (*n-gram overlap*)
 - Ces mesures évaluent le degré de correspondance entre des textes générés automatiquement et des textes de référence
ex. F-score (ou F1), BLEU, ROUGE...
 - les mesures de distance
 - Ces mesures évaluent la similarité entre deux unités (mots, phrases...), sur la base de la distance d'édition (le nombre de modifications à faire pour retomber sur la phrase de référence) ou à partir de la distance entre représentations vectorielles
 - les mesures de diversité
 - Ces mesures évaluent la diversité (ou la richesse) lexicale d'un texte
ex. nombre de n -gram distincts, Type-Token ratio, SELF-BLEU
 - les mesures de recouvrement de contenu (*content overlap*)
 - Ces mesures évaluent la similarité d'un texte généré à un texte de référence en extrayant les informations sémantiques explicites
 - les mesures basées sur des critères grammaticaux
 - Ces mesures évaluent la similarité syntaxique d'un texte généré et d'un texte de référence.

	Metric	Property	MT	IC	SR	SUM	DG	QG	RG
n-gram overlap	F-SCORE	precision and recall	✓	✓	✓	✓	✓	✓	✓
	BLEU	<i>n</i> -gram precision	✓	✓			✓	✓	✓
	METEOR	<i>n</i> -gram w/ synonym match	✓	✓			✓		
	CIDER	<i>tf-idf</i> weighted <i>n</i> -gram sim.		✓					
	NIST	<i>n</i> -gram precision	✓						
	GTM	<i>n</i> -gram metrics	✓						
	HLEPOR	unigrams harmonic mean	✓						
	RIBES	unigrams harmonic mean							
	MASI	attribute overlap							
	WER	% of insert,delete, replace			✓				
	TER	translation edit rate	✓						
	ROUGE	<i>n</i> -gram recall				✓	✓		
	DICE	attribute overlap							
distance-based	EDIT DIST.	cosine similarity	✓	✓	✓	✓	✓	✓	
	MEANT 2.0	vector based similarity	✓						
	YISI	weighted similarity	✓						
	WMD	EMD on words		✓		✓			
	SMD	EMD on sentences		✓	✓	✓			
	FRÉCHET	distributional similarity		✓					
content overlap	PYRAMID	content selection			✓				
	SPICE	scene graph similarity		✓					
	SPIDER	scene graph similarity		✓					
diversity	TTR	richness of vocabulary			✓				
	SELF-BLEU	<i>n</i> -gram precision						✓	

Table 1: Untrained *automatic* and *retrieval-based* metrics based on string match, string distance, or context overlap. The acronyms for some of the NLP sub-research fields that each metric is commonly used to evaluate text generation are: **MT**: Machine Translation, **IC**: Image Captioning, **SR**: Speech Recognition, **SUM**: Summarization, **DG**: Document or Story Generation, **Visual-Story Generation**, **Visual-Story Generation**, **QG**: Question Generation, **RG**: Dialog Response Generation. EMD:Earth Mover's Distance; Sim.: Similarity.

- Ces mesures permettent de mesurer l'efficacité d'un modèle à générer un texte
 - De façon rapide
 - De façon efficace
- Elles ne sont cependant pas adaptées à l'évaluation de systèmes *open-ended*
 - Le recouvrement entre un texte de référence et un texte généré est bien moins significatif lorsqu'il y a plusieurs outcomes possibles

- Ces mesures permettent de mesurer l'efficacité d'un modèle à générer un texte
 - De façon rapide
 - De façon efficace
- Elles ne sont cependant pas adaptées à l'évaluation de systèmes *open-ended*
 - Le recouvrement entre un texte de référence et un texte généré est bien moins significatif lorsqu'il y a plusieurs outcomes possibles

- Ces mesures permettent de mesurer l'efficacité d'un modèle à générer un texte
 - De façon rapide
 - De façon efficace
- Elles ne sont cependant pas adaptées à l'évaluation de systèmes *open-ended*
 - Le recouvrement entre un texte de référence et un texte généré est bien moins significatif lorsqu'il y a plusieurs outcomes possibles

- Ces mesures permettent de mesurer l'efficacité d'un modèle à générer un texte
 - De façon rapide
 - De façon efficace
- Elles ne sont cependant pas adaptées à l'évaluation de systèmes *open-ended*
 - Le recouvrement entre un texte de référence et un texte généré est bien moins significatif lorsqu'il y a plusieurs outcomes possibles

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Celikyiklaz *et al.* (2021) évoquent plusieurs approches
 - Les approches à base d'embeddings
 - On crée des représentations vectorielles du sens d'un texte généré à un texte de référence pour en comparer la similarité sémantique
 - Une branche spécifique de ces mesures repose notamment sur l'utilisation de BERT
 - Les approches à base de régression
 - On traite l'évaluation d'un texte comme une tâche de régression, c'est-à-dire comme la prédiction d'une valeur mesurant la qualité d'un texte
 - Les approches basées sur les jugements humains
 - On entraîne des modèles à imiter l'évaluation humaine

- Les méthodes peuvent être croisées
- Certaines sont développées pour des aspects en particulier (fluency, adequacy...)
- Les challenges (ou shared tasks) sont aussi des bons moyens de permettre des évaluations à grande échelle
- Les mesures et approches varient aussi en fonction des tâches ou applications

- Les méthodes peuvent être croisées
- Certaines sont développées pour des aspects en particulier (fluency, adequacy...)
- Les challenges (ou shared tasks) sont aussi des bons moyens de permettre des évaluations à grande échelle
- Les mesures et approches varient aussi en fonction des tâches ou applications

- Les méthodes peuvent être croisées
- Certaines sont développées pour des aspects en particulier (fluency, adequacy...)
- Les challenges (ou shared tasks) sont aussi des bons moyens de permettre des évaluations à grande échelle
- Les mesures et approches varient aussi en fonction des tâches ou applications

- Les méthodes peuvent être croisées
- Certaines sont développées pour des aspects en particulier (fluency, adequacy...)
- Les challenges (ou shared tasks) sont aussi des bons moyens de permettre des évaluations à grande échelle
- Les mesures et approches varient aussi en fonction des tâches ou applications

- L'évaluation vise à mesurer la qualité d'un texte
 - Pour l'améliorer et le rendre aussi '*human-like*' que possible
 - Pour identifier sa nature de texte généré
- L'évaluation seule ne peut suffire
 - La qualité des corpus est primordiale
accuracy, timeliness, completeness, cleanness, unbiasedness

- L'évaluation vise à mesurer la qualité d'un texte
 - Pour l'améliorer et le rendre aussi '*human-like*' que possible
 - Pour identifier sa nature de texte généré
- L'évaluation seule ne peut suffire
 - La qualité des corpus est primordiale
accuracy, timeliness, completeness, cleanness, unbiasedness

- L'évaluation vise à mesurer la qualité d'un texte
 - Pour l'améliorer et le rendre aussi '*human-like*' que possible
 - Pour identifier sa nature de texte généré
- L'évaluation seule ne peut suffire
 - La qualité des corpus est primordiale
accuracy, timeliness, completeness, cleanness, unbiasedness

- L'évaluation vise à mesurer la qualité d'un texte
 - Pour l'améliorer et le rendre aussi '*human-like*' que possible
 - Pour identifier sa nature de texte généré
- L'évaluation seule ne peut suffire
 - La qualité des corpus est primordiale
accuracy, timeliness, completeness, cleanness, unbiasedness

- L'évaluation vise à mesurer la qualité d'un texte
 - Pour l'améliorer et le rendre aussi '*human-like*' que possible
 - Pour identifier sa nature de texte généré
- L'évaluation seule ne peut suffire
 - La qualité des corpus est primordiale
accuracy, timeliness, completeness, cleanness, unbiasedness

- L'évaluation vise à mesurer la qualité d'un texte
 - Pour l'améliorer et le rendre aussi '*human-like*' que possible
 - Pour identifier sa nature de texte généré
- L'évaluation seule ne peut suffire
 - La qualité des corpus est primordiale
accuracy, timeliness, completeness, cleanness, unbiasedness

- Dans les articles sur lesquels vous avez travaillé,
 - Quelles évaluations sont mises en place ?
 - En cas d'évaluation humaine, le nombre d'annotateurs est-il indiqué ? La tâche précisée ? L'accord inter-annotateur donné ?
 - Quelles mesures sont utilisées ?
 - En quoi cette mesure est pertinente ? Quels éléments sont donnés pour aider à leur interprétation ?

Pour en savoir plus sur Amazon Mechanical Turk :

Karen Fort, Gilles Adda, Kevin Bretonnel Cohen. Amazon Mechanical Turk: Gold Mine or Coal Mine ?. *Computational Linguistics*, 2011, 37 (2), pp.413-420.