

LYSET08 – Analyse linguistique des modèles de langues

Diaporama 4 – Chaînes de Markov

[Andrea Briglia](#)

andrea.briglia@sorbonne-nouvelle.fr

Crédits : A. Millour, K. Fort, G. Lejeune

Plan

Rappel de la notion de probabilité

Chaînes de Markov

Génération de texte

Rappel de la notion de probabilité

Probabilité :

- Toujours positif
- Intervalle entre 0 et 1 $[0,1]$

Statistique vs probabilité (pour faire simple) :

- Une statistique vise à décrire un événement dans un vase clos.
- Une probabilité cherche à prédire un événement avec un degré de (in)certitude.
- Une probabilité peut utiliser des statistiques.

Variable Aléatoire X

Expérience aléatoire : une expérience dont le résultat dépend du hasard.

- Résultat d'un lancement de pièce de monnaie ou d'un jet de dé
- l'apparition d'un mot étant donné un contexte

Quelques règles sur les expériences aléatoires :

- la somme de toutes les probabilités de tous les résultats possibles est toujours 1
- il y a une distribution entre les résultats possibles

Lancement de dé



Chiffre obtenu entre 1 et 6

- Dé bien formé (non pipé)
- Lancement indépendant
- $P(X = 1) = P(X = 2) = [...] = P(X = 6) = 1/6$
- $P(X = 1) + P(X = 2) + [...] + P(X = 6) = 1$

$P(a|b)$

- La probabilité de "a sachant b"
- $P(X_n = \textit{pile} | X_{n-1} = \textit{face}) = ?$
- $P(X_n = \textit{pile} | X_{n-1} = \textit{face}, X_{n-2} = \textit{face}) = ?$
- $P(X_n = \textit{pile} | X_i = \textit{face}, i \in [1, n-1]) = ?$

Attention à ne pas faire l'erreur du parieur¹.

1. https://fr.wikipedia.org/wiki/Erreur_du_parieur

Plan

Rappel de la notion de probabilité

Chaînes de Markov

Génération de texte

À l'inverse des pièces, certains éléments arrivent (ou on peut en faire l'assumption) en séquence.

La probabilité d'un élément dépend des éléments qui précèdent :

- Caractères
- Mots
- Notes de musique
- etc.

Comment modéliser ces séquences ?

Chaîne de Markov, définition

Idée générale : une **chaîne de Markov**² représente l'évolution dans un temps discret (on évolue "pas à pas") d'une variable aléatoire (ici : caractères, mots, etc..), où l'état suivant se prédit uniquement sachant l'état qui le précède.

2. *An example of statistical study on the text of Eugene Onegin* illustrating the linking of events to a chain (traduit du russe), A. Markov, 1913

. source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition

Idée générale : une **chaîne de Markov**² représente l'évolution dans un temps discret (on évolue "pas à pas") d'une variable aléatoire (ici : caractères, mots, etc..), où l'état suivant se prédit uniquement sachant l'état qui le précède.

Plus précisément...

2. *An example of statistical study on the text of Eugene Onegin* illustrating the linking of events to a chain (traduit du russe), A. Markov, 1913

. source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition

Idée générale : une **chaîne de Markov**² représente l'évolution dans un temps discret (on évolue "pas à pas") d'une variable aléatoire (ici : caractères, mots, etc..), où l'état suivant se prédit uniquement sachant l'état qui le précède.

Plus précisément...

Chaîne de Markov : processus de Markov, dans notre cas à temps discret.

2. *An example of statistical study on the text of Eugene Onegin* illustrating the linking of events to a chain (traduit du russe), A. Markov, 1913

source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition

Idée générale : une **chaîne de Markov**² représente l'évolution dans un temps discret (on évolue "pas à pas") d'une variable aléatoire (ici : caractères, mots, etc..), où l'état suivant se prédit uniquement sachant l'état qui le précède.

Plus précisément...

Chaîne de Markov : processus de Markov, dans notre cas à temps discret.

Processus de Markov : processus stochastique qui vérifie la propriété de Markov.

2. *An example of statistical study on the text of Eugene Onegin* illustrating the linking of events to a chain (traduit du russe), A. Markov, 1913

. source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition

Idée générale : une **chaîne de Markov**² représente l'évolution dans un temps discret (on évolue "pas à pas") d'une variable aléatoire (ici : caractères, mots, etc..), où l'état suivant se prédit uniquement sachant l'état qui le précède.

Plus précisément...

Chaîne de Markov : processus de Markov, dans notre cas à temps discret.

Processus de Markov : processus stochastique qui vérifie la propriété de Markov.

Processus stochastique : représente l'évolution dans le temps d'une variable aléatoire.

2. *An example of statistical study on the text of Eugene Onegin* illustrating the linking of events to a chain (traduit du russe), A. Markov, 1913

source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition

Idée générale : une **chaîne de Markov**² représente l'évolution dans un temps discret (on évolue "pas à pas") d'une variable aléatoire (ici : caractères, mots, etc..), où l'état suivant se prédit uniquement sachant l'état qui le précède.

Plus précisément...

Chaîne de Markov : processus de Markov, dans notre cas à temps discret.

Processus de Markov : processus stochastique qui vérifie la propriété de Markov.

Processus stochastique : représente l'évolution dans le temps d'une variable aléatoire.

Un processus stochastique vérifie la **propriété de Markov** si la prédiction d'un état futur ne se fait que selon l'état qui le précède.

2. *An example of statistical study on the text of Eugene Onegin illustrating the linking of events to a chain* (traduit du russe), A. Markov, 1913

source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition mathématique

Une **chaîne de Markov** est un **processus de Markov**, ici à temps discret.

Chaîne de Markov, définition mathématique

Une **chaîne de Markov** est un **processus de Markov**, ici à temps discret.

Elle modélise une séquence de variables aléatoires $X_0, X_1, \dots, X_t$

Chaîne de Markov, définition mathématique

Une **chaîne de Markov** est un **processus de Markov**, ici à temps discret.

Elle modélise une séquence de variables aléatoires $X_0, X_1, \dots, X_t$

$$P(X_{t+1} = i_{t+1} | X_0 = i_0, X_1 = i_1, \dots, X_t = i_t) = P(X_{t+1} = i_{t+1} | X_t = i_t)$$

Chaîne de Markov, définition mathématique

Une **chaîne de Markov** est un **processus de Markov**, ici à temps discret.

Elle modélise une séquence de variables aléatoires $X_0, X_1, \dots, X_t$

$$P(X_{t+1} = i_{t+1} | X_0 = i_0, X_1 = i_1, \dots, X_t = i_t) = P(X_{t+1} = i_{t+1} | X_t = i_t)$$




Figure 1: source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Chaîne de Markov, définition mathématique

Une **chaîne de Markov** est un **processus de Markov**, ici à temps discret.

Elle modélise une séquence de variables aléatoires $X_0, X_1, \dots, X_t$

$$P(X_{t+1} = i_{t+1} | X_0 = i_0, X_1 = i_1, \dots, X_t = i_t) = P(X_{t+1} = i_{t+1} | X_t = i_t)$$




Figure 1: source : https://fr.wikipedia.org/wiki/Chaîne_de_Markov

Une chaîne de Markov a un **ordre**, la taille du contexte pour prédire l'état suivant.

ordre 1 : $P(X_{t+1} = i_{t+1} | X_t = i_t)$

ordre 2 : $P(X_{t+1} = i_{t+1} | X_t = i_t, X_{t-1} = i_{t-1})$

ordre n : $P(X_{t+1} = i_{t+1} | X_t = i_t, \dots, X_{t-(n-1)} = i_{t-(n-1)})$

Un modèle probabiliste modélise une loi de probabilité.

S'appuie sur des statistiques et probabilités :

- Basé sur les probabilités (ici conditionnelles)
- A quoi peut-on s'attendre dans le contexte?

Modèle probabiliste

Un modèle probabiliste modélise une loi de probabilité.

S'appuie sur des statistiques et probabilités :

- Basé sur les probabilités (ici conditionnelles)
- A quoi peut-on s'attendre dans le contexte?

Robuste, car peut toujours donner une réponse, mais superficiel :

- Pas de théorie linguistique
- S'appuie sur des séquences et pas sur une structure arborée

Application des chaînes de Markov

- Correcteur orthographique
- Reconnaissance de la parole
- Reconnaissance des écrits manuels
- Annotation des catégories des mots (parties de discours)
- Génération de texte
- Identification d'auteur
- Analyse de sentiment
- Composition musicale

lettres possibles qui suivent la lettre "p" en français :

- passion, peau, pique-nique, polaire, pu, python,
- problème, photo, plage, optique, pneu,
- pb, pc, pff, pg, pj, pk, pm, pp, pq, psss,
- ?? pg, pw, px, pz

Plan

Rappel de la notion de probabilité

Chaînes de Markov

Génération de texte

"Paris, ville ..."

- morte
- lumière
- romantique
- ordinateur ??

"Paris, ville ..."

- morte
- lumière
- romantique
- ordinateur ??

"Vous allez ..."

- manger un sandwich
- à la boulangerie
- moto ??

Un modèle de langue est un modèle mathématique (probabiliste) qui modélise la probabilité qu'un mot apparaisse étant donné un contexte.

-
3. *Language Models are Few-Shot Learners*, Tom B. Brown et al. (2020)
 4. *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, Jacob Devlin et al. (2019)

Modèle de langue

Un modèle de langue est un modèle mathématique (probabiliste) qui modélise la probabilité qu'un mot apparaisse étant donné un contexte.

Traditionnellement, on cherche à modéliser le mot suivant étant donné les mots précédents (ex : GPT-3³), même si des modèles récents peuvent utiliser des contextes étendus comme l'ensemble des mots alentours (ex : BERT⁴).

3. *Language Models are Few-Shot Learners*, Tom B. Brown et al. (2020)

4. *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, Jacob Devlin et al. (2019)

Modèle de langue

Un modèle de langue est un modèle mathématique (probabiliste) qui modélise la probabilité qu'un mot apparaisse étant donné un contexte.

Traditionnellement, on cherche à modéliser le mot suivant étant donné les mots précédents (ex : GPT-3³), même si des modèles récents peuvent utiliser des contextes étendus comme l'ensemble des mots alentours (ex : BERT⁴).

Les chaînes de Markov prennent en contexte n mots, on les appelle également des modèles de langue n -grammes.

3. *Language Models are Few-Shot Learners*, Tom B. Brown et al. (2020)

4. *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, Jacob Devlin et al. (2019)

Génération de texte 1

Imaginons que nous modélisons les mots d'une langue comme une variable aléatoire.

Nous comptons les mots dans un corpus pour créer une distribution de probabilité sur les mots.

Corpus avec 1 million de mots :

- $P(X = \text{"le"}) = 1000/1000000$
- $P(X = \text{"avec"}) = 200/1000000$
- $P(X = \text{"Alice"}) = 5/1000000$
- ...
- la somme de toutes les probabilités pour tous les mots : 1

Pourtant, ce qui nous intéresse est de trouver la probabilité d'un mot, étant donné le contexte.

- Bob aime les ...
 - "Le", "avec" et "Alice" ne sont pas de réponses pertinentes
- On veut donc trouver la distribution de probabilités étant donné le contexte

Génération de texte 3

Chercher dans les corpus toutes les occurrences de "Bob aime les"
 $P(X \mid \text{"Bob aime les"})$

- La probabilité de X conditionnée sur "Bob aime les"
- Baser la distribution de probabilités uniquement là-dessus.
- Bob aime les chiens : 2
- Bob aime les glaces : 1
- Bob aime les Schtroumpfs : 1

On aura :

- $P(X = \text{"chiens"} \mid \text{"Bob aime les"}) = 2/4$
- $P(X = \text{"glaces"} \mid \text{"Bob aime les"}) = 1/4$
- $P(X = \text{"Schtroumpfs"} \mid \text{"Bob aime les"}) = 1/4$

Proposition N-gramme

Modéliser un texte en travaillant sur des blocs de n éléments

Bob aime les...

- ordre 1 (unigramme) : $P(X \mid \text{"les"})$
- ordre 2 (bigramme) : $P(X \mid \text{"aime les"})$
- ordre 3 (trigramme) : $P(X \mid \text{"Bob aime les"})$

Proposition N-gramme

Modéliser un texte en travaillant sur des blocs de n éléments

Bob aime les...

- ordre 1 (unigramme) : $P(X \mid \text{"les"})$
- ordre 2 (bigramme) : $P(X \mid \text{"aime les"})$
- ordre 3 (trigramme) : $P(X \mid \text{"Bob aime les"})$

Ou, si représenté de manière plus rigoureuse (cf slide 10) :

- ordre 1 (unigramme) : $P(X_{t+1} \mid X_t = \text{"les"})$
- ordre 2 (bigramme) : $P(X_{t+1} \mid X_t = \text{"les"}, X_{t-1} = \text{"aime"})$
- ordre 3 (trigramme) : $P(X_{t+1} \mid X_t = \text{"les"}, X_{t-1} = \text{"aime"}, X_{t-2} = \text{"Bob"})$

- Quand on génère un texte, faudrait-il plutôt que dire :
 - "Alice n'en veut point", ou "Alice n'en veut pas" ?
On peut comparer les probabilités des n-grammes pour décider
- Quand on veut savoir quelle est la langue d'un message « Hello, les amis » nous allons regarder les modèles de langues stockées (Fr. Ang. Néerl. Chinois) pour voir dans quel modèle l'entrée obtient la plus haute probabilité.