

Construction de données, pt.2

TD2 de G.I.M. sur le codage des caractères sur 8 bits

Ilaine Wang

18 novembre 2025

Au cours précédent...

- ▶ système binaire
- ▶ système hexadécimal
- ▶ bit (*binary digit*) = unité de mesure de base de l'information
- ▶ byte = groupe de n bits
 - ◇ octet = groupe de 8 bits (*8-bit byte*)
 - ◇ octet = unité de stockage (ko, Mo, Go, To, Po etc.)
 - ◇ octet = unité de stockage du caractère
 - ◇ octet = 2 chiffres hexadécimaux (ex: 0010 1011 = ?)
 - ◇ octet = 8 positions binaires, et donc 256 valeurs
- ▶ ASCII = table 7-bits (sur 8 de l'octet)

Systèmes de numération

Binaire : système de numération

► deux symboles : $\{ 0, 1 \}$

2^8	2^7	2^6	2^5	2^4	2^3	2^2	2^1	2^0
256	128	64	32	16	8	4	2	1

Binaire : stockage (de caractères)

► deux symboles : $\{ 0, 1 \}$

position	8	7	6	5	4	3	2	1
capacité	256	128	64	32	16	8	4	2

Systèmes de numération

décimal vs. hexadécimal vs. binaire

Base 10	Base 16	Base 2
0	0	0000
1	1	0001
2	2	0010
3	3	0011
4	4	0100
5	5	0101
6	6	0110
7	7	0111
8	8	1000
9	9	1001
10	A	1010
11	B	1011
12	C	1100
13	D	1101
14	E	1110
15	F	1111

Rappel : dans les systèmes de numération, les 0 à gauche ne comptent pas.

Donc, 1 = 01 = 001 = 0001 = 00001 ...

Mais attention, quand on est dans l'octet, il s'agit de positions binaires donc 0000 0001 $\neq$ 0000 0010 ...

ASCII, American Standard Code for Information Interchange

	0	1	2	3	4	5	6	7
0	NUL	DLE	space	0	@	P	`	p
1	SOH	DC1 XON	!	1	A	Q	a	q
2	STX	DC2	"	2	B	R	b	r
3	ETX	DC3 XOFF	#	3	C	S	c	s
4	EOT	DC4	\$	4	D	T	d	t
5	ENQ	NAK	%	5	E	U	e	u
6	ACK	SYN	&	6	F	V	f	v
7	BEL	ETB	'	7	G	W	g	w
8	BS	CAN	(	8	H	X	h	x
9	HT	EM	)	9	I	Y	i	y
A	LF	SUB	*	:	J	Z	j	z
B	VT	ESC	+	;	K	[	k	{
C	FF	FS	,	<	L	\	l	
D	CR	GS	-	=	M	]	m	}
E	SO	RS	.	>	N	^	n	~
F	SI	US	/	?	O	_	o	del

Figure 1: Table ASCII

Table 7-bits

= 128 caractères (0 à 127) dont:

- ▶ caractères imprimables
 - ◇ lettres latines minuscules et majuscules
 - ◇ signes de ponctuation
 - ◇ chiffres
 - ◇ symboles mathématiques
- ▶ caractères non-imprimables = les caractères de contrôle (machines Teletype)

Le 8e bit de l'octet, ou bit de poids fort (le plus à gauche), est 0.

Limites de ASCII

- ▶ encore utilisé aujourd'hui (adresses mail) mais...
- ▶ limité à l'alphabet latin, donc exclut la majorité des langues du monde
- ▶ limité même pour l'anglais diachronique ou pour les emprunts
 - ◇ frappé, résumé, cliché, rosé, piñata, jalapeño...

Que faire ?

- ▶ remplacement de quelques caractères peu usités :
 - ◇ # (croisillon) remplacé par & pour les pays anglo-saxons,
 - ◇ \ remplacé par ¥ au Japon et ₩ en Corée
- ▶ encore trop limité et pose de nouveaux problèmes :
C:¥Users¥Dupont ou C:₩Users₩Dupont
- ▶ utilisation du 8e bit pour utiliser les numéros 128 à 255 (total de 256 caractères), avec les tables appelées "ASCII étendu" ou *extended ASCII* (sic)

Tables Microsoft Windows

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
00	<u>NUL</u> 0000	<u>STX</u> 0001	<u>SOT</u> 0002	<u>ETX</u> 0003	<u>EOT</u> 0004	<u>ENQ</u> 0005	<u>ACK</u> 0006	<u>BEL</u> 0007	<u>BS</u> 0008	<u>HT</u> 0009	<u>LF</u> 000A	<u>VT</u> 000B	<u>FF</u> 000C	<u>CR</u> 000D	<u>SO</u> 000E	<u>SI</u> 000F
10	<u>DLE</u> 0010	<u>DC1</u> 0011	<u>DC2</u> 0012	<u>DC3</u> 0013	<u>DC4</u> 0014	<u>NAK</u> 0015	<u>SYN</u> 0016	<u>ETB</u> 0017	<u>CAN</u> 0018	<u>EM</u> 0019	<u>SUB</u> 001A	<u>ESC</u> 001B	<u>FS</u> 001C	<u>GS</u> 001D	<u>RS</u> 001E	<u>US</u> 001F
20	<u>SP</u> 0020	!	"	#	\$	%	&	'	(	)	*	+	,	-	.	/
30	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
40	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
50	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
60	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
70	p	q	r	s	t	u	v	w	x	y	z	{		}	~	<u>DEL</u> 007F
80	€ 20AC		ƒ 201A		„ 201E	… 2026	† 2020	‡ 2021		‰ 2030	Š 0160	< 2039	Ś 015A	Ť 0164	Ž 017D	Ž 0179
90		\	/	“	”	•	—	—		™ 2122	Š 0161	> 203A	Ś 015B	Ť 0165	Ž 017E	Ž 017A
A0	<u>NBSP</u> 00A0	ˆ 02C7	˜ 02D8	Ł 0141	⌘ 00A4	Ą 0104	İ 00A6	Š 00A7	ˆ 00A8	© 00A9	§ 015E	« 00AB	¬ 00AC	— 00AD	® 00AE	Ž 017B
B0	° 00B0	± 00B1	ˆ 02DB	ł 0142	/	μ 00B5	¶ 00B6	· 00B7	ˆ 00B8	ą 0105	§ 015F	» 00BB	Ł 013D	ˆ 02DD	İ 013E	Ž 017C
C0	Ř 0154	Á 00C1	Ě 00C2	Ǻ 0102	Ǻ 00C4	Í 0139	Ć 0106	Ç 00C7	Č 010C	É 00C9	Ě 0118	« 00CB	Ě 011A	Í 00CD	İ 00CE	Ǻ 010E
D0	Đ 0110	Ň 0143	Ň 0147	Ó 00D3	Ō 00D4	Ō 0150	Ö 00D6	× 00D7	Ř 0158	Ů 016E	Ú 00DA	Ů 0170	Ů 00DC	Ý 00DD	Ť 0162	ß 00DF
E0	ř 0155	á 00E1	ě 00E2	ǻ 0103	ǻ 00E4	í 013A	ć 0107	ç 00E7	č 010D	é 00E9	ě 0119	« 00EB	ě 011B	í 00ED	ı 00EE	ǻ 010F
F0	đ 0111	ň 0144	ň 0148	ó 00F3	ō 00F4	ō 0151	ö 00F6	÷ 00F7	ř 0159	ů 016F	ú 00FA	ú 0171	ú 00FC	ý 00FD	ţ 0163	· 02D9

Figure 2: Win-1250 (Latin 2) : Central Europe

Tables Microsoft Windows

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80	€ 20AC		ƒ 201A		„ 201E	… 2026	† 2020	‡ 2021		‰ 2030	Š 0160	< 2039	Ś 015A	Ť 0164	Ž 017D	Ž 0179
90		ˆ 2018	˜ 2019	˝ 201C	“ 201D	• 2022	— 2013	— 2014		™ 2122	Š 0161	> 203A	Ś 015B	ť 0165	ž 017E	ž 017A
A0	NBSP 00A0	˘ 02C7	˙ 02D8	Ł 0141	• 00A4	Ą 0104	ı 00A6	Ś 00A7	ˆ 00A8	@ 00A9	Œ 015E	« 00AB	¬ 00AC	— 00AD	® 00AE	Ž 017E
B0	° 00E0	± 00B1	ˆ 02DB	ł 0142	˘ 00B4	μ 00B5	¶ 00B6	• 00B7	ˆ 00B8	ą 0105	Œ 015F	» 00BB	Ł 013D	ˆ 02DD	ı 013E	Ž 017C
C0	Ř 0154	Á 00C1	Ě 00C2	Ǽ 0102	Ǽ 00C4	Í 0139	Ć 0106	Ç 00C7	Č 010C	É 00C9	Ě 0118	Ê 00CB	Ë 011A	Í 00CD	Î 00CE	Ǽ 010E
D0	Ð 0110	Ñ 0143	Ň 0147	Ó 00D3	Õ 00D4	Ö 0150	Ö 00D6	× 00D7	Ř 0158	Ů 016E	Ú 00DA	Û 0170	Ü 00DC	Ý 00DD	Ť 0162	ß 00DF
E0	ř 0155	á 00E1	ě 00E2	ǽ 0103	ǽ 00E4	í 013A	ć 0107	ç 00E7	č 010D	é 00E9	ę 0119	ê 00EB	ë 011B	í 00ED	î 00EE	ǽ 010F
F0	ď 0111	ń 0144	ň 0148	ó 00F3	õ 00F4	ö 0151	ö 00F6	÷ 00F7	ř 0159	ů 016F	ú 00FA	û 0171	ü 00FC	ý 00FD	ţ 0163	• 02D9

Figure 3: Win-1250 (Latin 2) : Central Europe

Tables Microsoft Windows

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80	€ 20AC		ı 201A	ƒ 0192	“ 201E	… 2026	† 2020	‡ 2021	˜ 02C6	% 2030	Š 0160	< 2039	Œ 0152		Ž 017D	
90		˘ 2018	ı 2019	“ 201C	” 201D	• 2022	— 2013	— 2014	˜ 02DC	™ 2122	Š 0161	> 203A	œ 0153		ž 017E	Ÿ 0178
A0	<u> </u> 00A0	ı 00A1	¢ 00A2	£ 00A3	¤ 00A4	¥ 00A5	¦ 00A6	§ 00A7	¨ 00A8	© 00A9	ª 00AA	« 00AB	¬ 00AC	­ 00AD	® 00AE	¯ 00AF
B0	° 00E0	± 00B1	² 00B2	³ 00B3	´ 00B4	µ 00B5	¶ 00B6	· 00B7	¸ 00B8	¹ 00B9	º 00BA	» 00BB	¼ 00BC	½ 00BD	¾ 00BE	¿ 00BF
C0	À 00C0	Á 00C1	Â 00C2	Ã 00C3	Ä 00C4	Å 00C5	Æ 00C6	Ç 00C7	È 00C8	É 00C9	Ê 00CA	Ë 00CB	Ì 00CC	Í 00CD	Î 00CE	Ï 00CF
D0	Ð 00D0	Ñ 00D1	Ò 00D2	Ó 00D3	Ô 00D4	Õ 00D5	Ö 00D6	× 00D7	Ø 00D8	Ù 00D9	Ú 00DA	Û 00DB	Ü 00DC	Ý 00DD	Þ 00DE	ß 00DF
E0	à 00E0	á 00E1	â 00E2	ã 00E3	ä 00E4	å 00E5	æ 00E6	ç 00E7	è 00E8	é 00E9	ê 00EA	ë 00EB	ì 00EC	í 00ED	î 00EE	ï 00EF
F0	ö 00F0	ñ 00F1	ò 00F2	ó 00F3	ô 00F4	õ 00F5	ö 00F6	÷ 00F7	ø 00F8	ù 00F9	ú 00FA	û 00FB	ü 00FC	ý 00FD	þ 00FE	ÿ 00FF

Figure 4: Win-1252 (Latin 1) : Western Europe

Table Apple

MacRoman																
	x0	x1	x2	x3	x4	x5	x6	x7	x8	x9	xA	xB	xC	xD	xE	xF
0x										TAB	LF			CR		
1x																
2x	SP	!	"	#	\$	%	&	'	(	)	*	+	,	-	.	/
3x	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4x	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5x	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6x	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7x	p	q	r	s	t	u	v	w	x	y	z	{		}	~	
8x	Ä	Å	Ç	É	Ñ	Ö	Ü	á	à	â	ä	ã	å	ç	é	è
9x	ê	ë	í	ì	î	ï	ñ	ó	ò	ô	ö	õ	ú	ù	û	ü
Ax	†	°	¢	£	§	•	¶	ß	®	©	™	'	™	≠	Æ	Ø
Bx	∞	±	≤	≥	¥	μ	∂	Σ	Π	π	∫	∂	∂	Ω	æ	ø
Cx	¿	¡	¬	√	ƒ	≈	Δ	«	»	...	Nbsp	À	Ã	Õ	Œ	œ
Dx	-	—	"	"	'	'	÷	◇	ÿ	ÿ	/	€	<	>	fi	fl
Ex	‡	·	,	„	‰	Â	Ê	Á	Ë	È	Í	Î	Ï	Ì	Ó	Ô
Fx	⌘	Ò	Ú	Û	Ü	ı	ˆ	˜	-	˘	·	°	˙	˚	˛	˜

Figure 5: MacRoman (utilisé comme codage par défaut jusqu'à MacOS 9, donc avant 2001)

Tables ISO-8859-*n*

Famille de 16 tables / jeux de caractères non-propriétaires

ISO = International Organization for Standardization

- ▶ 8859-1, ISO Latin-1 Europe occidentale, Amérique Latine
- ▶ 8859-2, ISO Latin-2 Europe centrale
- ▶ 8859-3, ISO Latin-3 Autres langues utilisant l'alphabet latin
- ▶ 8859-4, ISO Latin-4 Europe du Nord*
- ▶ 8859-5 Latin/cyrillique
- ▶ 8859-6 Latin/arabe
- ▶ 8859-7 Latin/grec
- ▶ 8859-8 Latin/hébreu

*estonien, letton, lituanien, groenlandais, sami.

Famille de 16 tables / jeux de caractères non-propriétaires

- ▶ 8859-9, ISO Latin-5 Variante latin pour le turc
- ▶ 8859-10, ISO Latin-6 Sami/nordique/eskimo
- ▶ 8859-11 Latin/thaï [proposition, non IANA]
- ▶ 8859-12 Latin/devanagari [abandonné]
- ▶ 8859-13, ISO Latin-7 Côte baltique
- ▶ 8859-14, ISO Latin-8 Celtique
- ▶ 8859-15, ISO Latin-9 Euro
- ▶ 8859-16, ISO Latin-10 Pour un ensemble de langues*

*albanais, croate, anglais, allemand, français, finnois, hongrois, gaélique (nouvelle orthographe), italien, latin, polonais, roumain, slovène.

Tables ISO-8859-*n*

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80																
90																
A0	<u> </u> NBSP 00A0	ı 00A1	ç 00A2	£ 00A3	® 00A4	¥ 00A5	 00A6	§ 00A7	¨ 00A8	© 00A9	ª 00AA	« 00AB	¬ 00AC	– 00AD	® 00AE	— 00AF
B0	° 00B0	± 00B1	² 00B2	³ 00B3	´ 00B4	µ 00B5	¶ 00B6	· 00B7	¸ 00B8	¹ 00B9	º 00BA	» 00BB	¼ 00BC	½ 00BD	¾ 00BE	¿ 00BF
C0	À 00C0	Á 00C1	Â 00C2	Ã 00C3	Ä 00C4	Å 00C5	Æ 00C6	Ç 00C7	È 00C8	É 00C9	Ê 00CA	Ë 00CB	Ì 00CC	Í 00CD	Î 00CE	Ï 00CF
D0	Ð 00D0	Ñ 00D1	Ò 00D2	Ó 00D3	Ô 00D4	Õ 00D5	Ö 00D6	× 00D7	Ø 00D8	Ù 00D9	Ú 00DA	Û 00DB	Ü 00DC	Ý 00DD	Þ 00DE	ß 00DF
E0	à 00E0	á 00E1	â 00E2	ã 00E3	ä 00E4	å 00E5	æ 00E6	ç 00E7	è 00E8	é 00E9	ê 00EA	ë 00EB	ì 00EC	í 00ED	î 00EE	ï 00EF
F0	ö 00F0	ñ 00F1	ò 00F2	ó 00F3	ô 00F4	õ 00F5	ö 00F6	÷ 00F7	ø 00F8	ù 00F9	ú 00FA	û 00FB	ü 00FC	ý 00FD	þ 00FE	ÿ 00FF

Figure 6: ISO-8859-1 (Western Europe)

Tables ISO-8859-*n*

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80																
90																
A0	<u> </u> NBSP 00A0	Ё 0401	Ђ 0402	Ѓ 0403	Є 0404	Ѕ 0405	І 0406	Ї 0407	Ј 0408	Љ 0409	Њ 040A	Ћ 040B	Ќ 040C	– 00AD	Ў 040E	Џ 040F
B0	А 0410	Б 0411	В 0412	Г 0413	Д 0414	Е 0415	Ж 0416	З 0417	И 0418	Й 0419	К 041A	Л 041B	М 041C	Н 041D	О 041E	П 041F
C0	Р 0420	С 0421	Т 0422	У 0423	Ф 0424	Х 0425	Ц 0426	Ч 0427	Ш 0428	Щ 0429	Ъ 042A	Ы 042B	Ь 042C	Э 042D	Ю 042E	Я 042F
D0	а 0430	б 0431	в 0432	г 0433	д 0434	е 0435	ж 0436	з 0437	и 0438	й 0439	к 043A	л 043B	м 043C	н 043D	о 043E	п 043F
E0	р 0440	с 0441	т 0442	у 0443	ф 0444	х 0445	ц 0446	ч 0447	ш 0448	щ 0449	ъ 044A	ы 044B	ь 044C	э 044D	ю 044E	я 044F
F0	№ 2116	ё 0451	ђ 0452	ѓ 0453	є 0454	ѕ 0455	і 0456	ї 0457	ј 0458	љ 0459	њ 045A	ќ 045B	ќ 045C	Ѕ 00A7	ў 045E	џ 045F

Figure 7: ISO-8859-5 (Cyrillic)

Tables ISO-8859-*n*

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80																
90																
A0	<u>NBSP</u> 00A0				⌘ 00A4								‘ 060C	— 00AD		
B0												؛ 061B				؟ 061F
C0		ء 0621	آ 0622	أ 0623	ؤ 0624	إ 0625	ئ 0626	ا 0627	ب 0628	ة 0629	ت 062A	ث 062B	ج 062C	ح 062D	خ 062E	د 062F
D0	ذ 0630	ر 0631	ز 0632	س 0633	ش 0634	ص 0635	ض 0636	ط 0637	ظ 0638	ع 0639	غ 063A					
E0	— 0640	ف 0641	ق 0642	ك 0643	ل 0644	م 0645	ن 0646	ه 0647	و 0648	ي 0649	ي 064A	ء 064B	آ 064C	أ 064D	ؤ 064E	إ 064F
F0	ـ 0650	ـ 0651	ـ 0652													

Figure 8: ISO-8859-6 (Arabic)

Tables ISO-8859-*n*

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80																
90																
A0	<u> </u> 00A0	' 02BD	' 02BC	£ 00A3			 00A6	§ 00A7	¨ 00A8	@ 00A9		« 00AB	¬ 00AC	— 00AD		— 2015
B0	° 00B0	± 00B1	² 00B2	³ 00B3	´ 0384	µ 0385	¶ 0386	· 00B7	¸ 0388	¹ 0389	º 038A	» 00BB	¼ 038C	½ 00BD	¾ 038E	Ω 038F
C0	í 0390	À 0391	Á 0392	Â 0393	Ã 0394	Ä 0395	Å 0396	Æ 0397	Ç 0398	È 0399	É 039A	Ê 039B	Ë 039C	Ì 039D	Í 039E	Î 039F
D0	Π 03A0	Ρ 03A1		Σ 03A3	Τ 03A4	Υ 03A5	Φ 03A6	Χ 03A7	Ψ 03A8	Ω 03A9	Ϊ 03AA	Ϋ 03AB	ά 03AC	έ 03AD	ή 03AE	ί 03AF
E0	Ů 03B0	α 03B1	β 03B2	γ 03B3	δ 03B4	ε 03B5	ζ 03B6	η 03B7	θ 03B8	ι 03B9	κ 03BA	λ 03BB	μ 03BC	ν 03BD	ξ 03BE	ο 03BF
F0	π 03C0	ρ 03C1	ς 03C2	σ 03C3	τ 03C4	υ 03C5	φ 03C6	χ 03C7	ψ 03C8	ω 03C9	ϊ 03CA	ϋ 03CB	ό 03CC	ύ 03CD	ώ 03CE	

Figure 9: ISO-8859-7 (Greek)

Tables ISO-8859-*n*

	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
80																
90																
A0	<u> </u> 00A0	ı 00A1	ç 00A2	£ 00A3	® 00A4	¥ 00A5	 00A6	§ 00A7	¨ 00A8	© 00A9	ª 00AA	« 00AB	¬ 00AC	— 00AD	® 00AE	— 00AF
B0	° 00B0	± 00B1	² 00B2	³ 00B3	´ 00B4	µ 00B5	¶ 00B6	· 00B7	¸ 00B8	¹ 00B9	º 00BA	» 00BB	¼ 00BC	½ 00BD	¾ 00BE	¿ 00BF
C0	À 00C0	Á 00C1	Â 00C2	Ã 00C3	Ä 00C4	Å 00C5	Æ 00C6	Ç 00C7	È 00C8	É 00C9	Ê 00CA	Ë 00CB	Ì 00CC	Í 00CD	Î 00CE	Ï 00CF
D0	Ğ 011E	Ñ 00D1	Ò 00D2	Ó 00D3	Ô 00D4	Õ 00D5	Ö 00D6	× 00D7	Ø 00D8	Ù 00D9	Ú 00DA	Û 00DB	Ü 00DC	İ 0130	Ş 015E	ß 00DF
E0	à 00E0	á 00E1	â 00E2	ã 00E3	ä 00E4	å 00E5	æ 00E6	ç 00E7	è 00E8	é 00E9	ê 00EA	ë 00EB	ì 00EC	í 00ED	î 00EE	ï 00EF
F0	ğ 011F	ñ 00F1	ò 00F2	ó 00F3	ô 00F4	õ 00F5	ö 00F6	÷ 00F7	ø 00F8	ù 00F9	ú 00FA	û 00FB	ü 00FC	ı 0131	ş 015F	ÿ 00FF

Figure 10: ISO-8859-9 (Turkish)

Tables ISO-8859-*n*

Latin-9 quasiment identique à Latin-1, mais nécessité de créer une nouvelle convention pour...

- ▶ le symbole monétaire de l'euro (€), avec son arrivée imminente à l'époque
- ▶ Š , š , Ž et ž pour la translittération des noms russes en finnois et en estonien
- ▶ les digrammes soudés Œ et œ du français
- ▶ le Ÿ (majuscule) pour certains noms propres (dont L'Haÿ-les-Roses et Pierre Louÿs)

Différences ISO 8859-15 — ISO 8859-1

Position	0xA4	0xA6	0xA8	0xB4	0xB8	0xBC	0xBD	0xBE
8859-1	¤	ı	¨	'	,	¼	½	¾
8859-15	€	Š	š	Ž	ž	Œ	œ	Ÿ

Figure 11: ISO-8859-15 (Latin 9, “euro”)

Et pour les autres langues...

Autres conventions d'encodage

- ▶ BrasCII : Brazilian Standard Code for Information Interchange
- ▶ ISCII : Indian Standard Code for Information Interchange
- ▶ PASCII : Perso-Arabic Script Code for Information Interchange (kashmiri, persan, sindhi, ourdou)
- ▶ VISCII : Vietnamese Standard Code for Information Interchange
- ▶ ...

CJK : utilisation de 2 octets

- ▶ ISO-2022-CN, GB/Big5, EUC-CN/EUC-TW...
- ▶ ISO-2022-JP (JIS), Shift-JIS, EUC-JP...
- ▶ ISO-2022-KR, EUC-KR/EUC-KP...

Tables 8 bits : en résumé

- ▶ principe comme pour le 7 bit, 1 octet = 1 caractère
- ▶ de 00 à 7F : ASCII
- ▶ de 80 à 9F : pas utilisé dans le standard ISO
- ▶ pas de jeu parfait, donc selon les besoins ponctuels
- ▶ autrefois les plus importants de manière globale (web) :
 - ◇ ISO-8859-1
 - ◇ Windows 1252
 - ◇ dans une moindre mesure, MacRoman

Ambiguïtés

Des différences d'encodage possibles au moment de :

- ▶ la saisie : pas mécanique !
- ▶ la sauvegarde (écriture dans un fichier)
- ▶ l'affichage (interprétation, ou lecture d'un fichier)

Saisie

- ▶ quels points de code pour `é` selon ISO-8859-1, MacRoman et Windows 1252 ?
- ▶ et pour le `€` ?

Affichage

- ▶ comment interpréter le point de code `84` si je suis en ISO-8859-6, MacRoman ou Windows 1250 ?

Évolution

► dans le temps

- ◇ DOS devenu Windows : par exemple, DOS CP851 pour le grec, où CP ici signifie *codepage*
- ◇ les différentes tables ISO (première version de Latin-1 en 1986, de Latin-9 en 1998)...

► dans l'espace

- ◇ US-ASCII vs. Europe
- ◇ les différents ISO à l'intérieur même de l'Europe
- ◇ Afrique, Moyen-Orient, Asie, Océanie...

► suivant les constructeurs : Microsoft, Apple, Linux...

Origines des problèmes d'encodage

- ▶ la différence entre la table d'encodage et celle de décodage
- ▶ les problèmes de normalisation
- ▶ le double encodage (encodages successifs)
- ▶ un défaut au niveau des octets (octet manquant, tronqué...)
- ▶ les glyphes manquants

Identification des jeux de caractères

Logiciels

- ▶ les éditeurs de texte
- ▶ les éditeurs hexadécimaux

Lignes de commande

- ▶ commande `file`
- ▶ commande `chardet` qui donne un résultat et un % de confiance
- ▶ commande `uchardet`

Pour installer les deux dernières commandes :

```
sudo apt install python-chardet
sudo apt install uchardet
```

Attention, rien n'est fiable à 100% !
(sauf vous à la fin de l'année bien sûr)

Manipulation des jeux de caractères

Conversion

- ▶ au moment d'écrire (*Sauvegarder sous*)
- ▶ dans Notepad++, avec `Convert to` (et non `Encoding` qui ne gère que le *décodage*)
- ▶ commande `iconv`

◇ syntaxe de base :

```
iconv -f [ENCODAGE_SOURCE] -t [ENCODAGE_CIBLE]  
/chemin/vers/fichier_source.txt
```

- ◇ si on veut non pas seulement afficher le résultat de la conversion dans le terminal mais aussi le sauvegarder dans un fichier, on ajoute à la fin de la commande :

```
> /chemin/vers/fichiers_cible.txt
```

- ◇ option utile pour afficher les encodages que la commande supporte (à noter que MACROMAN devient ici MACINTOSH)

```
iconv -l
```