

TD3

Unicode

Exercice 1

Soit l'information binaire suivante :

```
01010000 01101001 01100101 01110010 01101111 01100111 01101001 00100000 11100010
10000000 10010011 00100000 01101111 01100111 11000011 10110011 01101100 01101110
01101001 01100101 00111010 00100000 01101011 01100001 01110111 01100001 11000101
10000010 01101011 01101001 00100000 01100011 01101001 01100101 01101110 01101011
01101001 01100101 01100111 01101111 00101100 00100000 01100101 01101100 01100001
01110011 01110100 01111001 01100011 01111010 01101110 01100101 01100111 01101111
00100000 01101001 00100000 01100100 01101111 01100010 01110010 01111010 01100101
00100000 01111010 01101100 01100101 01110000 01101001 01100001 01101010 11000100
10000101 01100011 01100101 01100111 01101111 00100000 01110011 01101001 11000100
10011001 00100000 01100011 01101001 01100001 01110011 01110100 01100001 00100000
01101110 01100001 01110000 01100101 11000101 10000010 01101110 01101001 01101111
01101110 01100101 00100000 01101110 01100001 01101010 01110010 01101111 01111010
01101101 01100001 01101001 01110100 01110011 01111010 01111001 01101101 01101001
00100000 01100110 01100001 01110010 01110011 01111010 01100001 01101101 01101001
00101110
```

- Combien y a-t-il d'octets ?
- Combien comptez-vous de caractères si vous savez que cette information correspond à un fichier encodé...
 - en 8 bits ?
 - en UTF-8 ?

Justifiez !

- Relever les octets (en binaire) des caractères encodés sur plusieurs octets, puis donner la représentation de ces octets en hexadécimal.
- Retrouver les caractères correspondants ainsi que leur code Unicode sur un des sites donnés en cours.

Exercice 2

Voici les numéros de trois caractères tirés du catalogue Unicode :

- U+C0B6
- U+0E15
- U+1D199

- a) A partir des sites donnés en cours, trouver le codage UTF-8 de ces caractères en binaire et en hexadécimal.
- b) Observer le premier chiffre hexadécimal de l'octet initial de chaque caractère. Que pouvez-vous en dire ?
- c) *Question bonus*: retrouver les caractères correspondants sur un des sites donnés en cours.

Exercice 3

Soit la suite d'octets suivante vue dans un éditeur hexadécimal et représentant un texte enregistré dans un fichier texte :

0000:0000	4C 65 20 70	61 72 63 20	6E 61 74 69	6F 6E 61 6C	Le parc national
0000:0010	20 64 65 20	53 C3 B6 64	65 72 C3 A5	73 65 6E 20	de Söderösen
0000:0020	65 73 74 20	75 6E 20 70	61 72 63 20	6E 61 74 69	est un parc nati
0000:0030	6F 6E 61 6C	20 73 69 74	75 C3 A9 20	65 6E 20 53	onal situöö en S
0000:0040	63 61 6E 69	65 2C 20 61	75 20 73 75	64 20 64 65	canie, au sud de
0000:0050	20 6C 61 20	53 75 C3 A8	64 65 2E 20	49 6C 20 65	la Suööde. Il e
0000:0060	73 74 20 64	C3 A9 63 6F	75 70 C3 A9	20 70 61 72	st döökouöö par
0000:0070	20 64 65 20	70 72 6F 66	6F 6E 64 65	73 20 76 61	de profondes va
0000:0080	6C 6C C3 A9	65 73 2C 20	64 6F 6E 74	20 65 6E 20	llöös, dont en
0000:0090	70 61 72 74	69 63 75 6C	69 65 72 20	63 65 6C 6C	particulier cell
0000:00A0	65 20 64 65	20 53 6B C3	A4 72 61 6C	69 64 2E 0A	e de Skööralid..

- a) S'agit-il d'un codage 7 bits, 8 bits ou d'UTF-8 ? Justifier.
- b) Donner le code Unicode des caractères en rouge dans la capture.
- c) Retrouver les caractères correspondants sur un des sites donnés en cours.
- d) *Question bonus*: ce fichier pourrait-il être converti en Windows-1250, Windows-1252, MacRoman, ISO-8859-1 ou ISO-8859-9 ?

Justifier en constituant un tableau exhaustif avec, si possible, le point de code de chacun des caractères dans chacun des encodages.

Exercice 4

Ouvrir le fichier `teochew.txt` avec votre éditeur de texte.

1. Sans même regarder ce qu'indique l'éditeur ni utiliser un éditeur hexadécimal, nous savons qu'il s'agit d'un fichier encodé en UTF-8. Pourquoi ?
2. Mon éditeur de texte, TextEdit, indique que ce fichier contient 212 caractères (en incluant les espaces) encodés sur 224 octets. D'après ces informations, pouvez-vous **déduire** sur combien d'octets sont encodés chacun des caractères ? Justifier.
3. Afin d'observer les encodages UTF-16 et UTF-32, convertir le fichier avec les commandes suivantes :

```
iconv -f UTF-8 -t UTF-16LE teochew.txt > teochew_UTF16LE.txt  
iconv -f UTF-8 -t UTF-32LE teochew.txt > teochew_UTF32LE.txt
```

- a) Ouvrir ces nouveaux fichiers avec un éditeur hexadécimal. Expliquer en quoi le résultat obtenu n'est pas celui que l'on attendait.

- b) Faire maintenant les conversions suivantes :

```
iconv -f UTF-8 -t UTF-16 teochew.txt > teochew_UTF16.txt  
iconv -f UTF-8 -t UTF-32 teochew.txt > teochew_UTF32.txt
```

Qu'observez-vous ?

- c) A partir des fichiers obtenus en (3b), utiliser `iconv` pour convertir vers l'autre boutisme.
4. Trouver le code Unicode du caractère « œ » sur un des sites Unicode.
 5. Comparer le code Unicode obtenu à la question (4) avec l'encodage de ce caractère en UTF16BE et en UTF32LE. Que pouvez-vous dire ?