

Corpus arborés et parsing

Cours 5

Ioana-Madalina Silai
imsilai@parisnanterre.fr

Grew-match : outil de requêtage et d'exploration

<https://universal.grew.fr/>



Grew-match was developed by Bruno Guillaume in the Sémagramme team at LORIA / Inria Nancy Grand-Est.

- outil permettant de formuler des requêtes dans de nombreux corpus
- interface web
- requêtes formulées suivant une syntaxe particulière :
 - expressions sur les noeuds (= mots/tokens)
 - expressions sur les arêtes (= dépendances)
 - contraintes supplémentaires

Expressions concernant les noeuds

- Chaque noeud (=mot) que l'on souhaite repérer doit avoir un identifieur
- L'identifieur est accompagné par des contraintes sur la nature du noeud

{ pattern X [upos=VERB] }


Expressions concernant les arêtes

- Elles expriment l'existence d'une arête (= dépendance) entre deux noeuds (= mots)
- Optionnellement, elles expriment aussi des contraintes concernant l'arête

{ pattern X -> Y }

{ pattern X -[det]-> Y }

Grew-match : requêtes de base




```
pattern { X [form="attend"] }  
pattern { X [upos=VERB] }  
pattern { X [lemma="attendre"] }  
pattern { X [Tense=Pres] }  
pattern { X -[subj]->Y }
```

Plusieurs contraintes dans la même requête

```

pattern {
  V - [subj] -> S;
  V - [comp:obj] -> 0;
  S [upos=PROPN, Number=Sing]
}

```



A vous : testez et observez

pattern { V -[subj]-> S }

pattern { V [form="pensais"] }

pattern { V [lemma="penser"] }

pattern { V [lemma <> "penser"] }

pattern { V [upos=VERB] }

pattern { V [Tense=Past] }

pattern { V [upos=VERB | AUX] }

pattern { V [upos=VERB, lemma="penser"]; V -[subj]-> S; V -[comp:obj]-> O }

Corpus à utiliser :
SUD_French_GSD

D'autres contraintes

$N1 < N2$

Le mot N1 est immédiatement avant N2

$N1 << N2$

Le mot N1 est avant N2

$N1.feature = N2.feature$

La valeur du trait donné est la même pour N1 et N2

$N1.feature <> N2.feature$

La valeur du trait donné diffère entre N1 et N2

$N1[!Mood]$

Négation : le trait Mood n'est pas présent sur N1


$without \{ N1[upos=NOUN] \}$

Exclusion d'un patron plus général

Surface Syntactic Universal Dependencies



Relations définies sur des **bases distributionnelles et fonctionnelles**



Surface Syntactic Universal Dependencies



- Les éléments de la même **classe distributionnelle** portent la **même relation syntaxique**
- La **racine** est la forme portant la **force illocutoire** : typiquement, celle qui porte les **marques de TAM** et **s'accorde avec le sujet**
- On fait la **distinction entre les compléments** (obligatoires) **et les modifieurs** (optionnels)
- Les relations sont **hiérarchisées**

Surface Syntactic Universal Dependencies



- **root** : racine (en français, la forme verbale finie, sinon la tête de l'unité analysée)

Jean arrive

Jean est arrivé

Jean est étudiant

- **subj** : *subject* (tout sujet)

Jean est arrivé

Fumer est dangereux

Qui ne fait pas plaisir en arrivant fait plaisir en partant

*Pierre est-il arrivé ? <= **subj@expl***

Surface Syntactic Universal Dependencies



- **udep** : *underspecified dependency* (si on ne peut pas faire la distinction modifieur et complément)
- **mod** : *modifier* (tout type de modifieur, indépendamment de son gouverneur et de sa nature)

La maison rouge de ma mère / que ma mère a achetée

Hier, Jean a pris le train même s'il y avait la grève

Surface Syntactic Universal Dependencies



- **comp** : *complement* (complément)

- comp:aux
- comp:pred
- comp:obl
- comp:obj

- **comp:aux**

- **comp:aux@tense**
Jean est arrivé
- **comp:aux@pass**
La maison a été vendue
- **comp:aux@caus**
Elle le fait vendre la maison

Surface Syntactic Universal Dependencies



- **comp:aux**

- **comp:aux@tense**


Jean est arrivé

- **comp:aux@pass**

La maison a été vendue

- **comp:aux@caus**

Elle le fait vendre la maison



Surface Syntactic Universal Dependencies



- **comp:pred** : *complément prédicatif*
Elle est préponderante
Les blessures sont devenues fréquentes
Jean est étudiant
- **comp:obl**
*L'oeuvre est **situé** à Versailles*
*agressions **susceptibles** d'entraîner des poursuites*
***accès** à l'eau potable*

Surface Syntactic Universal Dependencies



- **comp:obj** *direct object*
 - Objet direct d'un verbe
*Jean **lit** un livre*
 - Complément de préposition
*accès **à** l'eau potable*
 - Lien entre le subordonnant et le verbe de la subordonnée
*Il pleuvait **quand** Jean a pris le train*

Des structures de traits dans les dépendances

N1 -[comp:obj]-> N2

N1 -[1=comp, 2=obj]-> N2

N1 -[1=comp, !2, !deep]-> N2

N1 -[subj@expl]-> N2

N1 -[1=subj, deep=expl]-> N2

N1 -[deep=expl]-> N2

Grouper et décompter les résultats dans Grew-match

Clustering

Clustering 1: ☐ No ☒ Key ☐ Whether

X.upos

Syntaxe : X.upos, X.Number, X.NumType, X.PronType

Pour faire appel à l'étiquette d'une dépendance : e.label

(le patron de recherche doit contenir la définition de la dépendance :)

```
1 pattern { e:X->Y }
```

Grouper et décompter les résultats dans Grew-match

Whether:

Clustering 1: ☐ No ☐ Key ☒ Whether

1 Y[upos=NOUN]; Y << X

Forme du patron habituel (sans 'pattern {}')

2 clusters :

- 1) occurrences qui correspondent au patron
- 2) occurrences qui ne correspondent pas

Exos : À vous

- Trouvez tous les lemmes (**lemma**) des auxiliaires (**AUX**)
- Trouvez toutes les relations de dépendance entre deux verbes (**VERB**)
- Observez la distribution du genre sur les noms français vs les noms allemands (**corpus allemand: SUD_German-GSD**)
- Observez la distribution du POS du **gouverneur** des relatives (**mod@relcl**)
- Observez la distribution du POS de la **tête** des relatives (**mod@relcl**)
- Vérifiez si le pronom relatif (**PronType=Rel**) dépend ou non de la tête de la clause relative

Exos : À vous

- Trouvez tous les lemmes (**lemma**) des auxiliaires (**AUX**)

The screenshot shows a web interface for a linguistic search tool. At the top, there is a button labeled "Show corpora list" and a text box containing "SUD_French-GSD@2.14". To the right of the text box are an information icon and a dropdown menu icon. Below this, a code editor shows a single line of code: "1 pattern {X[upos=AUX]}|". At the bottom, there is a section for "Clustering 1:" with three radio buttons: "No", "Key" (which is selected), and "Whether". Below the radio buttons is a text box containing "X.lemma". At the very bottom, there are five checkboxes: "lemma" (checked), "upos" (checked), "xpos" (unchecked), "features" (checked), and "textform/wordform" (unchecked). A help icon is located to the right of the last checkbox.

Show corpora list SUD_French-GSD@2.14

```
1 pattern {X[upos=AUX]}|
```

Clustering 1: ☐ No ☒ Key ☐ Whether

X.lemma

☒ lemma ☒ upos ☐ xpos ☒ features ☐ textform/wordform ?

Exos : À vous

- Trouvez toutes les relations de dépendance entre deux verbes (**VERB**)

The screenshot shows a web interface for a dependency parser. At the top, there is a button labeled "Show corpora list" and a text box containing "SUD_French-GSD@2.14". To the right of the text box are an information icon (i) and a dropdown menu icon. Below this is a text area containing the following code:

```
1 pattern {X[upos=VERB]; Y[upos=VERB]; d: X->Y}
```

At the bottom, there is a section labeled "Clustering 1:" with three radio buttons: "No", "Key" (which is selected), and "Whether". Below this is a text input field containing the text "d.label".

Exos : À vous

- Observez la distribution du genre sur les noms français vs les noms allemands (**corpus allemand: SUD_German-GSD**)

[Show corpora list](#) SUD_French-GSD@2.14  

1

`pattern {X[upos=NOUN]}`

Clustering 1: ☐ No ☒ Key ☐ Whether

Exos : À vous

- Observez la distribution du POS du **gouverneur** des relatives (**mod@relcl**)

```
1 pattern {X-[mod@relcl]->Y}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

X.upos

Exos : À vous

- Observez la distribution du POS de la **tête** des relatives (**mod@relcl**)

```
1 pattern {X-[mod@relcl]->Y}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

Y.upos

Exos : À vous

- Vérifiez si le pronom relatif (**PronType=Rel**) dépend ou non de la tête de la clause relative

```
1 pattern {X-[mod@relcl]->Y; Z[PronType=Rel]; X << Z; Z << Y}
```

Clustering 1: ☐ No ☐ Key ☒ Whether

```
1 Y->Z
```

Exploration : adjectif

- Comment les adjectifs sont-ils annotés en SUD ?
 - Trouvez tous les adjectifs (**ADJ**)
 - Identifiez les upos des gouverneurs de tous les adjectifs
 - Quelles sont les dépendance qui relient les adjectifs à leur gouverneur ?
 - Quels sont les lemmes des adjectifs qui se trouvent avant le nom qui les gouverne?
 - Trouvez avec une seule requête la distribution des lemmes des adjectifs selon leur position (avant ou après) par rapport au nom

Exploration : adjectif

Identifiez les upos des gouverneurs de tous les adjectifs

```
1 pattern {X[upos=ADJ]}; A->X;}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

A.upos

Exploration : adjectif

Quelles sont les dépendances qui relient les adjectifs à leur gouverneur ?

```
1 pattern {X[upos=ADJ]; d: A->X;}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

d.label

Exploration : adjectif

Quels sont les lemmes des adjectifs qui se trouvent avant le nom qui les gouverne?

```
1 pattern {X[upos=ADJ]; A->X;  
2 A[upos=NOUN]; X << A;}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

X.lemma

Exploration : adjectif

Trouvez avec une seule requête la distribution des lemmes des adjectifs selon leur position (avant ou après) par rapport au nom

```
1 pattern {X[upos=ADJ]; A->X;  
2 A[upos=NOUN];}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

X.lemma

Clustering 2: ☐ No ☐ Key ☒ Whether

```
1 A << X
```

Observation critique de SUD et UD

- Identifiez **tous les modifieurs d'un nom** dans le corpus. Examinez la distribution des occurrences selon leur étiquette syntaxique.
- Identifiez les **lemmes** de tous les **verbes ayant un complément au sens propre** (un dépendant obligatoire)
- Combien de **phrases dont la racine n'est pas un verbe fini** existe-t-il dans le corpus ?
- Identifiez tous les **sujets nominaux** qui **ne s'accordent pas en nombre** avec **leur gouverneur**.

Identifiez **tous les modifieurs d'un nom** dans le corpus. Examinez la distribution des occurrences selon leur étiquette syntaxique.

```
1 pattern {X[upos=NOUN]; e:X->Y|}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

e.label



Identifiez les **lemmes** de tous les **verbes** ayant un **complément au sens propre** (un dépendant obligatoire)



```
1 pattern {X[upos=VERB]; e:X-[nsubj|obj|iobj|csubj|ccomp|xcomp]->Y}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

X.lemma

4.40%	avoir	4.00%	pouvoir	3.00%	faire	2.50%	
1.20%	laisser	1.20%	mesurer	1.10%	commencer		



```
1 pattern {X[upos=VERB]; X-[l=comp]->Y}
```

Clustering 1: ☐ No ☒ Key ☐ Whether

X.lemma

5.50%	avoir	3.90%	faire	2.50%	pouvoir		
1.10%	compter	1.10%	rester	1.10%	voir		

Combien de **phrases dont la racine n'est pas un verbe fini** existe-t-il dans le corpus ?



```
1 pattern {X-[root]->Y}
2 without {Y[VerbForm=Fin]}
```

Clustering 1: ☒ No ☐ Key ☐ Whether

☒ lemma ☒ upos ☐ xpos ☒ features ☐ textfo

Search Q Count ≡ Clone ↗

8748 occurrences [0.376s]

Save %



```
1 pattern {X-[root]->Y}
2 without {Y[VerbForm=Fin]}
```

Clustering 1: ☒ No ☐ Key ☐ Whether

☒ lemma ☒ upos ☐ xpos ☒ features ☐ te

Search Q Count ≡ Clone ↗

804 occurrences [0.337s]

Save %

Identifiez tous les **sujets nominaux** qui ne s'accordent pas en nombre avec leur gouverneur.



```
1 pattern {V-[nsubj]->Y; Y[upos=NOUN]; Y.Number<>V.Number}
2 without {Y-[conj]->Z}
```

Clustering 1: ☒ No ☐ Key ☐ Whether

☒ lemma ☒ upos ☐ xpos ☒ features ☐ textform/wordform ? senten

Search Q Count ≡ Clone ↗

473 occurrences [0.399s]

Save 📄 TSV ⬇ CoNLL ⬇



```
1 pattern {V-[subj]->Y; Y[upos=NOUN]; Y.Number<>V.Number}
2 without {Y-[conj:coord]->Z}
```

Clustering 1: ☒ No ☐ Key ☐ Whether


☒ lemma ☒ upos ☐ xpos ☒ features ☐ textform/wordform ? senten

Search Q Count ≡ Clone ↗

96 occurrences [0.429s]

Save 📄 TSV ⬇ CoNLL ⬇



Ces détecteurs sont d'une extrême sensibilité.



Grew


- Grew-match n'est qu'une partie de Grew
- Outil de réécriture de graphes : **Graph rewriting** tool
- Il permet de transformer et modifier les graphes, dont les arbres
 - Par exemple, transformation $UD \rightarrow SUD$ et $SUD \rightarrow UD$
- Utilisation : ligne de commande, python ou interface web
- Documentation disponible :

<https://web.grew.fr/>




Grew

Vous pouvez télécharger les résultats de requêtes et les utiliser sur Grew web.



Vous pouvez éditer les règles
directements dans l'interface



Syntaxe de Grew

```
rule r1 {  
    pattern {} Motif recherché ✓  
    without {} Sous-motif à exclure ✓  
    commands {} Transformations à réaliser sur les motifs retenus  
}
```

Commands : **add_node** X, **del_node** X, **add_edge**, **del_edge**, **del_feat** X.Feature, etc.

Doc : <https://grew.fr/doc/commands/>

Règles de transformation

```
rule cc {  
    pattern {X[form=et]}  
    commands {X.upos = CCONJ}  
}
```

Trouve tous les noeuds X ayant la forme 'et'

Attribue la valeur CCONJ au trait upos de ces noeuds

Si le trait n'existe pas, on le crée

Règles de transformation

```
rule gender_del {  
    pattern {X[upos=NOUN, Gender]}  
    commands {del_feat X.Gender}  
}
```

Trouve tous les noeuds X ayant le upos “NOUN” et portant le trait Gender

Elimine le trait Gender sur ces noeuds

Stratégies d'application de règles

La règle est appliquée à chaque occurrence du patron recherché indépendamment :

nombre d'occurrences = nombre d'arbres retournés

Pour obtenir un seul arbre comprenant toutes les modifications :

```
rule gender_del {  
    pattern {X[upos=NOUN, Gender]}  
    commands {del_feat X.Gender}  
}  
  
strat s1 { Onf (gender_del) }
```

Règles de transformation

```
rule subject {  
    pattern {e:X-[subj]->Y}  
    commands {del_edge e; add_edge X-[nsubj]->Y}  
}  
  
strat s1 { Onf (subject) }
```

Trouve toutes les arêtes e allant d'un X vers un Y et portant l'étiquette subj

Supprime toutes les arêtes e

Ajoute une arête portant la dép nsubj entre toutes les paires X et Y

Règles de transformation

```
rule add_empty {  
    pattern {X[upos=NOUN]}  
    commands {add_node N:>X; N.form=empty_node}  
}  
  
strat s1 { Onf (add_empty) }
```

Trouve tous les X ayant le upos NOUN

Ajoute un noeud N immédiatement après X

N a “empty_node” comme forme

add_node N :> X

Juste avant

add_node N :< X

Juste après

Règles de transformation

```
rule add_empty {  
  pattern {X[upos=NOUN]}  
  without {X < Y; Y[form="empty_node"]}   
  commands {add_node N:>X; N.form=empty_node}  
}
```

**pour éviter la boucle infinie,
exclure les noeuds déjà traités**

```
strat s1 { Onf (add_empty) }
```

Trouve tous les X ayant le upos NOUN

Ajoute un noeud N immédiatement après X

N a “empty_node” comme forme

`add_node N :> X`

Juste après

`add_node N :< X`

Juste avant

Exos

- Changez tous les étiquettes VERB en V
- Ajoutez aux verbes transitifs un pair trait-valeur, Transitive=Yes
 - Faites pareil pour les verbes intransitifs en ajoutant Transitive=No
- Transformez le trait 'Gender' des noms en 'Genre', en gardant les mêmes valeurs.
 - Pour donner la valeur d'un trait à un autre trait: $X.Feature = Y.Feature$
- Transformez la séquence "éclatée" à *le* en un seul noeud "au".
 - Créez le nouveau noeud et donnez-lui la forme "au"
 - Ajoutez-lui l'étiquette upos "ADP+DET"
 - Ajoutez une dépendance 'comp:prep' allant de la forme "au" au nom du groupe prépositionnel.
 - Ajoutez une dépendance allant du gouverneur du groupe prépositionnel à la forme "au"
 - Donnez-lui la même étiquette de dépendance syntaxique qui était portée par la préposition "à" dans l'arbre de départ
 - Pour copier la dépendance d'une arête à une autre arête : $e2.label = e1.label$