

Ressources linguistiques

Corpus : définition

- Ensemble de documents numériques,
- Corpus = collection structurée de données textuelles ou orales
- Un corpus peut être composé de
 - Texte complet
 - Ensemble de textes complets
 - Les œuvres complètes d'un ou de plusieurs auteurs
 - Tous les numéros d'un journal sur une ou plusieurs années
 - Tous les textes connus d'une période historique particulière
 - Echantillons extraits de textes complets : ensemble de citations
 - Dictionnaire
 - Images
 - Documents sonores ou audiovisuels

Corpus

- Rôle / fonction pour la linguistique ?
- Rôle / fonction pour le TAL ?

Corpus

- Rôle pour la linguistique :
 - Etude d'un phénomène ou de la langue
 - Approche empirique ou inductive : corpus driven (« guidée par les corpus »)
 - Pas d'hypothèse initiale forte
 - Approche bottom-up : on part des observations individuelles vers des abstractions plus globales
 - Découvrir des phénomènes que les théories linguistiques n'ont pas (ou mal) anticipées

=> **Le corpus est un objet, une source de théorie en soi**
 - Vérification de l'hypothèse
 - Approche déductive : corpus based (« basée sur les corpus »)
 - utiliser des corpus **pour tester, quantifier** ou **illustrer** des hypothèses linguistiques déjà existantes
 - Approche top-down : On part d'une généralisation théorique, et on examine dans le corpus si elle est confirmée
 - Le corpus sert à mesurer et confirmer/invalider cette hypothèse

=> **Le corpus est un outil, pas une source de théorie en soi**

Corpus

- Rôle pour le TAL :
 - Outiller les recherches en linguistique
 - Entraînement de modèles,
 - Evaluation,
 - Extraction de connaissances.

Typologie des corpus

- **Selon le mode**

- Corpus textuels
- Corpus oraux (transcrits) (CHILDES, TCOF)

- **Selon la nature**

- Corpus généraux (Brown Corpus, BNC, frWac)
- Corpus spécialisés (médical, juridique, presse, éducation, etc.)
- Corpus de langue familière / réseaux sociaux
- Learner corpora (corpus d'apprenants)
- Corpus monolingue vs corpus multilingue
- Corpus comparables / corpus parallèles (traduction)
 - sélections de textes similaires dans plus d'une langue ou dans plusieurs variétés d'une langue

- **Selon la finalité**

- Corpus annotés vs non annotés
- Corpus d'apprentissage d'un modèle vs corpus d'évaluation

Constitution de corpus

- Principes?

Constitution d'un corpus : Principes

- définir les critères de sélection
 - objectif théorique explicite
 - taille des données
 - diversification
 - représentativité
- organisation de ces données
- documentation du corpus
- préparation et homogénéisation des textes

Constitution de corpus

- Problèmes juridiques
- Métadonnées
- Homogénéisation

Constitution de corpus

- Problèmes juridiques ?

Problèmes juridiques

- **Droits d'auteur (copyright)**

- Utilisation de textes, images, sons ou vidéos protégés par le droit d'auteur.
- Absence d'autorisation explicite pour reproduire, stocker ou analyser les données.
- Restrictions liées aux licences (presse, littérature, contenus commerciaux, bases payantes, etc.).

- **Droits voisins**

- Pour les enregistrements audio/vidéo : droits des interprètes, producteurs, diffuseurs.

Problèmes juridiques

- **Protection des données personnelles (RGPD)**

- Présence d'informations permettant d'identifier une personne (noms, adresses, messages privés...).
- Obligation de définir une base légale pour le traitement des données (consentement, intérêt scientifique...).
- Nécessité d'anonymiser ou pseudonymiser les données.

- **Données sensibles (selon le RGPD)**

- Texte mentionnant : opinions politiques, religion, santé, orientation sexuelle, données biométriques, etc.
- Traitement strictement encadré et nécessitant souvent des protections renforcées.

- **Respect de la vie privée**

- Collecte de données issues de communications privées (emails, chats, réseaux sociaux non publics).
- Risque de divulgation involontaire d'informations sensibles.

Problèmes juridiques

- **Conditions d'utilisation des plateformes (TOS)**

- Interdiction de scraper certains sites (Twitter/X, Facebook, Instagram, forums, etc.).
- Limitations sur la réutilisation des données collectées via API.

- **Propriété intellectuelle des annotations**

- Les annotations manuelles peuvent elles-mêmes être couvertes par le droit d'auteur.
- Nécessité de définir les droits des annotateurs (contrat, cession de droits).

- **Accords de diffusion**

- Certains corpus peuvent être exploités pour la recherche mais non diffusés publiquement.
- Nécessité de distinguer : accès interne, partage restreint, publication ouverte.

Problèmes juridiques

- **Conservation et sécurité des données**

- Obligation de garantir un stockage sécurisé (surtout si données personnelles).
- Définir une durée légale ou contractuelle de conservation.

- **Consentement des participants (corpus oraux ou enquêtes)**

- Nécessité de formulaires de consentement clairs.
- Droit des participants à retirer leur accord (droit à l'effacement).

Métadonnées

- C'est quoi?
- A quoi ca sert?

Quelles informations ?

- Le contenu intellectuel :
 - titre, résumé, mots-clés, type ;
- Le contexte de production :
 - date, créateur, procédés de création ;
- Les caractéristiques techniques :
 - formats, taille, organisation ;
- Les propriétés et droits d'usage :
 - détenteurs des droits, conditions d'accès, conditions de partage, conditions d'usage.

Quelles informations ?

- La transcription
 - [Qui transcrit et comment ?]
- La correction
 - [Qui corrige ? Quel niveau de correction ?]
- La structuration logique du texte (entête, paragraphe, liste, etc.) et présentation matérielle (changement de ligne, soulignement, espaces, etc.)
 - [Qui encode ?]
- L'annotation :
 - [Qui annote ?][Liens vers d'autres textes, ou des sources d'informations : dictionnaires, bdd biographiques, ...]
- L'indexation : Liste alphabétique des entités intéressantes citées dans le texte (personnes, organisations, lieux, ou tout autre information utile pour le travail de recherche)
 - [Qui indexe ?][Liens vers sources d'informations : vocabulaires contrôlés, ontologies, dictionnaires]

Pourquoi

- **Décrire le document et conditionnent sa transmission, son archivage et sa réception**
- **Lier le document numérique à l'original** et inversement
- **Lier différentes versions** d'un document
- **Gérer les droits d'accès** (droits d'auteur, confidentialité) et d'usage (droits d'impression, de reproduction, de modification...);
- **Préserver les informations techniques** nécessaires à la lecture des fichiers ;
- **Garantir l'intégrité des fichiers et le suivi de leurs éventuelles modifications.**

Homogénéiser les documents

Pourquoi ?

Hétérogénéité de sources et de formats

- Variation de sources :
 - Pdf, OpenDocument, Docx, HTML, XML, PNG, JPEG, tar, zip, 7z
- Codage de caractères
 - chaque symbole graphique (caractère alphabétique, chiffre, signe de ponctuation...) correspond pour le système à un nombre
 - Un des principaux obstacles à l'échange de données informatiques est que tous les systèmes informatiques n'utilisent pas le même code

Codage de caractères

- Problème : lorsqu'un texte n'est pas interprété avec le même système d'encodage que celui utilisé pour l'enregistrer
 - Les stations Unix, le Macintosh et le PC n'utilisent pas la même norme de codage
 - Word vs Open Document vs Pdf ...
 - Word
 - Documentation inaccessible au grand public
 - N'est pas un format de document structuré
 - PDF (Portable Document Format)
 - Format de représentation des documents de Adobe
 - Est un format structuré
 - HTML :
 - format utilisé pour les pages du Web.
- Le passage d'un format à l'autre peut se traduire par une perte d'information

Codage de caractères

- Multiplicité des encodages
 - ASCII
 - ISO-8859-1 / Latin-1
 - Windows-1252
 - Shift-JIS (japonais)
 - KOI8-R (russe)
 - ...
- Chaque encodage attribue des valeurs numériques différentes aux mêmes caractères.
- Un texte créé avec un encodage peut être illisible ou déformé lorsqu'il est lu avec un autre.

ISO 10646

4 294 967 296 car


UNICODE

65 536 car

ISO-LATIN-n 256 car

ASCII

128 car



Codage de caractères

- Lorsque l'encodage utilisé pour lire le texte ne correspond pas à celui du fichier, on obtient :
 - des caractères illisibles : 
 - des séquences étranges : Ã© pour « é »
 - des symboles inattendus

=> **Uniformiser l'encodage** dès le début du projet : adopter **Unicode (UTF-8)**, devenu le standard international.



Format commun

- Standard — interopérable :
 - Standardisations officielles (ISO, Afnor, W3C, Consortium Unicode)
- repose sur un consensus entre les acteurs
- échange de données plus facile

Standards et formats

- **Formats textuels**

- TXT : Le chat dort sur le tapis.
- JSONL : {"id": 1, "text": "Le chat dort sur le tapis."}
- TSV/CSV :
 - CSV (comma-separated)
id,text
1,"Le chat dort sur le tapis.«
 - TSV (tab-separated)

```
id  text
1   Le chat dort sur le tapis.
```

Standards et formats

- **Formats textuels**

- XML/TEI

<TEI>

<text>

<body>

<p xml:id="s1">Le chat dort sur le tapis.</p>

</body>

</text>

</TEI>

- Format CoNLL

```
1  Le  le  DET  _  Definite=Def|Gender=Masc|Number=Sing 2  det  _  _
2  chat  chat  NOUN  _  Gender=Masc|Number=Sing 3  nsubj  _  _
3  dort  dormir  VERB  _  Tense=Pres|Mood=Ind 0  root  _  _
4  sur  sur  ADP  _  _ 6  case  _  _
5  le  le  DET  _  Definite=Def|Gender=Masc|Number=Sing 6  det  _  _
6  tapis  tapis  NOUN  _  Gender=Masc|Number=Sing 3  obl  _  _
7  .  .  PUNCT  _  _ 3  punct  _  _
```

Standards et formats

Formats audio

WAV,

MP3

Transcriptions au format CHAT (CHILDES)

Formats ELAN (.eaf)

Problèmes méthodologiques

- Corpus trop petits
- Corpus déséquilibrés
- Corpus biaisés socialement
- Problèmes de droits d'auteur
- Transparence et reproductibilité

Corpus en ligne : Anglais

- Corpus de Brown (1964)
 - https://en.wikipedia.org/wiki/Brown_Corpus
- *British National Corpus* (1991)
 - <http://www.natcorp.ox.ac.uk/archive/papers/gblibs.html>

Corpus en ligne : français

- Corpus écrits

- [Frantext](#)
- [Corpus for Idiolectal Research \(CIDRE\)](#) : 400 œuvres de fiction
- <http://redac.univ-tlse2.fr/corpus/resolco/> : copies transcrites des élèves et des étudiants
- <https://filsdelapensee.ch/> :
 - corpus de plus de 83 000 extraits de tous temps et tous lieux et de plus de 21000 auteurs, ce fonds ne cessant de s'enrichir grâce à la participation de membres
- <https://www.sketchengine.eu/frwac-french-corpus/> (frWac)
- <https://lidilem.univ-grenoble-alpes.fr/ressources/corpus/emolex>

Corpus en ligne : français

- Corpus oraux

- [Corpus du Français Parlé Parisien](#)
- [Multicultural Paris French Corpus](#)
- [Corpus d'Étude pour le Français Contemporain](#)
- [ESLO](#)
- <https://www.cnrtl.fr/corpus/tcof/>

Dictionnaires en ligne

- TLFi : <http://atilf.atilf.fr/>
- Crisco : dictionnaire des synonymes
 - <https://crisco.unicaen.fr/dictionnaire-electronique-des-synonymes-des/presentation-du-dictionnaire-electronique-des-synonymes/>
- <https://www.cnrtl.fr/dictionnaires/anciens/>

Lexiques

- WordNet / WOLF
- VerbNet, FrameNet
- Lexique383
- Morphalou et Demonette
- Wikipédia

WordNet 2005 : <https://wordnet.princeton.edu/>

- réseau lexical structurant les mots en synsets reliés par des relations sémantiques (hyperonymie, hyponymie, antonymie, méronymie, etc.).
- **to run :**
 - **run.v.01** “move fast by using one's feet” (se déplacer rapidement en utilisant ses pieds)
 - **run.v.02** “direct or control” (e.g., run a business) (diriger ou gérer => gérer une entreprise)
 - **run.v.04** “flow” (water runs) (couler => l'eau coule)
- ressource de référence, très utilisée en TAL.
 - Désambiguïsation lexicale
 - Recherche sémantique / expansion de requêtes
 - Inférence lexicale
 - Représentation sémantique
 - Paraphrases et similarité sémantique
 - Traduction automatique ou résumé

FrameNet : <https://framenet.icsi.berkeley.edu/>

- Ressource sémantique basée sur la Frame Semantics (Fillmore). Elle décrit des **frames** (situations conceptuelles) et les **rôles associés** (frame elements), avec des exemples annotés.
- Exemple : **Frame “Commerce_buy”**
 - **Situation** : Achat
 - **Rôles** : *Buyer, Seller, Goods, Money* (acheteur, vendeur, marchandise, argent)
 - **Exemple** :
 - *Mary bought a book from John for 10 dollars.* (Mary a acheté un livre à John pour dix dollars)
- Utilisation en TAL
 - Reconnaissance et étiquetage des rôles sémantiques
 - Extraction d'information
 - Analyse d'événements et de relations
 - Désambiguïsation sémantique via la détection de frames
 - Compréhension et génération de texte

Lexique : <http://www.lexique.org/>

- Base lexicale du français contenant plus de 135 000 formes, avec :
 - catégories grammaticales,
 - fréquences d'usage,
 - informations phonologiques et orthographiques,
 - lemmes.
- Utilisation en TAL
 - Analyse lexicale (lemmatisation, tokenisation)
 - Création de modèles de langage
 - Analyse phonologique (par ex. en TTS)
 - Évaluation de la complexité lexicale
 - Applications en psycholinguistique computationnelle

Morphalou :

<https://www.ortolang.fr/market/lexicons/morphalou>

- Lexique morphologique du français qui contient
 - lemmes,
 - flexions complètes,
 - catégories grammaticales,
 - traits morphosyntaxiques
 - **aller**:
 - vais, vas, va, allons, allez, vont, irai, irais, irait... => toutes les formes fléchies
 - catégorie (V)
 - traits morphosyntaxiques : *mode, temps, personne, nombre*
- Utilisation en TAL
 - Lemmatisation et étiquetage morpho-syntaxique
 - Génération de formes fléchies
 - Normalisation linguistique
 - Ressource d'entrée pour entraînement de taggers morpho-syntaxiques
- Demonette : https://demonette.fr/demonext/vues/front_page.php

Lexiques de sentiments et d'émotions

- SentiWordNet
 - Anglais
 - Scores pos/neg/obj pour synsets de WordNet
- NRC Word-Emotion Association Lexicon (“NRC EmoLex”)
 - anglais (+ traductions automatiques vers ~40 langues)
 - ~14 000 mots annotés selon 8 émotions (joie, colère, peur, etc.) + polarité pos/neg
 - <https://gitlab.uni-hannover.de/nagengast.m/nagengast25-ma-thesis/-/tree/main/data/NRC-Lexicons/NRC-Emotion-Lexicon>
- NRC Affect Intensity Lexicon
 - Score d'intensité pour bonheur, colère, peur, tristesse.
- FEEL (French Expanded Emotion Lexicon)
 - Français
 - ~14 000 mots français annotés pour polarité + émotions (basé sur NRC puis validé humainement)
 - <http://advanse.lirmm.fr/feel.php>
- WordNet-Affect
 - Anglais
 - Extension émotionnelle de WordNet
 - Anglais
- BERT Emotion Lexicons
 - Dédits automatiquement près de 30 langues via modèles multilingues.

Sentiment vs émotion

- Sentiment
 - polarité positive/négative
- Émotions
 - catégories émotionnelles
- Intensité émotionnelle
 - score d'intensité

Wikipédia

- **Utilisation en TAL**

- Extraction d'entités nommées
- Construction automatique d'ontologies
- Détection de relations
- Pré-entraînement de modèles de langage (BERT, GPT, etc.)
- Enrichissement lexical (définitions, synonymes, hyperonymes)
- Alignement multilingue (articles parallèles ou comparables)

Web 3.0 : Exemple de DBpédia

De Wikipédia à Dbpédia

- un projet universitaire et communautaire d'exploration et d'extraction automatiques de données dérivées de Wikipédia.
- propose une version structurée et normalisée au format du web sémantique des contenus de Wikipedia.
- chaque ressource est décrite par plusieurs propriétés
 - au moins un label,
 - un abstract court ou long,
 - des liens vers les pages wikipedias correspondantes....

dbpprop:death	1885-05-22 (xsd:date)
dbpprop:deathdate	1885-05-22 (xsd:date)
dbpprop:deathplace	- dbpedia:Paris - dbpedia:France
dbpprop:hasPhotoCollection	http://www4.wiwiiss.fu-berlin.de/flickrwrappr/photos/Victor_Hugo
dbpprop:id	117 (xsd:integer) - Victor_Hugo
dbpprop:imagesize	240px
dbpprop:influenced	- dbpedia:Charles_Baudelaire - dbpedia:Jorge_Luis_Borges - dbpedia:Jean_Cocteau - dbpedia:Irvine_Welsh - dbpedia:Paul_Verlaine - dbpedia:Gérard_de_Nerval - dbpedia:Fyodor_Dostoevsky - dbpedia:Albert_Camus - dbpedia:Charles_Dickens - dbpedia:Charles-Marie-René_Leconte_de_Lisle - dbpedia:Gustave_Flaubert - dbpedia:Oscar_Wilde - dbpedia:Ayn_Rand - dbpedia:Louis-Honoré_Frédérique
dbpprop:influences	- dbpedia:Alphonse_de_Lamartine - dbpedia:François-René_de_Chateaubriand - dbpedia:Walter_Scott - dbpedia:Voltaire - dbpedia:William_Shakespeare
dbpprop:movement	dbpedia:Romanticism
dbpprop:name	- Victor Hugo - Hugo, Victor-Marie
dbpprop:occupation	poet, playwright, novelist, essayist, visual artist, statesman, human rights campaigner

Corpus annotés

- UD French (GSD, Sequoia...)
- <http://www.llf.cnrs.fr/fr/elico>

Ressources en français

- <https://www.ortolang.fr/fr/accueil/>
- <https://corli.huma-num.fr/fr/>
- <https://www.cnrtl.fr/>