

Langues formelles

Lexique et morphologie

INALCO
kata.gabor@inalco.fr

14 octobre 2024

dans la **théorie des langages formels**, une langue est

- un ensemble de **chaînes** ou **mots** (*strings*)
- composées de **symboles**
- sélectionnées à partir d'un **alphabet** (vocabulaire)

- **Alphabet**, un ensemble « hors-langage » :
 - Ensemble Σ des symboles utilisés par un langage
 - $\Sigma = \{a, b, c, d \dots z\}$ (= [a-z])
 - $\Sigma = \{0, 1, 2 \dots 9\}$ (= [0-9])
 - $\Sigma = \{a, f, d, x\}$
 - $\Sigma = \{b, c, 0, \$, \mu, z\}$
 - $\Sigma = \{ab, de, xyz\}$
 - $\Sigma = \{abc, a, tuv, vu\}$
 - On considère les éléments comme **atomiques** : « abc » peut-être un symbole unique pour un langage
 - Pas de répétitions au sein d'un alphabet (ensemble)

- **Mot** (ou **chaîne**) :
 - Un élément de l'alphabet est un mot
 - **Concaténation** « . » **de symboles** issus d'un alphabet :
 - $\Sigma = \{0, 1\} : \alpha_1 = 0.0.1.0, \alpha_2 = 1.0.0.0.1.0 \dots$
 - Associative : $(a.b).c = a.(b.c)$
 - Non commutative : $0.1 \neq 1.0$
 - Quelque soit l'alphabet, il est possible de former le **mot** (ou chaîne) **vide**, noté « ϵ » (différent de $\emptyset$)
 - **Taille du mot** : $|x|$, nombre de **symboles** :
 - $|0.1.0.0| = 4$ ($\Sigma = \{0, 1\}$)
 - $|d.d.ab.ab.d| = 5$ ($\Sigma = \{ab, d\}$)
 - $|\epsilon| = 0$ ($\forall \Sigma$)


- Un langage est un **ensemble de mots**
- Définition de langages à partir d'**alphabets** :
 - Langage généré par un alphabet (récursive) :
 - Tout mot de l'alphabet appartient au langage
 - Toute concaténation de mots du langage appartient au langage
 - Le mot vide ε appartient au langage
 - **Puissance** « Σ^i » d'un alphabet :
 - Tous les mots formés par concaténation de i éléments de Σ
 - Quelque soit l'alphabet, $\Sigma^0 = \{ \varepsilon \}$
 - Par ex., si $\Sigma = \{0, 1\}$ alors :
 - $\Sigma^1 = \{0, 1\}$
 - $\Sigma^2 = \{00, 01, 10, 11\}$
 - $\Sigma^3 = \{000, 001, 010, 011, 100, 101, 110, 111\}$

- **Fermeture / étoile de Kleene « $*$ » :**
 - Kleene : mathématicien américain
 - Fermeture (étoile, itéré) (informellement) : tout ce qu'il est possible de construire à partir d'un alphabet / langage
 - Union de **toutes les puissances** d'un alphabet :
 - $\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \Sigma^3 \cup \Sigma^4 \dots$
 - Ou « **langage de Σ** », « **langage généré par Σ** »
 - Quelque soit Σ : $\varepsilon \in \Sigma^*$
- Attention à la distinction **symboles / mots** :
 - Si $\Sigma = \{0, 1\}$ alors 1.0.1 n'appartient pas à Σ^*
 - Si $\Sigma = \{a, ab\}$ alors a.ab.b.ab. n'appartient pas à Σ^*



- **Union** : « $L \cup M$ » (ou $L + M$) mots issus soit de L soit de M
 - Associative, commutative, élément neutre $\emptyset$
 - La concaténation est distributive par rapport à l'union
- **Intersection** : « $L \cap M$ » : mots qui existent dans L et dans M
 - Associative, commutative, élément neutre Σ^* , élément absorbant $\emptyset$
- **Complémentaire** : « $\bar{L}$ » : mots de Σ^* qui ne sont pas dans L
- **Fermeture (étoile, itéré) stricte** : « L^+ » = $\bigcup_{i \geq 1} L^i$

Examples

- Quelques exemples :
 - Alphabet $\Sigma = \{ a, b, c \}$




- Languages $L_1 = \{ a, b \}$, $L_2 = \{ a, c \}$





Examples

- Quelques exemples :
 - Alphabet $\Sigma = \{ a, b, c \}$



- Languages $L_1 = \{ a, b \}$, $L_2 = \{ a, c \}$




Examples





- Quelques exemples (suite) :

- $\Sigma = \{ a, b, c \}$, $L_1 = \{ a, b \}$, $L_2 = \{ a, c \}$

- Union : $L_3 = L_1 \cup L_2$



- Concaténation : $L_4 = L_1 \cdot L_2$




Éléments de
l'alphabet

Éléments du
langage







Examples

- Quelques exemples (suite) :

- $\Sigma = \{ a, b, c \}$, $L_1 = \{ a, b \}$, $L_2 = \{ a, c \}$
- Union et concaténation : $L_5 = L_1 \cup (L_1 \cdot L_2)$



- Intersection : $L_6 = L_1 \cap L_2$






Examples

- Quelques exemples (suite) :




- $\Sigma = \{ a, b, c \}, L_1 = \{ a, b \}, L_2 = \{ a, c \}$

- Puissance : $L_7 = L_1^0, L_8 = L_1^1, L_9 = L_1^2, L_{10} = L_1^3$



Éléments de
l'alphabet

Éléments du
langage



- un langage formel est un sous-ensemble de la fermeture kleene de l'alphabet : $L \subseteq \Sigma^*$
- comment dire si un mot appartient à la langue ?
 - les automates à états finis définissent une langue
 - le problème de l'appartenance peut être généralisé :
 - transduction d'une chaîne vers une autre (analyse, traduction vers une autre langue)
 - scoring (des chaînes selon leur acceptabilité : modélisation du langage)