

Lexique et morphologie


21 octobre 2024

—Kata Gábor

kata.gabor@inalco.fr—

Construction d'une morphologie computationnelle M

1. créer des automates pour les (classes de) radicaux
2. créer des automates pour les affixes (préfixes, suffixes)
3. combiner les automates de radicaux avec les automates d'affixes (règles morphotactiques : dans quel ordre les morphèmes se suivent, règles phonologiques et orthographiques)



un **Transducteur à états finis (FST)** est constitué de :

- V, un vocabulaire ou alphabet d'entrée
- S, un vocabulaire ou alphabet de sortie
- Q, un nombre fini d'états dont
 - état initial
 - état final (un ou plusieurs)
- f, fonction de transition : donne pour chaque état $q \in Q$ et chaque élément du vocabulaire $v \in V$, le ou les états que l'on peut atteindre en partant de q et en utilisant v : $f(q,v) \subset Q$.
- h, fonction de sortie qui associe à un état q et une entrée $v \in V$ une sortie $s \in S$

Opérations sur les FSTs :

- **inversion** : échanger les étiquettes, l'entrée devient la sortie et vice versa. Un FST analyseur peut être ainsi transformé en FST générateur.
- **union** de deux transducteurs $T_1 \cup T_2$: $x [T_1 \cup T_2] y$ si $x [T_1] y$ ou $x [T_2] y$ (le transducteur $T_1 \cup T_2$ traduit x en y si T_1 traduit x en y ou T_2 traduit x en y).

- **composition** de T_1 et T_2 : applique T_1 , puis applique T_2 à la sortie de T_1 . $x [T_1] y$ puis $y [T_2] z$: le vocabulaire de sortie de T_1 est le vocabulaire d'entrée de T_2 .

Morphologie par FSTs

1. Nous avons défini la morphologie (computationnelle) comme une relation entre les formes F et les descriptions/catégories/ C :

$$M \subseteq F \times C \quad (1)$$

où F est l'ensemble des formes et C est l'ensemble des descriptions (catégories); $F \times C$ est l'ensemble de tous les paires possibles entre formes et descriptions; M est l'ensemble des paires existants dans la langue

2. le **FST** a un vocabulaire d'entrée et un vocabulaire de sortie; pour l'analyse morphologique, l'entrée représente les formes et la sortie les descriptions
3. le **FST** définit une langue de paires :

$$F \times C = \{(f, c) | f \in F \text{ et } c \in C\} \quad (2)$$

4. un **FST** peut fonctionner en tant que **traducteur** : de la langue F (formes de mots) vers la langue C (catégories grammaticales et flexionnelles)
5. **FST** peut être traduit en **FSA** qui *accepte* une langue :

$$V_{FSA} = \{(f, c) | f \in F \text{ et } c \in C\} \quad (3)$$

accepte les paires $\{(f, c) \in M\}$

Exercices

1. Construisez un/des transducteurs morphologique(s) qui analyse les formes suivantes et les remplace par les informations morphologiques : cas et nombre.
 - (a) les déclinaisons latines suivantes :

Cas	Singulier	Pluriel
Nominatif	Rosa	Rosae
Accusatif	Rosam	Rosas
Génitif	Rosae	Rosarum
Datif	Rosae	Rosis
Ablatif	Rosa	Rosis

Cas	Singulier	Pluriel
Nominatif	Murus	Muri
Accusatif	Murum	Muros
Génitif	Muri	Murorum
Datif	Muro	Muris
Ablatif	Muro	Muris

(b) Construisez un/des transducteur(s) pour analyser les formes suivantes :

Temps	Nb et Pers	V amare	V monere
Futur	S1	amabo	monebo
Futur	S2	amabis	monebis
Futur	S3	amabit	monebit
Futur	P11	amabimus	monebimus
Futur	P12	amabitis	monebitis
Futur	P13	amabunt	monebunt
Passé	S1	amavi	monui
Passé	S2	amavisti	monuisti
Passé	S3	amavit	monuit
Passé	P11	amavimus	monuimus
Passé	P12	amavistis	monuistis
Passé	P13	amaverunt	monuerunt