

Morphologie non concaténative

Kata Gábor

4 décembre 2023

Lecture optionnelle (pour aller plus loin)

Farrell Ackerman, James Blevins et Robert Malouf: *Word and Paradigm Morphology*. in The Oxford Handbook of Morphological Theory, 2009

1. l'unité de base de l'analyse est le **mot**; l'approche nie l'existence du morphème en tant qu'unité forme + sens
2. dans les langues où les mots varient en forme (précédemment: les langues avec de multiples procédés morphologiques actifs), ces variations sont décrites par des **paradigmes**
3. ces variations montrent des régularités → à décrire sous forme de généralisations ou d'implications entre les formes qui remplissent un paradigme

	SG	DU	PL
NOM	ti	texəh	tiq
ACC	tim	texəh	ti
GEN	tih	texəh	tiq
DAT	tenəh	texəh n'ah	texəq
LOC	texəna	texəh n'ana	texəqna
ABL	texəd	texəh n'ad	texət
PROL	tewna	texəh n'amna	teqm

Figure 1: Déclinaison en nénètse de la toundra, avec une combinaison de morphologie fusionnelle, supplétive etc.

s.nom	méz	kéz	baj	haj	föld	sör	hír
s.gen	mézé	kézé	bajé	hajé	földé	söré	híré
s.dat	méznek	kéznek	bajnak	hajnak	földnek	sörnek	hírnek
s.ins	mézze	kézze	bajjal	hajjal	földdel	sörrel	hírral
s.cau	mézért	kézért	bajért	hajért	földért	sörért	hírért
s.ter	mézig	kézig	bajig	hajig	földig	sörig	hírig
pl.nom	mézek	kezek	bajok	hajak	földek	sörök	hírek
poss.s1	mézem	kezem	bajom	hajam	földem	söröm	hírem
s.acc	mézet	kezet	bajt	hajat	földet	sört	hírt
s.in	mézben	kézben	bajban	hajban	földben	sörben	hírben
s.ade	mézhez	kézhez	bajhoz	hajhoz	földhöz	sörhöz	hírhöz

Table 1: Déclinaison des noms en hongrois (extrait).

s.nom	ló	hó	nő	lé
poss.s3.	lova	hava	nője/neje	leve
s.acc	lovat	havat	nőt	lét/levet

Table 2: Changement du radical et variation dans la déclinaison des noms en hongrois (extrait).

Nous constatons cependant les difficultés suivantes :

- les conditions des allomorphes varient d'un morphème flexionnel à l'autre
- la classification ne fournit pas toute l'information (ou alors on finit par avoir un très grand nombre de classes), p.ex.:
 - organisation de la morphologie hongroise dépend du lieu d'articulation, du caractère arrondi ou non des voyelles de la racine, la dernière consonne, de facteurs lexicaux, sémantiques, ...) → plus de 1700 classes distinctes
- existence de macro- et microparadigmes
- manque d'informations (macro) ou redondance (micro) dans la description

1 L'apprentissage des paradigmes flexionnels

dans la morphologie flexionnelle, une case du paradigme = une forme avec une/des catégorie(s) flexionnelle(s) associée(s)

"Paradigme Cell Filling Problem", PCFP

Le problème du remplissage des cases du paradigme : *Comment les locuteurs sont-ils capables de produire toutes les formes fléchies d'un mot alors qu'ils n'ont que des observations partielles (n'ont jamais rencontré la totalité des formes)?*

Evidence :

- la *saturation* d'un paradigme pour une partie du discours est la proportion des formes réalisées dans un corpus pour le lemme qui maximise cette proportion
- dans les langues hautement flexionnelles, dans un corpus de 1 million de mots, on ne rencontre jamais *toutes les formes fléchies* d'un lemme; **que de données incomplètes** pour chaque paradigme!
- cause : double rareté (*double sparsity*) des formes =
 - peu de lemmes fréquents, beaucoup de lemmes rares,
 - peu de cases fréquemment utilisées (p.ex. nominatif singulier), beaucoup de cases rares

Comment faire?

1. dans l'approche concaténative/procédurale : morphèmes, allomorphes, **les conditions d'apparition des allomorphes** définissent les classes flexionnelles, Mais! comment apprendre les conditions à partir de données incomplètes?
2. dans l'approche mot et paradigme, il est possible de définir des **implications au sein des paradigmes** : il existe des corrélations entre les formes remplissant une case A et les formes remplissant une case B
 - compatible avec les langues non-concatenatives
 - possède la flexibilité nécessaire pour les paradigmes "imparfaits"
 - possible d'inclure des informations de fréquence dans le modèle, plausibilité psychologique : apprentissage par analogie statistique, variations

PCFP : une approche probabiliste. Comment apprendre à identifier les paradigmes et les formes?

Farrell Ackerman et Robert Malouf: *Morphological Organization: the Low Conditional Entropy Conjecture*. in Language, 89(3) 2013

1. chaque case peut être considérée comme une **variable aléatoire**; la probabilité qu'elle prenne une valeur spécifique peut être estimée à partir des observations dans un corpus (*estimateur du maximum de vraisemblance*)
p.ex. dans Table 1,

$$p(s.ade = hez) = 0.42$$

si 3 des 7 noms réalisent la case s.ade par l'ajout du suffixe *-hez*

2. pour pouvoir estimer les corrélations, nous nous appuyons sur la **probabilité conditionnelle** :

$$P(Y|X) = \frac{P(Y \cap X)}{P(X)}$$

par exemple, la probabilité pour un nom que sa forme s.ade est réalisé par *-hez* sachant que son s.ine est réalisé par *-ben*:

$$P(s.ade = hez | s.ine = ben) = \frac{P(s.ade = hez \cap s.ine = ben)}{P(s.ine = ben)} = \frac{\left(\frac{3}{7}\right)}{\left(\frac{5}{7}\right)} = \frac{3}{5}$$

3. **l'espérance** d'une variable aléatoire (pour un nombre fini de valeurs) correspond à une moyenne pondérée des valeurs par les probabilités d'apparition de chaque valeur :

$$E(X) = x_1p_1 + x_2p_2 + \dots + x_np_n$$

Théorie de l'information. L'idée fondamentale de la théorie de l'information est que la "valeur informationnelle" d'un message communiqué dépend du degré de surprise du contenu du message.

- un message = l'observation d'un événement, p.ex. s.ade=hez dans un corpus
- si un événement très probable se produit, le message véhicule très peu d'informations (peu de surprise); si un événement très improbable se produit, le message est beaucoup plus informatif
- p.ex. donner l'information qu'un certain numéro ne sera PAS le numéro gagnant d'une loterie fournit très peu d'informations (presque sûr pour n'importe quel numéro); savoir qu'un numéro particulier va gagner à a une valeur informationnelle élevée (car peu probable)

Comment quantifier l'information donnée par un événement?

- plus l'événement est improbable, plus la surprise/l'information doit être élevée (d'où le négatif)
- additivité : si x_1 et x_2 sont deux événements indépendants, leur occurrence jointe doit être la somme (et non le produit!) de leurs informations (d'où le logarithme)

L'**information** d'un événement spécifique est donc :

$$I(x) = -\log_2 p(x)$$

Elle mesure la surprise (probabilité négative) donnée par un événement en bits ($\log_2$). Convention: $\log 0 := 0$.