

Analyse symbolique des données

- Projet final -

Objectif du cours : montrer la nécessité (et la richesse) d'une réflexion théorique (axée sur les notions fondamentales nécessaires à la modélisation) en amont de toute démarche d'analyse automatique d'un phénomène linguistique, en particulier quand ce phénomène relève de la sémantique.

Objectif du projet final : le projet, découpé en deux parties, vise à proposer, sur un même corpus de textes, deux approches de modélisation portant sur deux phénomènes distincts, l'un portant sur l'analyse du phénomène de marquage de l'incertitude et l'autre portant sur l'analyse du phénomène de marquage de la datation calendaire.

Partie 1 : le marquage de l'incertitude

Annotation et calcul d'AIA

Objectifs principaux de la partie 1

Pendant le cours, nous avons pu appliquer la ressource ModalE à nos textes dans lesquels nous avons auparavant annoté les marqueurs d'incertitude. Nous avons mis en lumière certains limites de cette ressource, notamment le fait qu'elle ne permet pas à ce jour de prendre en compte certains paramètres dont le paramètre 3, celui de la valeur de la modalité, qui dans le cas des marqueurs épistémiques nous permet de distinguer entre marqueurs épistémiques d'incertitude et de non-incertitude. Dans le cadre de ce projet, nous souhaitons tester la pertinence de l'ensemble de règles qui nous permettent de distinguer les marqueurs épistémiques d'incertitude de ceux de NON-incertitude (présentés en cours et définies dans le *guide d'annotation*). Afin de faire cela, vous allez annoter les marqueurs épistémiques extrinsèques avec valeur d'incertitude et avec valeur de NON-incertitude en vous basant sur le guide d'annotation fourni. Ensuite, vous évaluerez la pertinence de ce guide d'annotation à travers un calcul de l'accord inter-annotateur (AIA).

Étape 1 :

À partir de la modélisation de la notion de "modalité" proposée par (Gosselin, 2010) et abordée pendant le cours, vous devrez **annoter** dans les textes fournis les marqueurs épistémiques extrinsèques qui ont une valeur d'incertitude (E-incertitude) et ceux qui n'ont pas une valeur d'incertitude (E-non_incertain). Plus précisément, vous devrez annoter dans les textes donnés tous les marqueurs en choisissant l'étiquette E-incertitude, s'il s'agit d'un marqueur épistémique d'incertitude et E-non_incertain s'il s'agit d'un marqueur épistémique non d'incertitude.

L'annotation sera menée à partir de la plateforme d'annotation **LabelStudio**.

NB : Pendant cette première étape, vous ne devez pas vous consulter avec les autres annotateurs de votre groupe par rapport à vos annotations et aux choix pris pendant l'annotation. Il est important que chacun annote individuellement pour pouvoir calculer le véritable accord entre les annotateurs. En revanche, vous êtes encouragés à noter toutes vos réflexions, hésitations, doutes et choix pris dans un fichier. Vous pourrez en discuter avec les autres au moment de l'étape 3 et pour la rédaction du dossier final.

Étape 2 :

Vous devrez valider la pertinence de cette modélisation à travers un **calcul de l'accord inter-annotateur** (AIA) sur vos données annotées.

Étape 3 :

À la suite de l'évaluation quantitative de vos annotations (AIA), vous devrez mener une **évaluation qualitative** de celles-ci.

Vous vous concentrez principalement sur les **points de désaccord** afin de comprendre les raisons de ces divergences :

- Est-ce parce que vous n'avez **pas repéré le marqueur épistémique** (problème lié au **paramètre 1**) ?
- Vous avez bien repéré qu'il était un marqueur épistémique, mais vous n'avez **pas identifié son caractère extrinsèque** (problème lié au **paramètre 2**) ?
- Vous avez bien repéré qu'il était un marqueur épistémique extrinsèque, mais vous n'avez **pas reconnu qu'il s'agissait d'un marqueur d'incertitude** (problème lié au **paramètre 3**) ?

Réfléchissez également aux **marqueurs repérés** :

- Les mêmes reviennent-ils régulièrement ?
- Ou, au contraire, présentent-ils une grande variété ?
- Observez-vous des similarités entre les marqueurs issus de textes de type différent (journalistique VS fiction) ?

Le matériel à disposition :

(ici : <https://drive.google.com/drive/u/3/folders/1bjD1tDCbIEbKPMJtDBDHA7GPfy1VH0F>)

- Un **guide d'annotation**
- Un **guide pour l'utilisation de LabelStudio** (installation, création d'un projet d'annotation, import des données, définition du jeu d'étiquettes, annotation des données, export des données annotées).
- Un **script pour le calcul automatique de l'AIA** à partir des données annotées exportées de LabelStudio.

Organisation interne :

- Groupes formés par 3 personnes
 - 5 textes pour chaque groupe (les textes vous seront fournis sur l'ENT une fois les groupes formés).
- Annotateurs A, B, C :
- Un **textes jolly** (qui peut être journalistique ou fiction)

- 2 textes journalistique
- 2 textes fiction

Les étapes à suivre :

1. **Annotation** : chaque annotateur devra annoter tous les 5 textes
2. **Calcul de l'AIA** en suivant le schéma suivant (pour le calcul, cfr. script python) :
 - AIA entre A et B.
 - AIA entre C et B.
 - AIA entre A et C.
3. **Analyse qualitative** : mise en commun des annotations faites par A, B, C pour l'analyse qualitative des annotations.
4. **Rédaction** du dossier (3 à 5 pages maximum)

Livrables :

- Le corpus annoté en format .json (un fichier par annotateur)
- Un court dossier (3 à 5 pages maximum) pour présenter le travail. Le dossier doit aborder les points suivants :
 - Rappeler la problématique et la démarche suivie
 - Évaluation quantitative des annotations (AIA) (cfr. étape 2)
 - Évaluation qualitative des annotations, surtout des points de non accord (cfr. étape 3)
 - Les difficultés et problèmes rencontrés
 - Les limites et améliorations possibles du travail.

Envoyer à acolli@parisnanterre.fr

Date limite : 18 décembre 2025 à 20h00

Usage IA générative (ChatGPT, Mistral, etc...)

L'utilisation d'une IA générative (ChatGPT, Mistral, etc.) est autorisée uniquement pour la correction et la reformulation des phrases lors de la rédaction du dossier final.

Attention : correction/reformulation ≠ production de texte. Il est donc interdit de faire générer le texte du dossier final par une IA.

L'objectif principal du projet n'est pas d'obtenir un super AIA, mais d'évaluer la modélisation proposée et d'adopter un regard critique. Pour cette raison, faire annoter vos données par une IA sera non seulement facile à détecter, mais vous empêchera de réaliser une véritable évaluation qualitative de vos annotations.