

Delphine Battistelli

Anna Colli

Analyse symbolique des données

- Projet final -


Objectif du cours : montrer la nécessité (et la richesse) d'une réflexion théorique (axée sur les notions fondamentales nécessaires à la modélisation) en amont de toute démarche d'analyse automatique d'un phénomène linguistique, en particulier quand ce phénomène relève de la sémantique.

Objectif du projet final : le projet, découpé en deux parties, vise à proposer, sur un même corpus de textes, deux approches de modélisation portant sur deux phénomènes distincts, l'un portant sur l'analyse du phénomène de marquage de l'incertitude et l'autre portant sur l'analyse du phénomène de marquage de la datation calendaire.

Partie 2 : le marquage de la « datation calendaire »

Ce travail fait suite à l'exercice 9 du TD3 consacré à l'analyse automatique des *adverbiaux de localisation temporelle calendaire* (ALTC) - par exemple, « vers le 28 mars » ou « dès le début des années 2000 » - à l'aide de graphes UNITEK et introduit à la question de l'évaluation d'un système à l'aide des mesures classiques de rappel et de précision.

A votre disposition sera mis sur CEL un corpus, nommé CorpusALTC, composé des textes suivants :



Dans un fichier .pdf nommé **M1 TAL_NumGpe_NOM1_NOM2_NOM3**, à déposer sur CEL au plus tard le 15/01/2026, vous fournirez (sur 10 pages maximum) les éléments suivants en les commentant succinctement :

A. Définition des graphes de reconnaissance des ALTC

1. Les textes jolly_texteHessel et jolly_texteObama annotés manuellement (vous rendrez lisibles, à l'aide du code couleurs adopté au TD1, les choix de catégorisation retenus qui seront les mêmes qu'au TD1)
2. Une copie écran des principaux graphes définis sous Unitex (cf. Annexe I) ainsi qu'une copie écran de ces textes annotés automatiquement à l'aide de vos graphes
3. Les mesures de rappel et de précision (cf. Annexe II) qui permettent de comparer les annotations de 1. et 2.

B. Evaluation des graphes de reconnaissance

4. Les textes Le_Monde_Antiamericanisme_en_France_partition_0 et Le_Monde_Anne_Hidalgo_partition_0 annotés manuellement (vous conserverez évidemment vos choix de catégorisation et de codes couleurs formulés en A.)
5. Une copie écran de ces textes annotés automatiquement à l'aide des mêmes graphes définis et utilisés en A.
6. Les mesures de rappel et de précision qui permettent de comparer les annotations de 4. et 5.

C. Comparaison avec une autre approche et synthèse

7. Vous comparerez les résultats obtenus avec votre approche et avec celle proposée par l'outil HeidelTime sur l'ensemble des textes de A. et de B.
8. Vous terminerez par une synthèse sur l'ensemble de votre travail (incluant si besoin la présentation des difficultés sous UNITEX rencontrées).

ANNEXES


Annexe I. Pistes pour la création des dictionnaires sous UNITEX

Il s'agit ici de pistes. Vous pouvez tout à fait définir des dictionnaires différents selon les choix de catégorisation que vous aurez privilégiés au vu d'un premier travail manuel d'analyse du texte. Il est en tout cas clair que l'on va avoir besoin de plusieurs dictionnaires pour faire fonctionner les futurs automates. Tout d'abord, reprenons la liste des mots susceptibles d'apparaître dans une date, comme dans les exemples [1] et [2].


[1] Ce mercredi 2 octobre 1872

[2] Le 29 septembre

Pour former une date, nous avons besoin de mots tels que le nom des jours de la semaine et le nom des mois de l'année. Ainsi, dans le dictionnaire jour.dic, nous trouverons les mots lundi, mardi, etc., et dans le fichier mois.dic, les mots janvier, février, etc. (cf. Figure 1). Dans les futurs transducteurs concernant les dates, nous trouverons donc ces dictionnaires appelés sous la forme <JOUR> et <MOIS>.




On peut ensuite s'intéresser à créer les dictionnaires N2, N3, N4, N6 et N7 (cf. Figure 2) afin de récupérer certains noms de temps tels que « époque », « matinée » ou « hiver » dans les différents automates.



On peut remarquer également dans le tableau des relevés que les adverbes apparaissent souvent seuls et sans virgule. On pourra donc créer un dictionnaire pour eux, appelé ici Advt.dic (cf. Figure 3).

Il est cependant des adverbes qui peuvent être employés dans plusieurs domaines, et notamment dans le spatial autant que dans le temporel. Par exemple, nous avons fait le choix d'entrer dans la liste ci-après l'adverbe « là-dessus », en pensant au sens de « après cela, sur ces paroles ». Or cet adverbe peut également s'utiliser dans le sens spatial de « sur ». Nous supposons que cet emploi spatial est moins fréquent dans la littérature, car plus familier.



Annexe II. Méthodes d'évaluation d'un système de TAL

Les **mesures d'évaluation** les plus fréquemment utilisées pour les systèmes de TAL sont le rappel et la précision. Ces mesures sont issues du domaine de la recherche d'information et se sont largement répandues dans l'évaluation de divers systèmes de TAL (extraction d'information, analyse syntaxique automatique, etc.). Ces deux notions sont souvent utilisées, car elles reflètent le point de vue de l'utilisateur : si la précision est faible, l'utilisateur sera insatisfait, car il devra perdre du temps à lire des informations qui ne l'intéressent pas. Si le rappel est faible, l'utilisateur n'aura pas accès à une information qu'il souhaitait avoir.

De manière générale, le rappel mesure le silence du système, c'est-à-dire les informations pertinentes qui n'ont pas été trouvées, tandis que la précision en mesure le bruit, c'est-à-dire les informations non pertinentes trouvées. Plus le taux de rappel est haut, moins il y a de silence, plus la précision est élevée, moins il y a de bruit. Les formules ci-après indiquent comment calculer ces taux.

Rappel = nombre d'informations bien repérées / nombre d'informations à repérer

$$0 \leq \text{Rappel} \leq 1$$

Précision = nombre d'informations bien repérées / nombre d'informations repérées

$$0 \leq \text{Précision} \leq 1$$